# Ein Rekonstruktionsverfahren für die Elektrische Impedanztomographie basierend auf maschinellem Lernen und realen Messdaten

**A reconstruction method for electrical impedance tomography based on machine learning and real measurement data**

Masterarbeit von Lars Gudjons

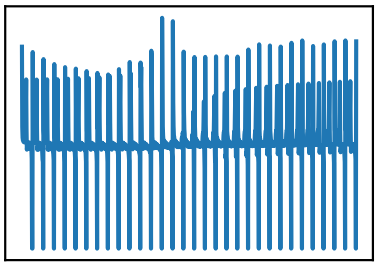
Tag der Einreichung: 15. Januar 2024

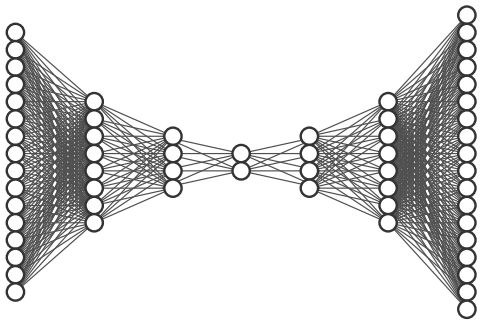
1. Gutachten: Prof. Dr.-Ing. Christoph Hoog Antink, KIS*MED
Darmstadt

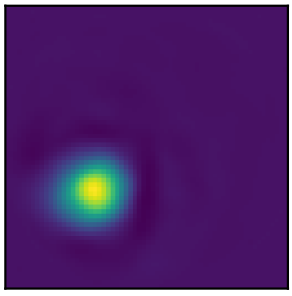
TECHNISCHE UNIVERSITÄT DARMSTADT

Fachbereich Elektrotechnik und Informationstechnik

KIS*MED - Künstlich Intelligente Systeme der Medizin







## Erklärung zur Abschlussarbeit gemäß § 22 Abs. 7 APB TU Darmstadt

Hiermit erkläre ich, Lars Gudjons, dass ich die vorliegende Arbeit gemäß § 22 Abs. 7 APB der TU Darmstadt selbstständig, ohne Hilfe Dritter und nur mit den angegebenen Quellen und Hilfsmitteln angefertigt habe. Ich habe mit Ausnahme der zitierten Literatur und anderer in der Arbeit genannter Quellen keine fremden Hilfsmittel benutzt. Die von mir bei der Anfertigung dieser wissenschaftlichen Arbeit wörtlich oder inhaltlich benutzte Literatur und alle anderen Quellen habe ich im Text deutlich gekennzeichnet und gesondert aufgeführt. Dies gilt auch für Quellen oder Hilfsmittel aus dem Internet.

Diese Arbeit hat in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen.

Mir ist bekannt, dass im Falle eines Plagiats (§ 38 Abs. 2 APB) ein Täuschungsversuch vorliegt, der dazu führt, dass die Arbeit mit 5,0 bewertet und damit ein Prüfungsversuch verbraucht wird. Abschlussarbeiten dürfen nur einmal wiederholt werden.

Bei einer Thesis des Fachbereichs Architektur entspricht die eingereichte elektronische Fassung dem vorgestellten Modell und den vorgelegten Plänen.

Darmstadt, 15. Januar 2024



L. Gudjons

# Danksagung

An dieser Stelle möchte ich mich bei all denjenigen bedanken, die mich während der Anfertigung dieser Arbeit und im Studium unterstützt und motiviert haben.

Zuerst möchte ich mich bei Herrn Prof. Dr.-Ing. Christoph Hoog Antink für die Gelegenheit bedanken, an diesem spannenden Thema arbeiten zu können. Sie haben mir viel Freiheit gelassen und mir ermöglicht, meine eigenen Ideen einzubringen und selbstständig zu arbeiten. Ebenfalls danke ich Ihnen für die persönliche Betreuung, bei der Sie durch regelmäßige Anregungen und konstruktive Beiträge zur Seite standen.

Ein großer Dank richte ich an meine Kommilitonen und Freunde, die einen bedeutenden Beitrag zur fachlichen Entwicklung sowie zur Erhaltung der mentalen Gesundheit durch gemeinsames Lernen während des Studiums geleistet haben. Dabei danke ich vor allem Tim Engel, Anatoli Kasanski, Fabian Krauß, Tim Maier, Stefan Schulte und Esan Sundaralingam. Durch die gemeinsam verbrachte Zeit und Erfahrungen war das Studium eine tolle Zeit.

Ebenfalls bedanke ich mich bei all denjenigen, die mir durch Ratschläge und Anregungen zu dieser Arbeit zur Seite standen.

Für das Korrekturlesen dieser Arbeit danke ich Anatoli Kasanski, Tim Maier (aka. mbaeuerlein), Emily Reinhold und meinen Eltern Katja Gudjons und Thorsten Gudjons.

Ein zusätzlicher Dank gilt meinen Eltern, Katja und Thorsten, für die Unterstützung während meines Studiums in allen Belangen.

Lars Gudjons

Darmstadt, 15.01.2024

# Kurzfassung

Die Elektrische Impedanz Tomographie (EIT) ist ein kostengünstiges und nichtinvasives Bildgebungsverfahren, welches es ermöglicht, die räumliche Impedanzverteilung eines Körpers zu bestimmen. Dieses Verfahren findet Anwendung sowohl in wissenschaftlichen, industriellen als auch medizinischen Kontexten. Ein Beispiel dafür ist die Überwachung der Lungenventilation.
Es existieren bereits viele Ansätze der EIT Bildrekonstruktion. Sie werden in modellbasierte und datenbasierte Ansätze unterschieden. Dabei haben sich in den letzten Jahren immer mehr die datenbasierten Ansätze als vielversprechend erwiesen. Für diese werden große Datensätze an Trainingsdaten benötigt. Solche Datensätze werden aktuell in der Regel durch Simulationen erzeugt. Ziel dieser Arbeit ist es, zu prüfen, ob dies ebenfalls mit einem Datensatz aus realen Messdaten möglich ist.

Zunächst wird ein Versuchsaufbau entwickelt, um einen entsprechenden Datensatz generieren zu können. Dieser Aufbau umfasst ein EIT-Gerät, speziell das EIT32-Modell der Firma ScioSpec, sowie einen Plexiglas-Tank mit Wasser, dessen Impedanzverteilung aufgezeichnet wird. Darüber hinaus wird ein Positioniersystem für Objekte verwendet, welche in den Tank eingeführt werden, um unterschiedliche Impedanzverteilungen zu erzeugen. Der Versuchsaufbau wird anschließend verwendet, um über $14\,000$ Samples zu sammeln.
Mit diesem Datensatz werden danach drei Modellarten evaluiert und verglichen. Eine lineare- und eine K-Nearest Neighbors (KNN) Regression, sowie ein neuronales Netzwerk. Zusätzlich wird die Möglichkeit der Data Augmentation und Dimensionality Reduction auf EIT Daten und deren Effekt analysiert. Dabei werden die Verfahren der Noise-, Rotation-, Gaussian-Blur- und Superposition-Augmentation genutzt.

Die Möglichkeit des Trainings von datenbasierten Modellen an realen Messdaten konnte bestätigt werden. Dabei schnitten die neuronalen Netze in relevanten Metriken bis zu $28\,\%$ besser ab als die Ansätze der linearen- oder der K-Nearest-Neighbours-Regression.
Ebenfalls wurde festgestellt, dass die Qualität des Datensatzes einen erheblichen Einfluss auf die Generalisierungsfähigkeit der Modelle hat. Aus diesem Grund wurde untersucht, ob die Variation der Daten mittels Augmentation verbessert werden kann.
Dabei ergab sich, dass besonders bei geringen Datenmengen ($120$ Samples) die Qualität der Modelle durch Augmentation verbessert werden kann. Zum einen wurde nachgewiesen, dass durch die Anwendung von Noise und Rotation als Augmentationsmethoden die Leistung der Algorithmen signifikant um bis zu $50\,\%$ gesteigert werden kann. Darüber hinaus konnte durch die Anwendung von Gaussian-Blur-Augmentation der visuelle Eindruck der Rekonstruktionen verbessert werden. Es wurde erfolgreich demonstriert, dass die Superposition-Augmentation es ermöglicht, Modelle besser auf komplexe Szenarien zu generalisieren.

# Abstract

Electrical impedance tomography (EIT) is a cost-effective and non-invasive imaging technique that makes it possible to determine the spatial impedance distribution of a body. This method is used in scientific, industrial and medical contexts. One example of this is the monitoring of lung ventilation.
Many approaches to EIT image reconstruction already exist. They are divided into model-based and data-based approaches. In recent years, data-based approaches have proven to be increasingly promising. This requires large data sets of training data. These are currently usually generated by simulations. This work aims to test whether this is also possible with a data set from real measurement data.

First, an experimental setup is developed to be able to generate a corresponding data set. This setup includes an EIT device, specifically the EIT32 model from ScioSpec, and a Plexiglas tank with water whose impedance distribution is recorded. In addition, a positioning system is used for objects that are inserted into the tank to generate different impedance distributions. The experimental setup is then used to collect over $14\,000$ samples. Three types of models are then evaluated and compared with this data set. A linear- and a K-Nearest Neighbors (KNN) regression, as well as a neural network. In addition, the possibility of data augmentation and dimensionality reduction on EIT data and their effects are analyzed. The methods of noise-, rotation-, Gaussian blur- and superposition-augmentation are used.

The possibility of training data-based models on real measurement data was confirmed. The neural networks performed up to $28\,\%$ better in relevant metrics than the linear- or K-nearest neighbor regression approaches. It was also found that the quality of the data set significantly influences the generalization ability of the models. For this reason, it was investigated whether the variation of the data can be improved through augmentation. It was found that the quality of the models can be improved by augmentation, especially with small amounts of data ($120$ samples). On the one hand, it was shown that the performance of the algorithms can be significantly increased by up to $50\,\%$ by using noise and rotation as augmentation methods. In addition, using Gaussian blur augmentation improved the visual impression of the reconstructions. It was successfully demonstrated that superposition augmentation enables models to be better generalized to complex scenarios.

# Inhaltsverzeichnis


**1 Einleitung** **8**

**2 Grundlagen Elektrische Impedanz-Tomographie** **11**
2.1 Messprinzip . . . 12
2.2 Vorwärtsproblem . . . 16
2.3 Rückwärtsproblem . . . 17
2.4 Regularisierung . . . 19
2.4.1 Tikhonov-Regularisierung . . . 19
2.4.2 NOSER-Regularisierung . . . 20
2.4.3 Laplace-Regularisierung . . . 20

**3 Grundlagen Neuronale Netze** **21**
3.1 Aufbau . . . 21
3.2 Trainingsdaten . . . 23
3.3 Training . . . 24
3.3.1 Loss Function . . . 24
3.3.2 Gradient Decent . . . 25
3.3.3 Backpropagation . . . 27
3.4 Regularisierung . . . 28
3.4.1 Weight Decay . . . 29
3.4.2 Early Stopping . . . 29
3.4.3 Dropout Layer . . . 30
3.4.4 Data Augmentation . . . 31

**4 Stand der Technik Image Reconstruction** **32**
4.1 Modellbasierte Ansätze . . . 32
4.2 Datenbasierte Ansätze . . . 33
4.2.1 Direkte Rekonstruktion mit einem einzigen neuronalen Netz . . . 33
4.2.2 Verbindung aus traditionellen Algorithmen und Netzwerken . . . 34
4.2.3 Hybrides Deep Learning . . . 35

**5 Algorithmus Performance Kriterien** **36**
5.1 Vorverarbeitung . . . 36
5.2 Kriterien . . . 38
5.2.1 Amplitude Response . . . 38
5.2.2 Position Error . . . 38
5.2.3 Resolution . . . 39
5.2.4 Shape Deformation . . . 39
5.2.5 Ringing . . . 39

**6 Versuchsaufbau** **40**

**7 Datensammlung und Vorverarbeitung** **42**
7.1 Augmentation . . . 43
7.1.1 Noise Augmentation . . . 44
7.1.2 Rotation Augmentation . . . 44
7.1.3 Superposition Augmentation . . . 45
7.2 Dimensionality Reduction . . . 46
7.3 Signal to Noise Ratio . . . 48
7.4 Overfitting an Aufbau . . . 49
7.5 Gesammelte Trainingsdaten . . . 49

**8 Ergebnisse und Diskussion Time Difference EIT** **50**
8.1 Lineare Regression . . . 50
8.2 K-Nearest Neighbors Regression . . . 52
8.3 Artificial Neural Network . . . 54
8.3.1 Dropout Layer . . . 57
8.3.2 Einfluss der Augmentation . . . 58
8.3.3 Einfluss Weight Decay . . . 61
8.3.4 Optimale Lerarning Rate . . . 62
8.3.5 Einfluss Dimensionality Reduction . . . 63
8.3.6 Performance mit optimalen Parametern . . . 64
8.3.7 Unterschiedliche Target-Materialien . . . 65

**9 Ergebnisse und Diskussion Absolute EIT** **66**
9.1 Artificial Neural Network . . . 66
9.1.1 Dimensionality Reduction . . . 67
9.1.2 Einfluss der Normierung . . . 68
9.1.3 Performance . . . 70
9.1.4 Unterschiedliche Target-Größen . . . 71
9.1.5 Superposition Augmentation . . . 72
9.1.6 Unterschiedliche Target-Materialien . . . 74
9.2 Lineare Regression . . . 77
9.3 K-Nearest Neighbors Regression . . . 79

**10 Diskussion** **81**

**11 Schlussfolgerung und Ausblick** **84**

**Abbildungsverzeichnis** **86**

**Tabellenverzeichnis** **89**

**Akronyme** **91**

**Literatur** **92**

# 1 Einleitung

Die medizinische Bildgebung spielt eine immer entscheidendere Rolle bei der Diagnose und Behandlung unterschiedlicher Krankheiten oder Verletzungen [1]. In den letzten Jahrzehnten wurden verschiedene bildgebende Verfahren entwickelt, die es Ärzten ermöglichen, detaillierte Einblicke in den Körper eines Patienten zu erhalten. Eine relativ neue Technologie, die vielversprechende Ergebnisse zeigt, ist die Elektrische Impedanz Tomographie (EIT) [2]. Die EIT basiert auf dem Prinzip der Impedanzmessung und ermöglicht die günstige, portable und nichtinvasive Visualisierung von Gewebeeigenschaften und Prozessen im Körper [3].
Die traditionellen Verfahren der medizinischen Bildgebung wie Röntgen, Computertomografie (CT), Magnetresonanztomographie (MRT) und Ultraschall nutzen verschiedene physikalische Phänomene, um Bilder des Körpers zu erzeugen. Röntgengeräte und CTs verwenden ionisierende Röntgenstrahlung, wobei unterschiedlich dichte Materie unterschiedlich viel Strahlung hindurchlässt. MRTs nutzen starke Magnetfelder, um den Spin der Protonen auszurichten und anschließend die durch die Rückausrichtung entstehende Strahlung zu detektieren. Ultraschallgeräte nutzen die Eigenschaften von Gewebearten, Schallwellen unterschiedlich stark zu absorbieren oder reflektieren [2].
EIT hingegen nutzt elektrische Ströme und Spannungen, um die elektrische Leitfähigkeit im Körper zu messen. Jedes Gewebe hat eine spezifische elektrische Leitfähigkeit, die durch die Anwesenheit von Flüssigkeiten, Ionen und Zellen beeinflusst wird [3]. Unter anderem durch die begrenzte Anzahl an Elektroden, die ringförmig um den Körper angebracht werden können, ergibt sich auch eine deutlich geringere räumliche Auflösung im Vergleich zu den traditionellen Verfahren. Der Vorteil von EIT liegt unter anderem in der dafür hohen temporalen Auflösung von mehr als $30$ Frames per Second (FPS), was beispielsweise eine Realtime Überwachung beatmeter Intensivpatienten ermöglicht. Weitere Vorteile sind der geringe Preis und die Portabilität. Insbesondere durch die geringen Kosten kann das Verfahren häufiger genutzt werden als aufwendigere Verfahren wie MRT und CT [4]. Eine Übersicht der Verfahren ist in Tabelle 1.1 zu sehen.

Tabelle 1.1: Vergleich der medizinischen Bildgebungsverfahren [2, 5].

| **Verfahren** | **CT** | **Ultraschall** | **MRT** | **EIT** |
|---|---|---|---|---|
| **Funktion** | Röntgenstrahlung | Schallwellen | Radiowellen | Impedanz |
| **Strahlungsart** | ionisierend | nicht ionisierend | nicht ionisierend | nicht ionisierend |
| **Kontrast** | hoch | gering | hoch | gering |
| **Räumliche Auflösung** | 50µm-200µm | 50µm-500µm | 25µm-100µm | gering ($\sim 10\,\%$ des Vol.) |
| **Zeitliche Auflösung** | 83 ms-135 ms | $<5$ ms | 20 ms-50 ms | 0.5 ms-5 ms |
| **Kosten** | moderat | gering | sehr hoch | gering |
| **Portabel** | nein | ja | nein | ja |

EIT ist also für Anwendungen geeignet, die eine hohe Anforderung an die zeitliche Auflösung aufweisen, ein längere Überwachung von Vitalparametern erfordern oder kostengünstig und portabel sein müssen.

### Funktionsweise und Forschungsstand

Biologisches Gewebe ist aus einzelnen Zellen aufgebaut. Diese wiederum besteht aus dem Zellkern im Zytoplasma, das von einer Zellmembran (Doppellipidschicht) umgeben ist. Daraus kann ein elektrisches Ersatzschaltbild abgeleitet werden (Abbildung 1.1).

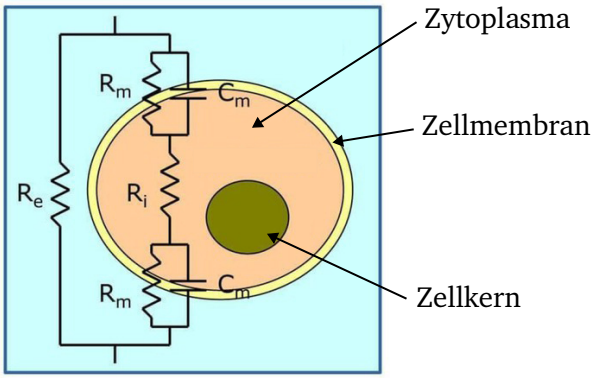



Abbildung 1.1: Elektrisch äquivalentes Schaltungsmodell einer Zelle. Die zellumgebende Flüssigkeit wird durch $R_e$ modelliert. Die Zellmembran hat einen resistiven ($R_m$) und einen kapazitiven ($C_m$) Anteil. Das Zytoplasma wird durch $R_i$ modelliert [6].

Dabei wird die zellumgebende Flüssigkeit wird durch $R_e$ modelliert. Die Zellmembran besitzt einen resistiven ($R_m$) und einen kapazitiven ($C_m$) Anteil und das Zytoplasma wird durch $R_i$ modelliert. $R_m$ ist in der Regel deutlich höher als $R_e$ und $R_i$. Dadurch sind niederfrequente Ströme nicht in der Lage durch die Zellmembran zu fließen. Bei höheren Frequenzen sinkt die Impedanz der Kapazität und und der Strom kann durch die Zellen fließen, wodurch die Gesamtimpedanz des Gewebes sinkt.
Gewebe besteht nun aus einem Netzwerk vieler verbundener Zellen, wodurch sich eine komplexe Impedanzverteilung ergibt. Durch das Wissen über diese Impedanzverteilung können unterschiedliche Strukturen im Körper differenziert und visualisiert werden. Dieses Modell ist jedoch lediglich für tierische Zellen gültig, da pflanzliche Zellen neben der Zellmembran ebenfalls eine zusätzliche dickere Zellwand besitzen, wodurch das Modell angepasst werden muss [7].

Die EIT befindet sich noch im Forschungsstadium und gehört noch nicht zu den Routineuntersuchungen, jedoch zeigen sich viele mögliche Anwendungsgebiete wie die Untersuchung von Hirnaktivitäten, Überwachung der pulmonalen Ventilation, Überwachung der Herzaktivität oder die Krebserkennung [3]. Weitere Anwendungen sind biosensorische Applikationen um Zellwachstum zu untersuchen, sowie industrielle Anwendungen zum Rohrleitungs-Monitorung und Kontaminations-Tracking [8, 9, 10]. Am häufigsten wird es aktuell für die Überwachung der pulmonale Ventilation verwendet [4].

Der Großteil der aktuellen Forschung im Bereich EIT beschränkt sich auf Simulationen. In der praktischen Anwendung könnte sich die Herausforderung ergeben, dass diese Algorithmen eine geringere Leistung aufweisen. Daraus ergibt sich der Bedarf für die Evaluierung eines Rekonstruktionsalgorithmus, welcher auf realen Messdaten basiert.
In dieser Arbeit wird deshalb ein Demonstrator implementiert, welcher auf einem EIT Gerät der Firma ScioSpec [11] basiert. Dieser wird für die automatisierte Sammlung von Trainingsdaten für Rekonstruktionsalgorithmen verwendet werden. Anschließend werden verschiedene Modelle zur Bildrekonstruktion aus den EIT Daten implementiert und verglichen.

### Aufbau der Arbeit

In Kapitel 2 wird zuerst das Messprinzip der EIT erklärt. Darin wird auf das sogenannte Vorwärtsproblem und Rückwärtsproblem eingegangen. Das Rückwärtsproblem ist dabei ein anderer Begriff für die EIT-Bildrekonstruktion.
In Kapitel 3 werden die erforderlichen Grundlagen neuronaler Netze erklärt, welche in dieser Arbeit zur Bildrekonstruktion genutzt werden. Dabei wird auch der Begriff der Regularisierung im Kontext neuronaler Netze erläutert sowie auf die, in dieser Arbeit relevante, Arten eingegangen.
Anschließend folgt in Kapitel 4 ein Überblick über den aktuellen Stand der Technik in der EIT-Bildrekonstruktion. Darin wird zwischen modellbasierten und datenbasierten Ansätzen unterscheiden.
In Kapitel 5 werden Kriterien zur Evaluierung der Qualität von Rekonstruktionsalgorithmen eingeführt.
Danach wird in Kapitel 6 der entwickelte Versuchsaufbau beschreiben, welcher zur Sammlung der Messdaten genutzt wird.
Der Prozess der Datensammlung und Vorverarbeitung durch Augmentation wird in Kapitel 7 erläutert. Nachdem die Daten gesammelt wurden, werden mehrere Algorithmen implementiert und verglichen. Die Ergebnisse werden in den Kapiteln Kapitel 8 und Kapitel 9 präsentiert, wobei zwischen den Fällen der relativen und absoluten EIT unterscheiden wird. Anschließend werden die Ergebnisse in Kapitel 10 diskutiert und eingeordnet.

# 2 Grundlagen Elektrische Impedanz-Tomographie

Mittels der EIT kann durch Messung der Spannung am Rand eines Körpers eine Aussage über die räumliche Impedanzverteilung im Inneren des Körpers getroffen werden. In der Medizin wird EIT als Bildgebungsverfahren verwendet, welches ein (tomografisches) Schnittbild einer Körperregion erstellt. Dabei werden die unterschiedlichen elektrischen Eigenschaften von Gewebearten genutzt (Abbildung 2.1 A). Dafür werden Elektroden (meist 16 oder 32) zirkulär um den Körper angebracht (Abbildung 2.1 B) und geringe Wechselströme (typischerweise geringer als $10\,\mathrm{mA}$), unterschiedlicher Frequenzen (meist $1\,\mathrm{kHz} - 1\,\mathrm{MHz}$) eingespeist [3].
Es existieren die Single- und multi frequency EIT (mfEIT). Die Single frequency EIT kann lediglich die zeitliche Änderung der Impedanz bestimmen. Bei Verwendung mehrerer Frequenzen werden die unterschiedlichen kapazitiven Eigenschaften von Geweben genutzt, um verschiedene Gewebearten zu unterscheiden.
Die unterschiedlichen Frequenzen können entweder sequentiell, oder auch gleichzeitig überlagert eingespeist werden [3]. Der Strom wählt dabei den Weg der geringsten Impedanz, wodurch sich je nach Art und Verteilung des Gewebes eine andere Spannungsverteilung im Körper ergibt (Abbildung 2.1 C).

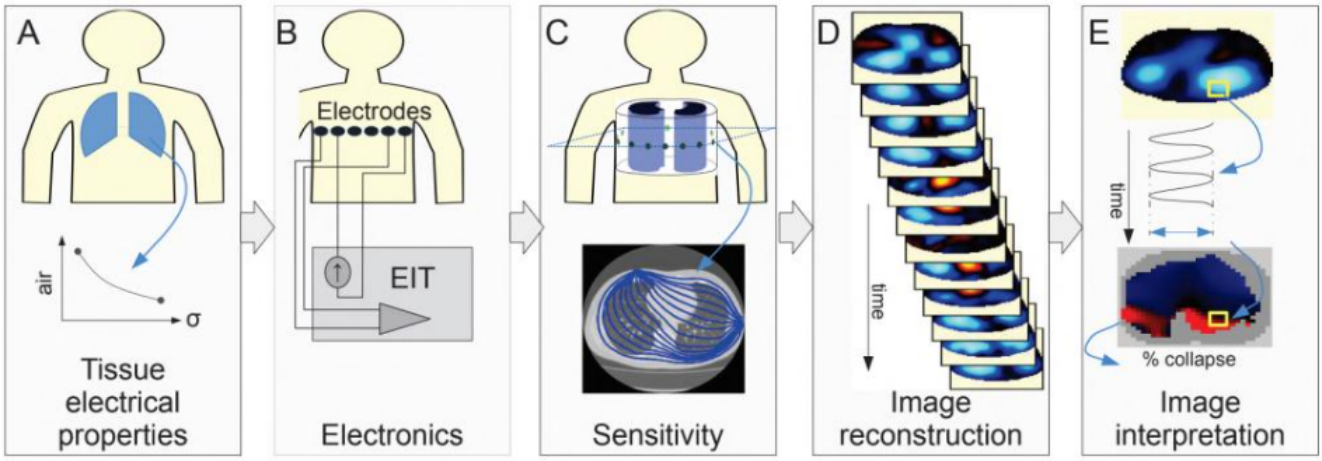



Abbildung 2.1: Überblick über den EIT Prozess. (A) Verschiedene Gewebearten haben unterschiedliche elektrische Eigenschaften. (B) Über Elektroden werden geringe Wechselströme in den Körper eingespeist. (C) Die Elektroden messen die Spannungsverteilung an der Oberfläche. Diese unterscheidet sich je nach Gewebeart und Verteilung im Körper. (D) Aus den Signalen wird mittels Rekonstruktionsalgorithmen ein Bild erzeugt. (E) Anschließend können Rückschlüsse über die Physiologie geschlossen werden [12].

Diese Spannungsverteilung kann nun an der Oberfläche des Körpers durch die nicht einspeisenden Elektroden gemessen werden. Daher unterscheidet sich das Verfahren zur Erstellung des Schnittbilds mittels EIT zu CT, bei welchem lineare elektromagnetische Strahlung die darzustellende Region rotatorisch aus verschiedenen Blickwinkeln durchdringt. Bei der MRT erfolgt die räumliche Zuordnung der Signale durch eine Frequenz- und Phasencodierung des Anregeimpulses.

Die EIT Messergebnisse werden gesammelt und anschließend durch einen Rekonstruktionsalgorithmus zu einem Bild umgewandelt (Abbildung 2.1 D). Der Eingang des Algorithmus ist die Spannungsverteilung an den Elektroden und je nach Ansatz weitere Informationen, wie ein Modell des Körpers. Aus diesen Daten wird anschließend die 2D Impedanzverteilung rekonstruiert. Danach können die Bilder für medizinische Zwecke, wie beispielsweise für die pulmonale Ventilation, interpretiert werden (Abbildung 2.1 E).

## 2.1 Messprinzip

In Abbildung 2.2 ist ein schematischer Aufbau eines EIT Geräts dargestellt. Ein Signalgenerator erzeugt Signale unterschiedlicher Frequenzen, die beim EIT Verfahren eingespeist werden sollen. Dieses Signal wird anschließend von einer spannungsgesteuerten Stromquelle umgesetzt und eingespeist. Als Messobjekt kann ein Plexiglastank mit angeschlossenen Elektroden genutzt werden. Dieser wird auch als Phantom Tank bezeichnet. Um die entsprechenden Einspeiseelektroden des Tanks auszuwählen, werden Multiplexer (MUX) eingesetzt [13]. Um die Messelektroden auszuwählen, werden Demultiplexer (DMUX) verwendet und auf einen oder mehrere Differenzverstärker geschaltet. Durch das Verwenden von mehreren Differenzverstärkern ist es möglich, die Messung zu parallelisieren und dadurch zu beschleunigen. Da verschiedene Messverstärker jedoch nie exakt identisch sind, geht der Vorteil verloren, dass alle Signale durch die gleiche Messkette fließen und somit Unterschiede je nach Messelektrode auftreten können. Das Signal des Differenzverstärkers wird anschließend durch einen Analog-Digital Wandler (ADC) in ein digitales Signal umgewandelt und von der Steuereinheit gespeichert [13]. Durch diese Verschaltung können beliebige Elektrodenpaare zum Einspeisen oder Messen ausgewählt werden.

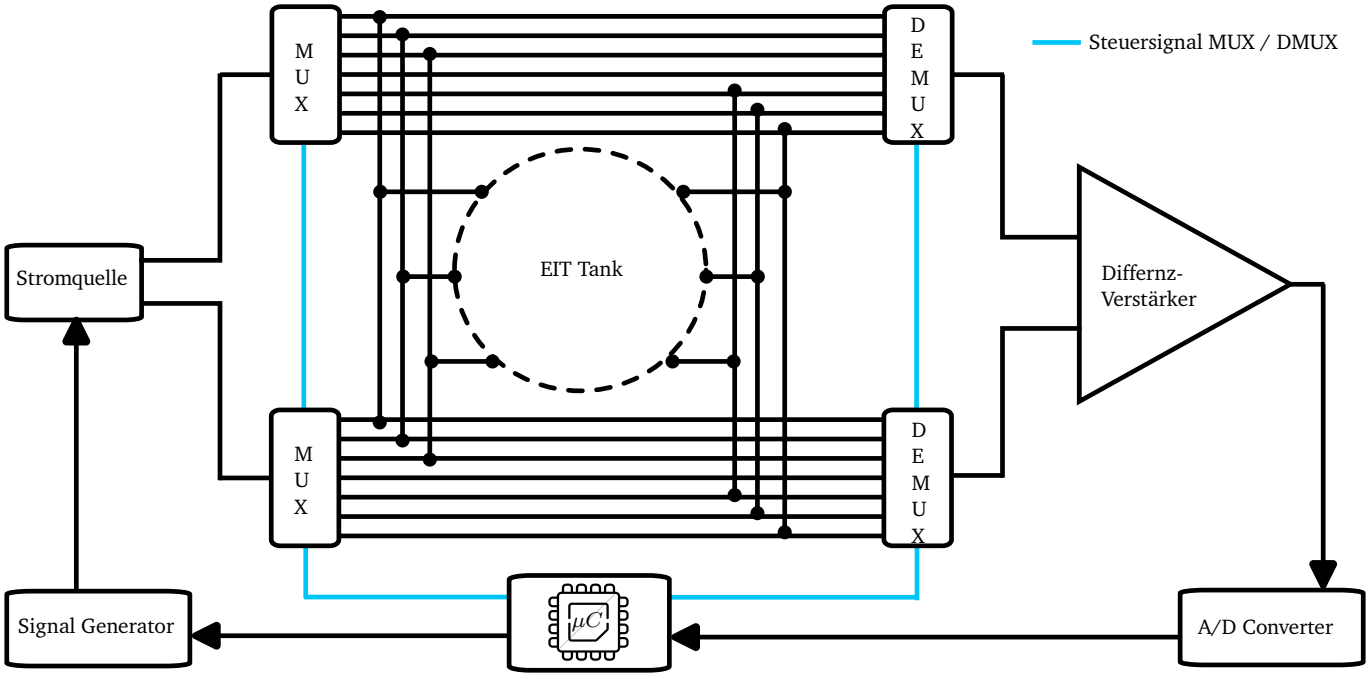



Abbildung 2.2: Das EIT Gerät steuert über einen Mikrocontroller ($\mu C$) eine Stromquelle, die Messsignale in die Zielregion einspeist. Ein Differenzverstärker mit ADC verstärkt und digitalisiert die gemessenen Spannungen. Das Verbinden der je nach Messung passenden Elektroden passiert über MUX und DMUX.

Beim Messvorgang können unterschiedliche Kombinationen von Elektroden zum Einspeisen und Messen verwendet werden. Diese werden auch „Injection Pattern“ und „Measurment Pattern“ genannt.
Allgemein lassen sich Injection und Measurment Pattern durch die sogenannten Skip-$n$ Patterns abbilden. Dabei wird beim Einspeisen $n$ Elektroden Platz zwischen Quelle und Senke gelassen.

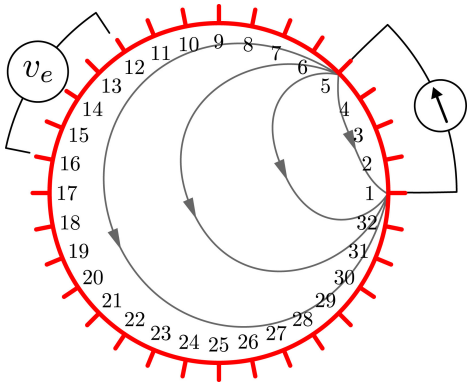



Abbildung 2.3: In diesem Beispiel ist eine Messung mit einem Skip-3 Injection Pattern und Skip-3 Measurment Pattern zu sehen [14].

Häufig verwendete Injektion Pattern sind das Skip-0 und das Skip-$n_{el}/2$ Pattern, welche auch „Adjesent“, „Opposite“ genannt werden. In diesem Fall ist $n_{el}$ die Anzahl der Elektroden [15].
Bei einer Messung rotieren die einspeisenden Elektroden ein Mal zirkulär um die Zielregion. In Abbildung 2.4 ist die sich ergebende Verteilung der Spannungs-Äquipotentiallinien zu sehen.

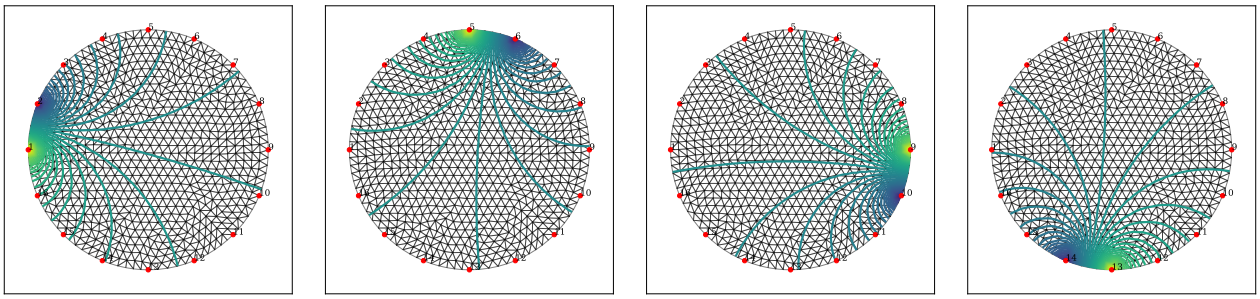


Abbildung 2.4: Ablauf einer EIT Messung. Die farbigen Linien repräsentieren die Spannungs-Äquipotentiallinien bei unterschiedlichen Einspeiseelektroden. Hierbei ist beispielhaft jede vierte Messung gezeigt. Insgesamt ergeben sich bei 16 Elektroden auch 16 Messungen.

In Abbildung 2.5 befindet sich nun eine Anomalie mit einer, vom Hintergrund abweichenden, Impedanz im Zielgebiet. Es ist zu erkennen, dass sich die Äquipotentiallinien verschieben und somit auch andere Spannungen an den Elektroden gemessen werden.

Die Anzahl der Elektroden des Messgeräts ist $n_{el}$, und die Anzahl unterschiedlicher Konfigurationen der Einspeiseelektroden ist $n_{inj}$. Pro Messung ergeben sich $n_{el} \cdot n_{inj}$ Spannungsmessungen. Meistens gilt jedoch $n_{el} = n_{inj}$, da die gleichen Elektroden zum Einspeisen und Messen genutzt werden. Diese werden in einem Spannungsvektor $\vec{V}$ kombiniert, der häufig als EIT-Frame bezeichnet wird. Ein Beispiel ist in Tabelle 2.1 zu sehen.

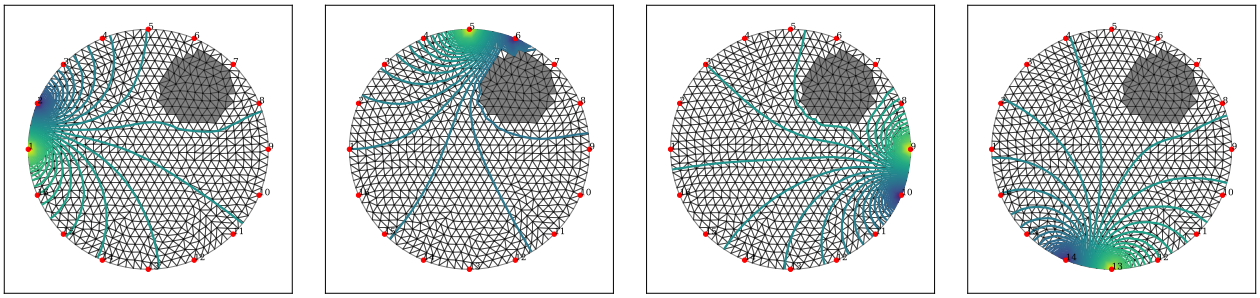


Abbildung 2.5: Eine Anomalie unterschiedlicher Impedanz verändert die sich ergebenen Äquipotentiallinien. Dadurch ergeben sich andere Potenziale an den Messelektroden.

Tabelle 2.1: Beispiel für einen EIT-Frame. Die einspeisenden Elektroden rotieren ein Mal im Kreis. Während jeder Einspeisung messen die restlichen Elektroden die Differenzspannungen.

| Elektroden für die Einspeisung | Elektroden für Differenzspannung | Gemessene Spannung |
|---|---|---|
| 1 , 0 | 1 , 2 | $V_1$ |
| 1 , 0 | 2 , 3 | $V_2$ |
| 1 , 0 | ... , ... | $V_{...}$ |
| 1 , 0 | n , (n-1) | $V_{n_{el}}$ |
| 2 , 1 | 1 , 2 | $V_{n_{el}+1}$ |
| 2 , 1 | 2 , 3 | $V_{n_{el}+2}$ |
| ... | ... | $V_{...}$ |
| n , (n-1) | n-1 , n | $V_{n_{el}*n_{inj}}$ |

Der EIT-Frame kann anschließend über dem Index aufgetragen und visualisiert werden (Abbildung 2.6).

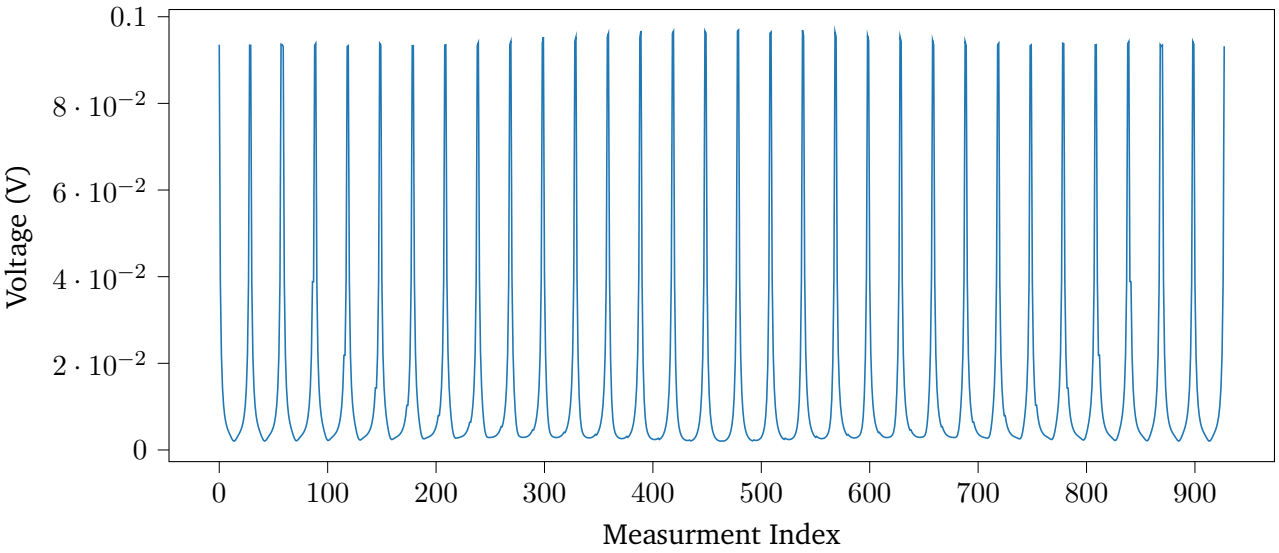



Abbildung 2.6: Die gemessenen Spannungen können anschließend über dem Index aufgetragen und somit visualisiert werden.

Im Folgenden sei $n_{el} = 32$. Die Einspeiseelektroden können anschließend vom EIT-Frame ausgeschlossen werden, da diese keine relevante Information enthalten [16]. Die Dimensionalität ergibt sich dadurch zu:

$$\dim(\vec{V}) = n_{el}(n_{el} - 3) = 928. \tag{2.1}$$

Das System stellt ein passives elektrisches N-Tor dar. Dadurch gilt das Reziprozitätsprinzip: Dies bedeutet, dass die Wechselwirkung zwischen den Elektroden a und b durch die Admittanzmatrix mit der Messung zwischen den Elektroden c und d verknüpft ist. Daher liefern die Wechselwirkung zwischen c und d und die Messung zwischen a und b keine zusätzlichen Informationen. Damit ergeben sich für $n_{el} = 32$ unter Ausschluss der Einspeiseelektroden $l$ linear unabhängige Messwerte:

$$l = \frac{n_{el}(n_{el} - 3)}{2} = 464. \tag{2.2}$$

Dies entspricht der maximal zu erwartenden Auflösung der Rekonstruktion in Pixeln [17].

Das EIT Problem wird in ein Vorwärtsproblem und ein inverses Problem unterteilt. Beim Vorwärtsproblem werden die Oberflächenspannungen in Abhängigkeit des Zielkörpers und der Impedanzverteilung bestimmt. Das Vorwärtsproblem wird häufig mittels einer Finite Elemente Methode (FEM) gelöst.
Das inverse Problem der EIT, auch als Bildrekonstruktion bezeichnet, ist das Lösen der Impedanzverteilung entsprechend der gemessenen Spannungen.

## 2.2 Vorwärtsproblem

Das Vorwärtsproblem ist der Fall, in dem die elektrische Antwort des Systems ($\vec{V}$) auf eine bekannte Impedanzverteilung $Z(\vec{x})$ und Anregung, wie z.B eine Stromdichte ($\vec{J}$), gesucht ist. Dabei ist $\vec{x}$ die Ortskoordinate, $\Omega$ das Gebiet des zu untersuchenden Körpers und $\partial\Omega$ der Rand dieses Körpers. Es gilt $\vec{x} \in \Omega$.
Der Vektor $\vec{x}$ ist im Falle der 2D Bildgebung $\vec{x} = \begin{pmatrix} x \\ y \end{pmatrix}$.

Um die Spannungsverteilung zu ermitteln, werden die Maxwell Gleichungen benötigt. Die elektrische Potenzialverteilung ist $\Phi(\vec{x})$. Somit gilt für das elektrische Feld $\vec{E}(\vec{x})$

$$\vec{E}(\vec{x}) = -\nabla\Phi(\vec{x}). \tag{2.3}$$

Wird nun statt der Impedanzverteilung $Z(\vec{x})$ die Leitfähigkeit $\sigma(\vec{x})$ verwendet, so ergibt sich folgender Zusammenhang aus der Stromdichte $J(\vec{x})$ und der Potenzialverteilung $\Phi(\vec{x})$

$$\vec{J}(\vec{x}) = -\sigma(\vec{x})\nabla\Phi(\vec{x}). \tag{2.4}$$

Aufgrund der Quellenfreiheit im Körper muss ebenfalls die Kontinuitätsgleichung gelten

$$\nabla\vec{J}(\vec{x}) = -\nabla\sigma(\vec{x})\nabla\Phi(\vec{x}) = 0 \quad \vec{x} \in \Omega \quad \setminus \quad \partial\Omega. \tag{2.5}$$

Für die skalare Stromdichte $j(\vec{x})$ gilt als Randbedingung

$$-\vec{J}(\vec{x}) \cdot \vec{n}(\vec{x}) = \sigma(\vec{x})\nabla\Phi(\vec{x}) \cdot \vec{n}(\vec{x}) = j(\vec{x}) \quad \vec{x} \in \partial\Omega. \tag{2.6}$$

Bei $\vec{n}(\vec{x})$ handelt es sich um den nach Außen zeigenden Normalvektor auf dem Rand $\partial\Omega$. Wenn nun $j(\vec{x})$ und $\sigma(\vec{x})$ gegeben sind, so ist die partielle Differenzialgleichung ein Neumann Problem und hat eine, bis auf eine Konstante $e$, eindeutige Lösung. Diese entspricht dem Erdungspotential.

$$\vec{V} = F(Z(\vec{x})) + e \tag{2.7}$$

Somit kann die Spannung $\vec{V}$ aus dem Vorwärtsproblem bestimmt werden. Dies ist jedoch nur für einfache Anordnungen analytisch möglich. Für komplexere Impedanzverteilungen wird deshalb meistens eine FEM verwendet [17].

#### Finite Elemente Methode

Bei der FEM werden die Volumen in kleine Elemente (Meshes) aufgeteilt. Je kleiner die Elemente, desto genauer kann beispielsweise die Verteilung des E-Feldes in dem Körper an der Stelle bestimmt werden.
Die Elemente müssen dabei jedoch nicht gleich groß sein, weshalb an Stellen, an denen die Genauigkeit der Werte nicht so relevant ist, weniger größere Elemente verwendet werden können. Somit werden Ressourcen gespart. Für diese Zwecke wird meistens MATLAB in Verbindung mit der Electrical Impedance Tomography and Diffuse Optical Tomography Reconstruction Software (EIDORS) verwendet [18]. In dieser Arbeit wurden Simulationen mit pyEIT erzeugt [19].

## 2.3 Rückwärtsproblem

Beim Rückwärtsproblem ist es nun das Ziel, die Impedanzverteilung $Z(\vec{x})$ bei bekanntem Spannungsvektor $\vec{V}$ zu bestimmen.

$$\vec{Z}(\vec{x}) = F^{-1}(\vec{V}) \tag{2.8}$$

Bei kleinen Änderungen in $Z(\vec{x})$ kann eine lineare Näherung angewendet werden. Es wird mit einer Impedanzverteiliung $Z_0(\vec{x})$ gestartet. Wird nun eine kleine Änderung in der Impedanzverteilung $Z_1(\vec{x})$ betrachtet, kann folgendes linearisiertes Vorwärtsproblem formuliert werden:

$$\vec{V}_1 = F(\vec{Z}_0(\vec{x})) + \mathbf{J}(\vec{Z}_1(\vec{x}) - \vec{Z}_0(\vec{x})). \tag{2.9}$$

**J** ist hierbei die Jakobi-Matrix, welche die partiellen Ableitungen enthält.

$$\mathbf{J} = \begin{bmatrix} \frac{\partial V_1}{\partial Z_1} & \frac{\partial V_1}{\partial Z_2} & \frac{\partial V_1}{\partial Z_3} & \cdots & \frac{\partial v_1}{\partial Z_M} \\ \frac{\partial V_2}{\partial Z_1} & \frac{\partial V_2}{\partial Z_2} & \frac{\partial V_2}{\partial Z_3} & \cdots & \frac{\partial v_2}{\partial Z_M} \\ \frac{\partial V_3}{\partial Z_1} & \frac{\partial V_3}{\partial Z_2} & \frac{\partial V_3}{\partial Z_3} & \cdots & \frac{\partial v_3}{\partial Z_M} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{\partial V_N}{\partial Z_1} & \frac{\partial V_N}{\partial Z_2} & \frac{\partial V_N}{\partial Z_3} & \cdots & \frac{\partial v_N}{\partial Z_M} \end{bmatrix} \tag{2.10}$$

In realen Anwendungen ist die absolute Impedanzverteilung des Zeilkörpers $Z_0(\vec{x})$ meistens unbekannt. Deshalb werden meist Differenzverfahren wie time difference EIT (tdEIT) oder frequencie difference EIT (fdEIT) verwendet. Es existiert jedoch auch die Möglichkeit der absoluten EIT [20]. Für die tdEIT wird nun die Differenzspannung zwischen $V_{t1}$ und einer Referenzmessung $V_{t0}$ zu verschiedenen Zeitpunkten gebildet. Anschließend kann noch mit $V_{t0}$ normalisiert werden:

$$V_{diff} = (V_{t1} - V_{t0})/V_{t0}. \tag{2.11}$$

Zusätzlich kann $V_{t0}$ über mehrere Frames gemittelt werden, sodass er als rauschfrei betrachtet werden kann [16]. Aus dieser Differenz der Spannungsvektoren kann nun die Differenz der Impedanzverteilung $Z_\Delta(\vec{x})$ bestimmt werden. Dies ist folgendermaßen möglich.

Werden zwei kleine Änderungen in der Impedanzverteilung: $Z_1(\vec{x})$ und $Z_2(\vec{x})$ betrachtet, kann folgendes linearisiertes Vorwärtsproblem formuliert werden:

$$\vec{V}_1 = F(\vec{Z}_0(\vec{x})) + \mathbf{J}(\vec{Z}_1(\vec{x}) - \vec{Z}_0(\vec{x})), \tag{2.12}$$

$$\vec{V}_2 = F(\vec{Z}_0(\vec{x})) + \mathbf{J}(\vec{Z}_2(\vec{x}) - \vec{Z}_0(\vec{x})). \tag{2.13}$$

Aus der Differenz ergibt sich folgende Gleichung:

$$\vec{V}_2 - \vec{V}_1 = F(\vec{Z}_0(\vec{x})) - F(\vec{Z}_0(\vec{x})) + \mathbf{J}(\vec{Z}_2(\vec{x}) - \vec{Z}_1(\vec{x})). \tag{2.14}$$

$$\vec{V}_\Delta = \mathbf{J}\vec{Z}_\Delta. \tag{2.15}$$

Dabei sind

$$\vec{V}_\Delta = \vec{V}_2 - \vec{V}_2 \quad \text{und} \tag{2.16}$$
$$\vec{Z}_\Delta = \vec{Z}_2 - \vec{Z}_2. \tag{2.17}$$

Somit ergibt sich zuerst das linearisierte Vorwärtsproblem

$$\vec{V} = \mathbf{J}\vec{Z} \tag{2.18}$$

und das daraus abgeleitete Rückwärtsproblem

$$\vec{Z} = \mathbf{A}\vec{V}. \tag{2.19}$$

Dabei ist $\mathbf{A}$ die Rekonstruktionsmatrix, welche für das Lösen der inversen EIT gefunden werden muss [17].

#### Bestimmung der Rekonstruktionsmatrix

Aus Gleichung (2.18) und Gleichung (2.19) könnte hervorgehen, dass die Rekonstruktionsmatrix durch Invertierung der Jakobi-Matrix bestimmt werden kann. Dies ist aber nicht möglich, da es sich hierbei um ein nach Hadamard „schlecht gestelltes“ Problem handelt [21]. Dies bedeutet, dass mindestens eins der folgenden Kriterien nicht erfüllt ist

1. Existenz der Lösung;
2. Eindeutigkeit der Lösung;
3. Stabilität der Lösung.

Die Existenz einer Lösung ist meistens gegeben, jedoch ist diese häufig nicht eindeutig. Wie in Abschnitt 2.1 gezeigt, ergibt sich bei $n_{el} = 32$ ein Spannungsvektor mit $464$ linear unabhängigen Spannungswerten pro Frame. Das bedeutet, dass das Impedanzbild eine maximale Seitenlänge von $\sqrt{464} \approx 21.54$ besitzen kann. Wenn höher aufgelöste Bilder (beispielsweise $(64 \times 64)$) genutzt werden, ist die Lösung nicht mehr eindeutig.

Damit hat die Jakobi-Matrix des resultierenden Problems keinen vollen Rang mehr und somit gilt

$$\det \mathbf{J} = 0. \tag{2.20}$$

Das letzte Kriterium ist ebenfalls verletzt, da die Impedanzverteilung $\vec{Z}$ nicht stetig vom Eingang $\vec{V}$ abhängig ist [17]. Dies hat zur Folge, dass die Lösung stark durch Störfaktoren beeinflussbar ist. Dies wird auch als hohe Kondition bezeichnet [22].
Damit handelt es sich um ein Problem, welches nur mit „a-priori Wissen“, also einer Einschränkung des Lösungsraumes bestimmt werden kann. Da keine eindeutige analytische Lösung existiert, kann das Problem in ein Minimierungsproblem umformuliert werden:

$$\underset{\vec{Z}}{\operatorname{argmin}} \, ||\mathbf{J}\vec{Z} - \vec{V}|| \tag{2.21}$$

## 2.4 Regularisierung

Das Ziel der Regularisierung ist es, einfachere und somit generellere Lösungen zu finden [23]. Dies wird durch Beschränkungen oder Strafterme erreicht. Sie wird unter anderem dafür verwendet um „schlecht gestellte“ Probleme, wie die EIT zu lösen. Im Falle von datenbasierten Algorithmen wird mit Regularisierung versucht, ein Überanpassen („Overfitting“) an die verwendeten Trainingsdaten zu vermeiden (vergl. Abschnitt 3.4).
Es wird zwischen einer expliziten oder impliziten Regularisierung unterschieden. Von expliziter Regularisierung wird gesprochen, wenn dem Optimierungsproblem explizit ein Term hinzugefügt wird. Die explizite Regularisierung wird üblicherweise bei unterbestimmten Optimierungsproblemen eingesetzt [23]. Der Regularisierungsterm erlegt der Optimierungsfunktion einen Preis auf, um die optimale Lösung eindeutig und einfacher zu machen. Implizite Regularisierung ist jede andere Form der Regularisierung. Dazu gehören z.B. Data Augmentation oder das Anpassen der Netzwerkarchitektur (vergl. Abschnitt 3.4).

In Gleichung (2.21) kann durch das Hinzufügen einer Regularisierungsmatrix $\mathbf{L}$ und einen Startvektor $\vec{Z}_s$ eine Regularisierung hinzugefügt werden:

$$\underset{\vec{Z}}{\operatorname{argmin}} ||\mathbf{J}\vec{Z} - \vec{V}|| + \lambda^2 ||\mathbf{L}(\vec{Z} - \vec{Z}_s)||. \tag{2.22}$$

Dabei kann als Initialisierung $\vec{Z}_s = 0$ gesetzt werden. Der hintere Teil von Gleichung (2.22) bestraft nun die Abweichungen von $\vec{Z}_s$. Die Stärke der Regularisierung kann durch den Hyperparameter $\lambda$ eingestellt werden.

Nun kann als Norm die L2-Norm genutzt werden:

$$||\vec{X}|| = ||\vec{X}||_{L2} = \vec{X}^T\vec{X} = \sqrt{\sum_{i=1} X_i^2} \tag{2.23}$$

Die Gleichung (2.22) kann anschließend analytisch gelöst werden. Dadurch ergibt sich die „Least-Squares“ Lösung. Wird $\vec{Z}_s = 0$ gesetzt ergibt sich folgendes Ergebnis:

$$\vec{Z} = \underbrace{(\mathbf{J}^T\mathbf{J} + \lambda^2\mathbf{L}^T\mathbf{L})^{-1}\mathbf{J}^T}_{\text{A}}\vec{V}. \tag{2.24}$$

Nun werden drei Regularisierungen vorgestellt, die in der EIT oft genutzt werden.

### 2.4.1 Tikhonov-Regularisierung

Eine der einfachsten expliziten Regularisierungen nutzt die Identitätsmatrix $\mathbf{I}$ als Regularisierungsmatrix:

$$\mathbf{L} = \mathbf{I}. \tag{2.25}$$

Diese führt zu einer ortsunabhängigen Bestrafung von Veränderungen des Rekonstruktionsergebnis $\vec{Z}$. Es handelt sich um eine ortsunabhängige „Kleinheitsannahme“. Das heißt, dass sich für $\vec{Z}_s$ alles möglichst nah an Null befinden soll. Es wird also das a priori Wissen verwendet, dass die Änderung der Impedanz nicht beliebig hoch sein wird.

### 2.4.2 NOSER-Regularisierung

Die Newton's One-Step Error Reconstructor (NOSER) Regularisierung hat eine Regularisierungsmatrix, welche eine ortsvariante Kleinheitsannahme darstellt.

$$\mathbf{L} = \sqrt{\delta(i,j)\mathbf{J}(i,j)\mathbf{J}(i,j)} \tag{2.26}$$

Dabei sind $i$ und $j$ die Indizes von Dreiecken in der FEM. Bei der NOSER-Regularisierung werden keine genaueren Impedanzrekosntruktionen erzeugt, aber dafür visuell bessere Bilder [24].

### 2.4.3 Laplace-Regularisierung

Bei der Laplace Regularisierung wird statt der Kleinheitsannahme die „Glattheitsannahme" verwendet. Dabei wird nicht die absolute Auslenkung von $\vec{Z}$ bestraft, sondern zu große Unterschiede von benachbarten Elementen. Damit wird die a priori Vermutung angewendet, dass wahrscheinlich keine extremen Sprünge in der Impedanzverteilung vorkommen sollten. Eine mögliche Regularisierungsmatrix wäre:

$$\mathbf{L}(i,j) = \begin{cases} 3 & \text{für } i = j \in \Omega \\ 2 & \text{für } i = j \in \partial\Omega \\ -1 & \text{für } i \neq j \wedge j \in \text{benachbarte Dreiecke} \\ 0 & \text{sonst.} \end{cases} \tag{2.27}$$

$\Omega$ ist hierbei das Innere des FEM Netzes ohne den Rand $\partial\Omega$.

Damit ist es nun möglich, das unterbestimmte inverse EIT-Problem zu lösen.

# 3 Grundlagen Neuronale Netze

Für die spätere Verwendung in Rekonstruktionsalgorithmen werden in diesem Abschnitt die relevanten Grundlagen neuronaler Netze erläutert. Ein neuronales Netzwerk ist ein maschinelles Lernmodell, das von der Struktur und Funktionsweise des menschlichen Gehirns inspiriert ist. Es besteht aus einer Reihe von miteinander verbundenen künstlichen Neuronen, die in Schichten (Layer) angeordnet sind und Informationen verarbeiten, um komplexe Aufgaben wie Mustererkennung und Vorhersagen durchzuführen [25, 26].

## 3.1 Aufbau

Ein Neuron (Abbildung 3.1) ist die grundlegende Einheit in einem neuronalen Netzwerk. Es erhält mehrere Eingaben („Features“) $x$, führt eine Berechnung durch und gibt eine Ausgabe („Output“) $o$ aus.

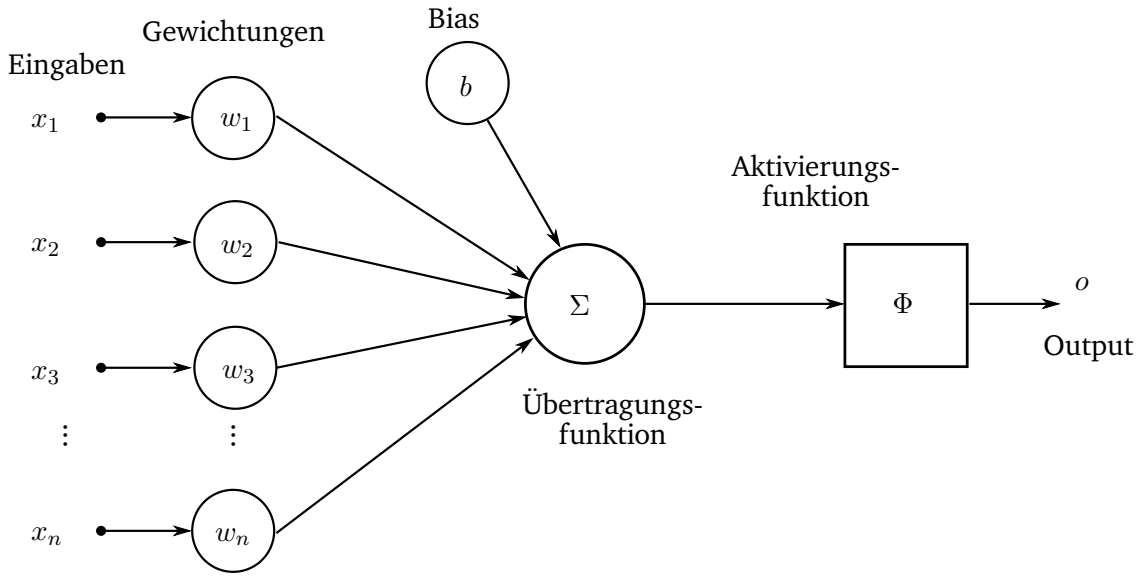



Abbildung 3.1: Aufbau eines einzelnen Neurons. Es verfügt über mehrere Eingänge $x$, welche mit $\omega$ gewichtet werden und einen konstanten Bias $b$. Anschließend werden die Eingänge in einer Übertragungsfunktion, wie beispielsweise einer Linearkombination, zusammengefügt. Das Ergebnis wird daraufhin durch eine Aktivierungsfunktion $\Phi$ skaliert und ergibt den Ausgang des Neurons $o$.

Ein Neuron erhält eine oder mehrere Eingaben $x$. Diese Eingaben können numerische Werte oder Signale von anderen Neuronen in einem vorherigen Layer sein. Jede Eingabe wird mit einem Gewicht („Weight“) $\omega$ multipliziert. Zusätzlich besitzen die Neuronen ebenfalls einen konstanten Bias $b$ der nicht von den Eingängen

abhängt. Die gewichteten Eingänge werden anschließend summiert und dienen als Eingang für eine Aktivierungsfunktion $\phi$. Auch diese ist von dem biologischen Neuron inspiriert. Sie reguliert, wie hoch der Ausgang je nach entsprechendem Eingang ist. Beispiele für Aktivierungsfunktionen sind Sigmoid, Tanh oder die Rectified Linear Unit (ReLU) (Abbildung 3.2).

Der Ausgang ist dann definiert als:

$$o = \phi\left(b + \sum_{i-1}^{n} x_i \cdot \omega_i\right) \tag{3.1}$$

Ein ebenfalls wichtiger Aspekt der Aktivierungsfunktion ist die Einführung von Nichtlinearitäten. In Gleichung (3.1) ist zu sehen, dass der Ausgang ohne $\phi$ ausschließlich einen linearen Zusammenhang von $x$ annehmen kann. Durch $\phi$ werden ebenfalls nichtlineare Zusammenhänge ermöglicht.

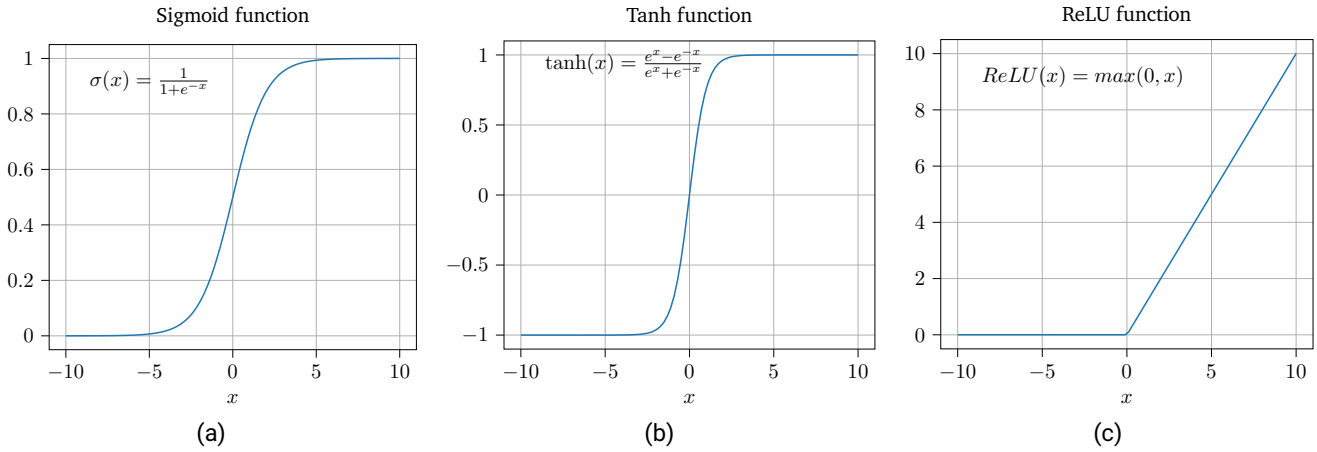



Abbildung 3.2: Durch das Hinzufügen einer Aktivierungsfunktion werden die Ausgänge der Neuronen skaliert und Nichtlinearitäten ermöglicht. Häufig genutzte Aktivierungsfunktionen sind (a) Sigmoid, (b) Tanh und (c) ReLU. Der Unterschied zwischen (a) und (b) kann in der Skalierung erkannt werden.

Nun können mehrere dieser Neuronen zu einem neuronalen Netz zusammengeschaltet werden. Dadurch ergibt sich eine Funktion:

$$y = f(x|(\omega_i)^{[l]}, b^{[l]}) \tag{3.2}$$

Layer, in welchen alle Neuronen als Eingang Signale von einem vorherigen Layer erhalten, werden „Dense Layer“ genannt. Es existieren auch andere Layerarten, welche mit Faltung (Convolution) von Filtern arbeiten oder welche die Dimension des Eingangs verringern oder vergrößern können („Pooling Layer“).
Der mehrschichtige Ansatz ist ebenfalls aus der Natur inspiriert, da auch im Gehirn mehrere Neuronen hintereinander verschaltet sind. Ein Netzwerk mit mehreren Layern wird auch „Deep Neural Network“ genannt. Es besteht aus einem Input Layer einem Output Layer und dazwischen gibt es mehrere versteckte (hidden) Layer (Abbildung 3.3).

Die ersten Layer haben meist die Aufgabe, relevante Features in den Daten zu erlernen und diese zu extrahieren und weiterzugeben. In Computer Vision Anwendungen sind die gelernten Features der ersten Layer meistens

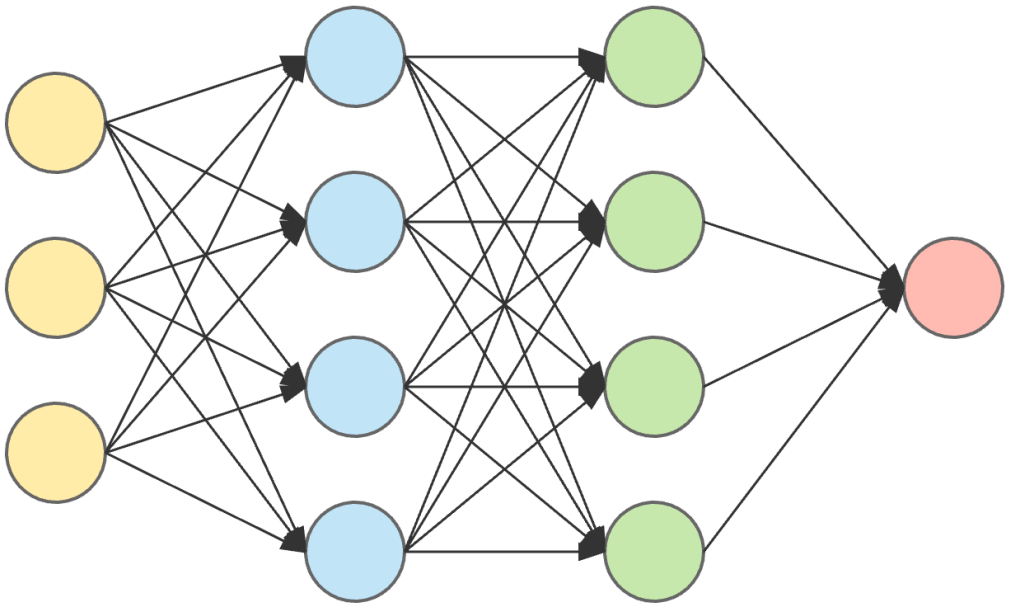



Abbildung 3.3: Ein Deep Neural Network ist ein Netzwerk aus mehreren Neuronen, die in Schichten angeordnet sind. Durch den schichtartigen Aufbau sind sie in der Lage, komplexe Zusammenhänge zu lernen [27].

Kanten im Bild. Auch in anderen Domänen ist es sinnvoll, das Gesamtproblem in mehrere Abstraktionsebenen zu unterteilen [26]. Es ist auch möglich, vorher manuell Features zu definieren und diese als Eingänge zu nutzen.

## 3.2 Trainingsdaten

Die Trainingsdaten für das Netzwerk bestehen aus bekannten Paaren („Samples“) aus Inputs $X$ und Outputs $Y$. Ziel dabei ist es, möglichst viel Variation in den Daten abzubilden, welche auch in der Realität vorkommen können. Dadurch soll das Netzwerk möglichst generell und wenig sensitiv gegenüber Veränderungen in den Daten und Rauschen sein. Am Beispiel der EIT sind die Inputs die gemessenen Spannungen $\vec{V}$ in den EIT-Frames und die Outputs die bekannte Impedanzverteilung $Z(x, y)$.
Zur Evaluierung der Modelle werden die Trainingsdaten in ein Trainings-, Validation- und Testset aufgeteilt. Das Trainingsset wird zum tatsächlichen Training des Modells verwendet und sollte deshalb möglichst groß sein. Das Validationset wird genutzt, um die Performance auf neuen, ungesehen Daten zu bewerten und ein eventuelles Overfitting an die Trainingsdaten zu erkennen.
Die Performance an dem Validationset wird ebenfalls verwendet, um Hyperparameter anzupassen. Dabei handelt es sich um Parameter, welche nicht trainiert, sondern im Voraus manuell festgelegt werden müssen. Beispiele sind die Anzahl der Layer und die genutzte Aktivierungsfunktion.
Durch diese Hyperparameteranpassung ergibt sich jedoch wiederum ein Bias, da die Hyperparameter nun an das Validationset über-angepasst sein könnte. Deshalb wird noch ein Testset zurückgehalten, um abschließend nach dem Hyperparameter Tuning die finale Performance des Modells ohne Bias zu bewerten.




Abbildung 3.4: Die Datenmenge wird zu Beginn aufgeteilt in Train, Validation und Test. Das Trainingsset wird zum Trainieren der Modelle genutzt. Das Validationset wird genutzt um die Hyperparameter zu optimieren. Dadurch sind diese jedoch speziell für das Validationset optimiert. Deswegen gibt es das Testset welches weder direkt noch indirekt Einfluss auf das Modell hatte.

Generell gilt, je mehr Daten vorhanden sind, desto besser ist in der Regel auch der Trainingserfolg. Eine grobe Regel ist, dass etwa $10$ Mal mehr Samples als Parameter vorhanden sein sollten [28].

## 3.3 Training

Damit das Neuronale Netzwerk in der Lage ist, eigenständig Muster in Eingangsdaten zu erkennen, müssen die Weights $w$ und Biases $b$ optimiert werden. Dieser Prozess des Optimierens der Weights und Biases wird Training genannt.
Es wird unterschieden zwischen unüberwachtem („unsupervised“) und überwachtem („supervised“) Training, beim unsupervised gibt es Daten $X$ ohne zugehörige Beschriftung („Label“), in denen meistens Zusammenhänge wie Häufungen erkannt werden sollen. Beim supervised Training sind die Eingangsdaten $X$ beschriftet mit gewünschten Outputs $Y$. Dabei ist das Ziel meistens eine Regression oder Klassifikation [29].
In der EIT Rekonstruktion handelt es sich um ein Regressionsproblem, weshalb supervised learning angewendet werden kann. Für das Training wird nun eine Menge an Daten aus gewünschten Inputs $X$ und dazugehörigen Outputs $Y$ benötigt. Das Netzwerk soll nun eine möglichst gute Abbildung $X \rightarrow Y$ finden. Um die Performance der Abbildung messen zu können, muss eine Fehlerfunktion oder Loss Function definiert werden.

### 3.3.1 Loss Function

Da es sich beim Training der Parameter um ein Optimierungsproblem handelt, wird eine Funktion zum Optimieren benötigt. Die Loss Funktion $\epsilon$ misst, wie groß der Unterschied zwischen dem Output $\widetilde{y}$ und dem realen Wert in den Trainingsdaten $y$ ist. Es ist wichtig, eine passende Loss Funktion zu definieren, da diese bestimmt, was eine gute Rekonstruktion ist. Eine unpassend gewählter Loss Funktion kann zu schlechteren Parametern oder zu gar keiner Konvergenz des Optimierungsproblems führen. Es gibt je nach Art der Daten und Aufgabe des Netzwerks unterschiedliche Loss Funktionen [30]. Für Regression gibt es beispielsweise den Mean Absolute Error (MAE):

$$\epsilon = \frac{1}{N} \sum_{i=1}^{N} |y_i - \tilde{y_i}|. \tag{3.3}$$

Dieser wird auch L1 Loss genannt und nutzt den Betrag der Abweichung. $N$ ist die Anzahl der Trainingsdaten. Zudem gibt es den Mean Squared Error (MSE):

$$\epsilon = \frac{1}{N}\sum_{i=1}^{N}(y_i - \tilde{y_i})^2. \tag{3.4}$$

Dieser wird auch L2 Loss genannt und nutzt die quadratische Abweichung. Dadurch ist dieser deutlich sensitiver gegenüber Ausreißern.

Für Klassifikationsalgorithmen gibt es beispielsweise die Cross Entropy $H$ als Loss Funktion [30]:

$$H(y,p) = \sum_{k}^{K} y_k^i \cdot \log(p_k^i). \tag{3.5}$$

Hierbei ist $p_k^i$ die geschätzte Wahrscheinlichkeit für Klasse $k$ und $y_k^i$ die reale Klasse. $K$ ist die Anzahl aller Klassen.

### 3.3.2 Gradient Decent

Das Ziel ist die Optimierung der Loss Funktion $\epsilon(\omega)$. Je mehr Parameter optimiert werden sollen, desto höher die Dimensionalität der Loss Funktion. In Abbildung 3.5 ist eine beispielhafte Loss Funktion mit 2 Parametern dargestellt. Es wird meist mit zufällig initialisierten Parametern gestartet.

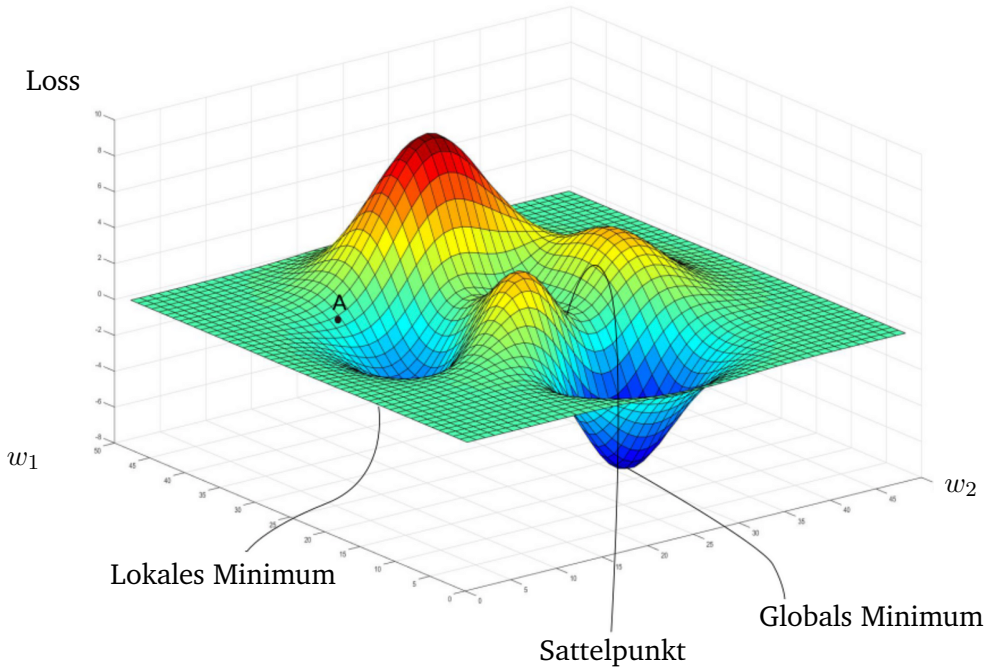



Abbildung 3.5: Der Gradient Decent Algorithmus versucht das Minimum der Loss Funktion zu finden. Dafür wird an einem beliebigen Punkt (A) gestartet und anschließend iterativ die Richtung des stärksten Abstiegs gesucht. Ziel ist es, das globale Minimum der Loss Funktion zu finden. Bei der Anwendung besteht die Gefahr, in lokale Minima zu geraten, aus welchen der Algorithmus möglicherweise nicht mehr entkommen kann [31].

Es gilt nun zu ermitteln, in welche Richtung die Parameter verschoben werden müssen, um einen verringerten durchschnittlichen Fehler zu erzielen. Dafür wird der Gradient Decent Algorithmus genutzt:

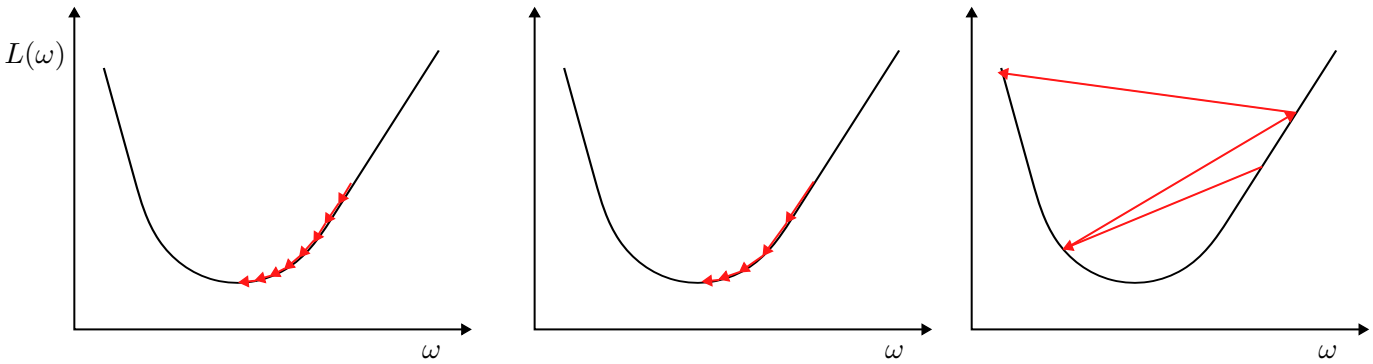
Zuerst werden die Parameter zufällig initialisiert:

$$\omega_{new} = \omega_0 \tag{3.6}$$

Anschließend werden die folgenden Schritte $n$ mal wiederholt:

1. $\omega_{current} = \omega_{new}$;
2. Bestimmen des Gradienten: $\vec{g} = \nabla\epsilon(\omega)$;
3. Verschieben in Richtung des Gradienten um Schrittweite $t$: $\omega_{new} = \omega_{current} - \alpha \cdot t \cdot \vec{g}$;
4. Anhalten, falls die Verbesserung des Fehlers zu klein ist: $|\epsilon_{new} - \epsilon_{current}| < \epsilon_{stop}$.

In Punkt 1 werden die Weights auf den neuen Wert gesetzt. In Punkt 2 wird der Gradient $\vec{g}$ der Loss Funktion bestimmt. Dieser gibt die Richtung der maximalen Steigung der Funktion an. Das Berechnen des Gradienten erfolgt mit einem Algorithmus namens Backpropagation (Abschnitt 3.3.3).
Anschließend wird $w_{current}$ proportional zur Schrittweite $t$ in Richtung des negativen Gradienten verschoben (Punkt 3). Diese Schrittweite $t$ kann durch die Learning Rate (LR) $\alpha$ beim Training des Netzwerks angepasst werden.
Die Wahl der richtigen LR ist ebenfalls relevant für den Erfolg des Trainings. Sie sorgt für die Balance zwischen Dauer und Qualität des Trainings [32]. Bei einer zu kleinen Schrittweite dauert das Training zu lange und bei einer zu großen könnte es passieren, dass das Optimum übersprungen wird (Abbildung 3.6). Durch die Multiplikation mit dem Gradienten ist die Schrittweite ebenfalls proportional zur Steigung. Je größer der Gradient, desto größer auch die Schrittweite. Dadurch wird sie automatisch skaliert, wodurch das Risiko des Herauslaufens aus dem Minimum reduziert wird [30]. Der Algorithmus wird abgebrochen, sobald die Verbesserung im Loss kleiner als $\epsilon_{stop}$ wird (Punkt 4).




Eine zu kleine Learning-Rate benötigt viele Schritte, bevor das Minimum erreicht wird.

Die optimale Learning-Rate konvergiert schnell zum Minimum ohne Überschwingen.

Eine zu hohe Learning-Rate kann zu einem divergenten Verhalten führen.

Abbildung 3.6: Für ein erfolgreiches Training muss die LR richtig gewählt werden. Andernfalls kann das Modell entweder zu langsam konvergieren oder divergieren und somit keine Lösung für das Problem finden.

Eine zu geringe LR kann potenziell zu einer verschlechterten Modellleistung führen, da der Gradient-Descent-Algorithmus anfälliger dafür ist, in lokalen Minima zu konvergieren [32].

### 3.3.3 Backpropagation

Der Backpropagation Algorithmus berechnet den in Abschnitt 3.3.2 benötigten Gradienten, durch rekursives Ableiten mittels der Kettenregel.

Der Backpropagation-Algorithmus funktioniert folgendermaßen:

1. Ein Input $x_i$ wird angelegt und vorwärts durch das Netz $f(x)$ propagiert;
2. Der Output des Netzwerks wird bestimmt $\tilde{y} = f(x_i)$;
3. Der Fehler wird mittels der Loss Funktion bestimmt $L = \epsilon(y, \tilde{y})$;
4. Der Fehler wird vom Output Layer bis zum Input Layer zurück propagiert.

Durch das Zurückpropagieren kann der Einfluss der einzelnen Weights auf den Ausgang und somit auf den Loss rekursiv bestimmt werden (Abbildung 3.9).

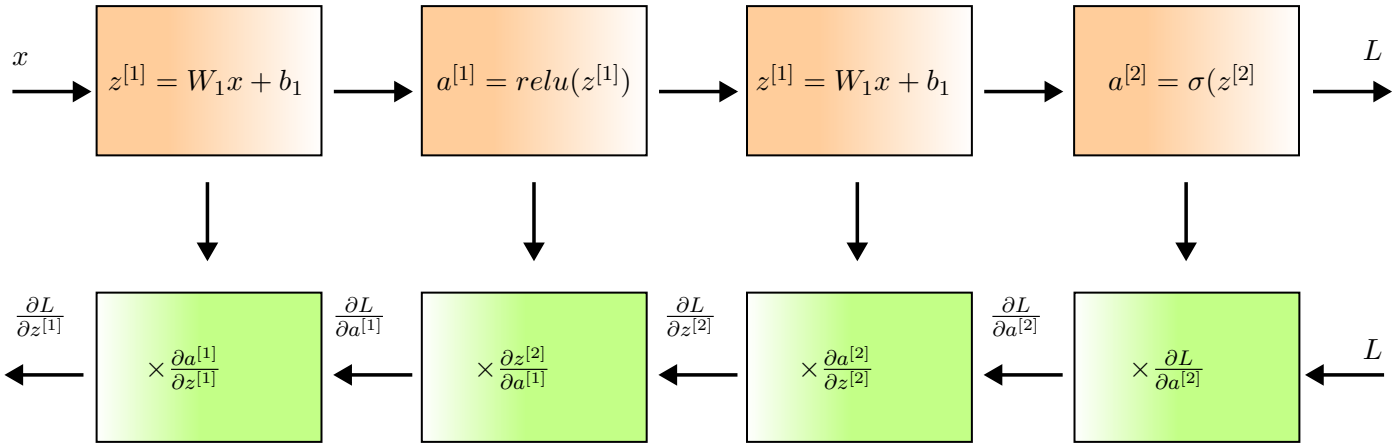



Abbildung 3.7: Der Backpropagation Algorithmus berechnet den Gradienten für die Optimierung des Losses mittels Gradient Decent. Dafür wird die Kettenregel angewendet, um die Auswirkungen von Änderungen in den vorderen Layern zu bestimmen.

Somit kann mittels der Kettenregel der Einfluss der Parameter am Eingang des Netzes ($z^{[1]}$) auf den Loss $L$ bestimmt werden:

$$\frac{\partial L}{\partial z^{[1]}} = \frac{\partial L}{\partial a^{[2]}} \cdot \frac{\partial a^{[2]}}{\partial z^{[2]}} \cdot \frac{\partial z^{[2]}}{\partial a^{[1]}} \cdot \frac{\partial a^{[1]}}{\partial z^{[1]}} \tag{3.7}$$

Dadurch ergibt sich die Sensitivität von $L$ gegenüber einer kleinen Änderung in $z^{[1]}$ und somit die Richtung in die einzelne Weights angepasst werden müssen, um den Fehler zu minimieren.
Je mehr Layer ein Netzwerk hat, desto kleiner wird jedoch dieser Gradient, was es schwieriger macht, diese zu trainieren („Vanishing Gradient Problem“) [33]. Dies ist hauptsächlich ein Problem bei Aktivierungsfunktionen wie Sigmoid, wobei die Ableitung, die bei der Backpropagation genutzt wird, immer kleiner wird. Eine Lösung dieses Problems ist das Verwenden der ReLU Aktivierungsfunktion, welche keine so geringen Ableitungen erzeugt [33].

## 3.4 Regularisierung

Ein häufiges Problem besteht darin, dass Modelle gut an den Trainingsdaten funktionieren, aber sich schlecht auf neue Daten generalisieren lassen. Dies wird als Overfitting bezeichnet. Im ungünstigsten Fall hat das Modell die Trainingsdaten „auswendig gelernt“ und hat somit keinen generellen Zusammenhang aus den Daten extrahiert [23]. Um dem entgegenzuwirken, gibt es das Konzept der Regularisierung.

Das Ziel der Regularisierung ist es, einfachere und somit generellere Lösungen zu finden. Dies wird durch Beschränkungen oder Strafterme erreicht. Dabei muss darauf geachtet werden, nicht zu viel zu regularisieren, da das Modell sonst nicht mehr in der Lage ist, sich an die Daten anzupassen (Abbildung 3.8). Dies wird als Unteranpassung („Underfitting“) bezeichnet. Underfitting kann aber auch an einer zu geringen Modellkomplexität oder zu wenig Input Features liegen.

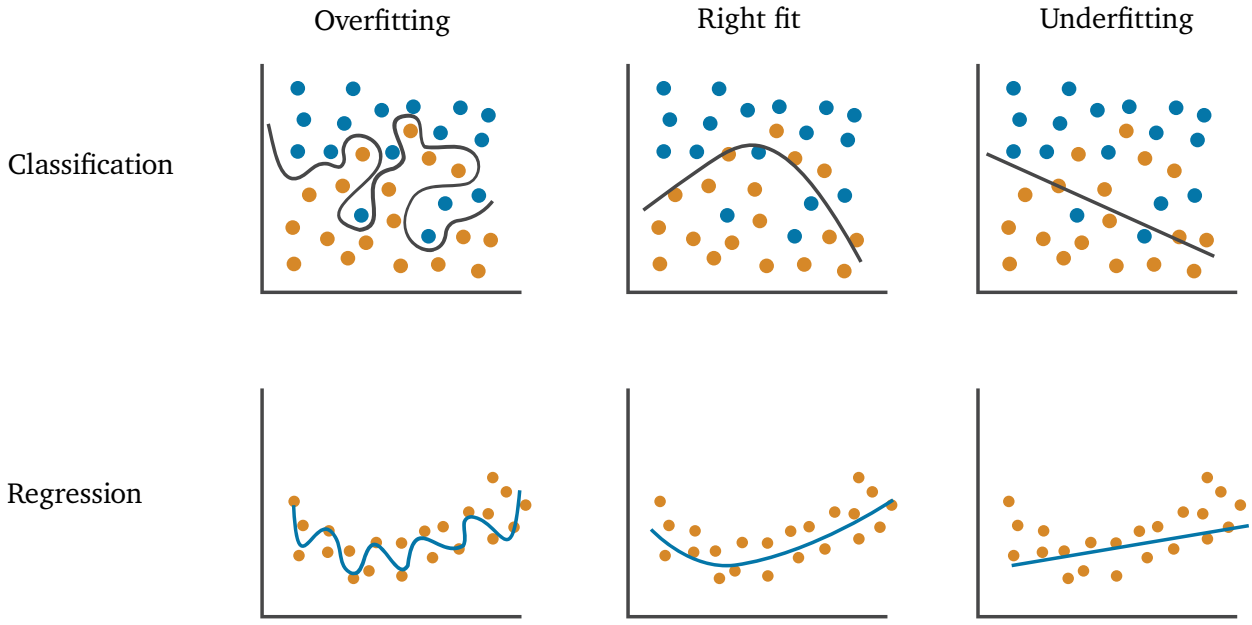



Abbildung 3.8: Beim Regularisieren muss immer die Balance zwischen Over- und Undefitting gefunden werden. Mit zu wenig Regularisierung wird das Modell nicht allgemein genug um auf neue Daten anwendbar zu sein. Mit zu viel Regularisierung hat das Modell zu wenig Freiraum, sich richtig an die Daten anpassen zu können [34].

Es wird zwischen einer expliziten oder impliziten Regularisierung unterschieden [23]. Bei der expliziten Regularisierung wird, dem Optimierungsproblem explizit einen Term hinzufügt (Abschnitt 2.4). Der Regularisierungsterm erlegt der Optimierungsfunktion einen Preis auf, um die optimale Lösung eindeutig und einfacher zu machen. Ein Beispiel für explizite Regularisierung ist Weight Decay (Abschnitt 3.4.1).
Implizite Regularisierung ist jede andere Form der Regularisierung. Dazu gehören z.B. Data Augmentation (Abschnitt 3.4.4) vor dem Training und Early Stopping während des Trainings (Abschnitt 3.4.2). Es ist ebenfalls möglich, regularisierende Faktoren bereits in das Netzwerk, durch spezielle Layer, einzubauen wie den Dropout Layer (Abschnitt 3.4.3).

### 3.4.1 Weight Decay

Weight Decay (WD) ist eine explizite Regularisierung. Das Ziel ist es, die Komplexität des neuronalen Netzes gering zu halten, indem die Weights zur Loss Funktion addiert werden. Dadurch wird bei der Optimierung nicht nur versucht die besten Parameter zu finden, sondern die besten Parameter unter der Bedingung von möglichst geringen Weights [35].

$$Loss = f(y, \tilde{y}) + wd \cdot \text{sum}(w^2) \tag{3.8}$$

Dabei ist $f$ die gewählte Loss funktion und $wd$ der Weight Decay Parameter, welcher regelt, wie stark die Größe der Parameter in den Loss eingebracht werden soll. Der optimale Wert für $wd$ muss wie die meisten Hyperparameter experimentell bestimmt werden. Er darf nicht zu hoch gewählt werden, da das Modell sonst schlechter trainiert werden kann, da es zu wenig Freiraum hat, sich an die Daten anzupassen [35].

### 3.4.2 Early Stopping

Die Daten werden, wie in Abschnitt 3.2 beschrieben, vor dem Training in ein Trainings- und ein Validierungsset aufgeteilt. Das Validierungsset dient dazu, die Leistung des Modells auf bisher ungesehene Daten zu bewerten. Während des Trainingsprozesses wird beobachtet, ob die Leistung auf dem Validierungsset sich nicht mehr verbessert oder sogar verschlechtert. Dies signalisiert, dass das Modell zu stark an die Trainingsdaten angepasst ist und nicht mehr gut auf unbekannte Daten generalisiert. An diesem Punkt wird das Training gestoppt [36].

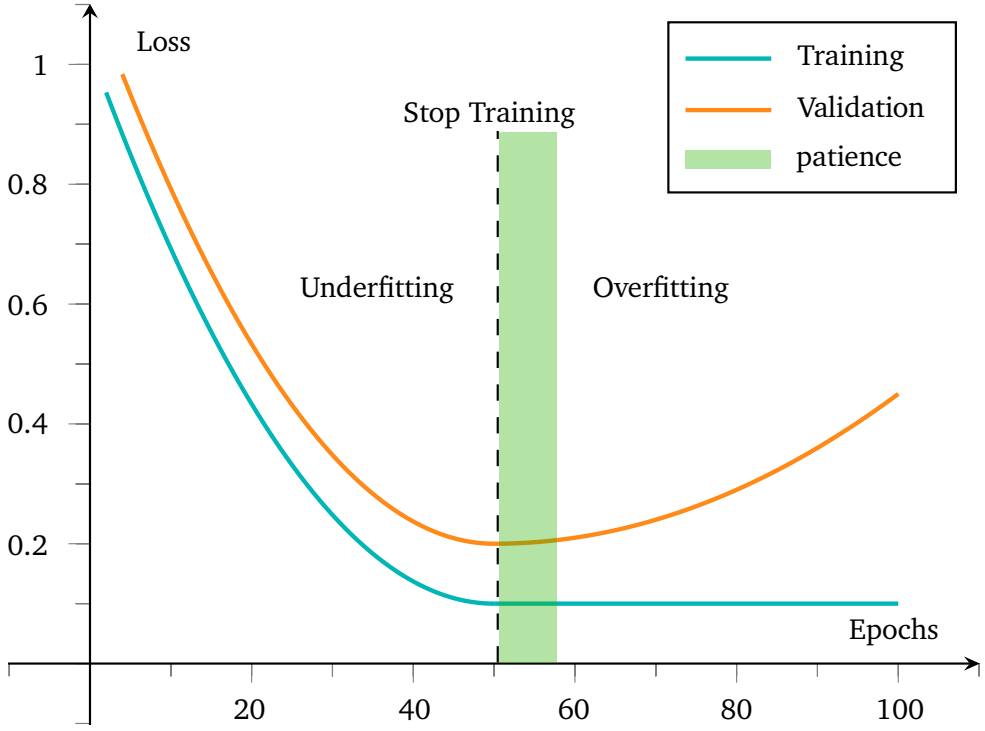



Abbildung 3.9: Sobald die Performance am Validationset stagniert oder sogar steigt, sollte der Trainingsprozess beendet werden, da das Modell anschließend anfängt auf das Trainingsset zu overfitten. Wird das Training vorher beendet, ist das Modell noch zu wenig angepasst.

Da während des Trainingsprozesses kleine Schwankungen im Loss auftreten können, in denen das Modell für ein paar Epochen keine Verbesserung oder sogar eine Verschlechterung aufweist, wird ein Geduldsparameter („patience“) eingeführt. Dieser gibt an, wie viele Epochen abgewartet werden, ohne eine Verbesserung zu sehen, bevor das Training abgebrochen wird [36].

### 3.4.3 Dropout Layer

In einem Dropout Layer werden während jeder Epoche mit einer gewissen Wahrscheinlichkeit Neuronen deaktiviert (Abbildung 3.10). Die Wahrscheinlichkeit eines einzelnen Neurons kann mittels der Dropout Rate $p$ gesetzt werden. Wichtig ist, dass die Auswahl der zu deaktivierenden Neuronen in jeder Trainingsepoche zufällig ist. Dies zwingt das Modell, sich an verschiedene Teilmengen der Daten anzupassen und verhindert das auswendig Lernen. Zudem wird eine Abhängigkeit von speziellen Neuronen verhindert. Das Modell lernt, nicht zu sehr auf bestimmte Neuronen oder Gewichtungen zu vertrauen, was die Robustheit gegenüber Änderungen in den Gewichten erhöht [37].

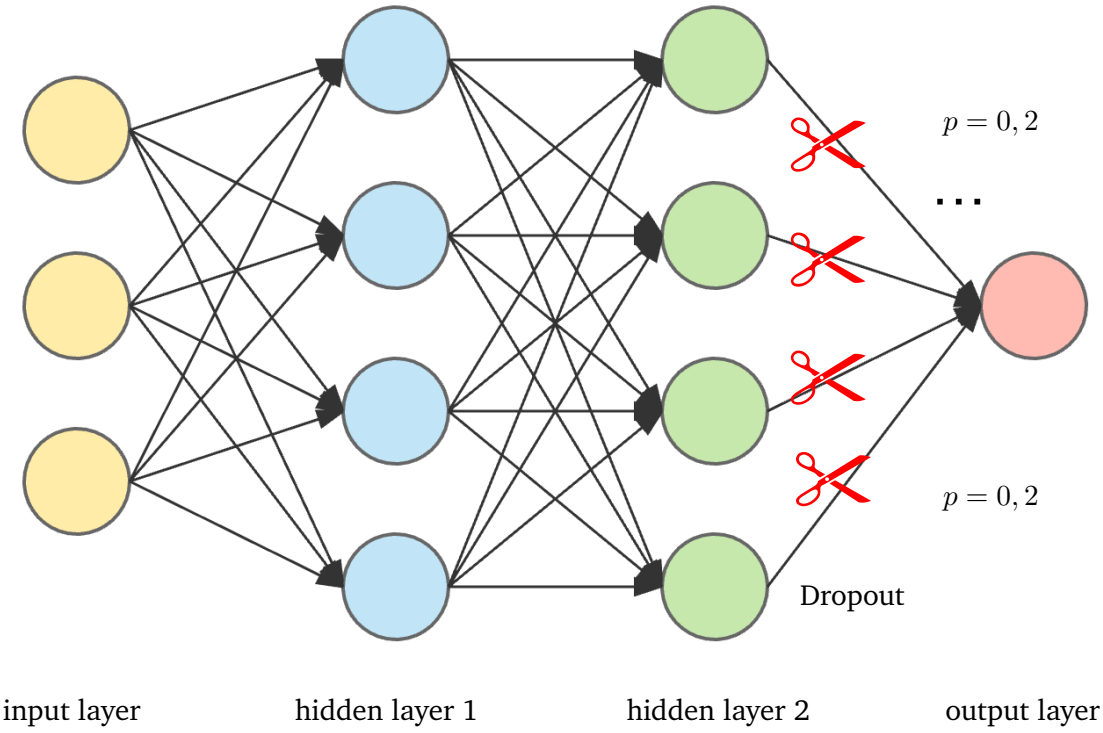



Abbildung 3.10: Durch das Hinzufügen von Dropout Layer in das Modell besteht eine Wahrscheinlichkeit $p$, für jedes Neuron, dass es deaktiviert wird. Dadurch werden zu starke Abhängigkeiten des Ergebnisses von einzelnen Neuronen verhindert und die Generalisierungsfähigkeit des Modells erhöht [38].

### 3.4.4 Data Augmentation

Bei der Data Augmentation werden aus den vorhandenen Trainingsdaten künstliche neue Daten erzeugt, um die Variation zu vergrößern. Dadurch ergibt sich ebenfalls ein regularisierender Einfluss. Je nach Datentyp sind unterschiedliche Augmentationen möglich. Es muss aber darauf geachtet werden, die zugrundeliegende Information der Daten nicht zu stark zu verändern. Gerade in der Bildklassifizierung gibt es viele Möglichkeiten, die Daten anzupassen (Abbildung 3.11) [39].
In der Objekterkennung kann beispielsweise ein Bild gespiegelt werden, ohne die zugrundeliegende Information zu verändern. Andere Möglichkeiten sind: Rotation, Translation, Crop, Padding, Blur, Kontrastveränderung, Gaussian Noise und viele weitere [39].

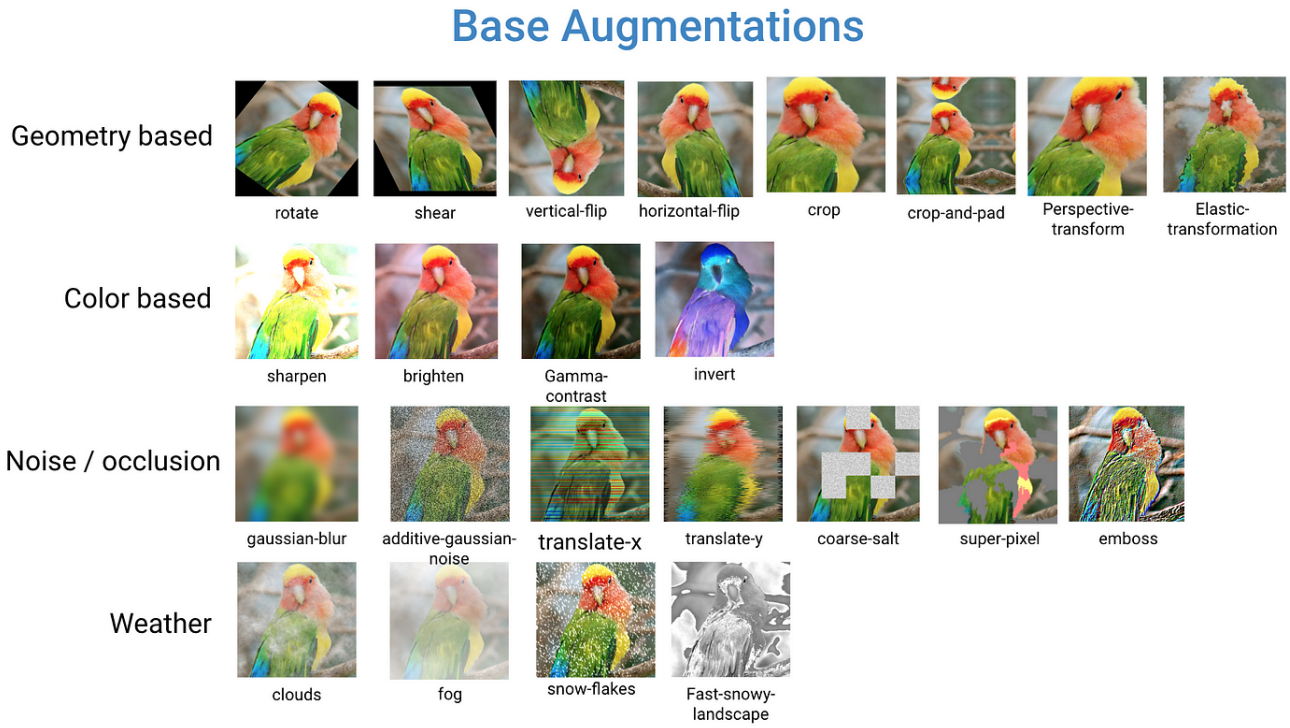



Abbildung 3.11: Mögliche Augmentationen in der Bild Domäne. Durch die Augmentation können zusätzliche Daten erzeugt werden, die Modelle robuster gegenüber Änderungen machen [39].

Nun können beliebig viele augmentierte Kopien zum Datensatz hinzugefügt und somit die Datenmenge stark vergrößert werden. Dadurch lernt das Modell mehr Variation und kann seine Performance steigern [39].

# 4 Stand der Technik Image Reconstruction

Allgemein lässt sich in der Datenauswertung zwischen modellbasierten und datenbasierten Ansätzen unterscheiden. In modellbasierten Ansätzen wird ein digitales Modell, der zu vermessenden Region des Körpers benötigt, mit dem die erwartete Verteilung der Spannung an den Elektroden bestimmt werden kann [3]. Nachteile von modellbasierten Ansätzen sind, dass die maximale Komplexität durch das Modell eingeschränkt und das Erstellen des Modells in der Regel sehr aufwendig ist. Dafür benötigen sie keine großen Datenmengen und ihre Ergebnisse sind nachvollziehbar.
Bei den datenbasierten Ansätzen wird auf ein Modell verzichtet und versucht, den Zusammenhang zwischen gemessenen Spannungen an den Elektroden und Impedanzverteilung im Körper direkt zu lernen [40]. Dafür ergeben sich aber wiederum andere Probleme. Beispielsweise werden mit zunehmender Komplexität exponentiell mehr Daten benötigt (Curse of Dimensionality) [41]. Zudem sind solche Ansätze oft schlechter nachvollziehbar und erklärbar, was eigentlich gewünscht wäre (Explainable AI) [42].

## 4.1 Modellbasierte Ansätze

Zunächst werden bei beiden Ansätzen die Spannungen an den Elektroden gemessen (Abbildung 4.1). Anschließend wird beispielsweise mittels einer FEM ein Modell des Körpers erstellt, welches die zu erwartende Spannungsverteilung für eingebrachte Ströme bestimmen kann. Dies entspricht dem Bestimmen von $V_0$ aus Gleichung (2.11) und wird Vorwärtsproblem genannt.

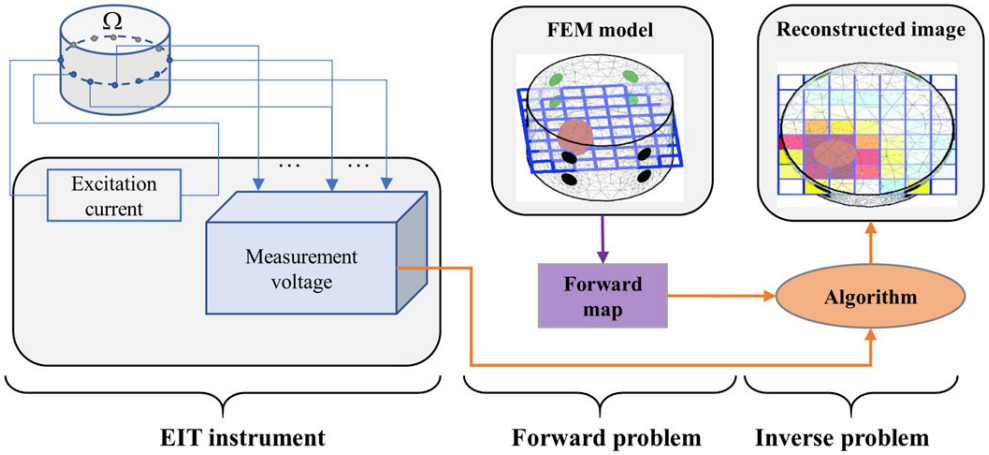



Abbildung 4.1: Typisches Schema der Bildrekonstruktion. Links: EIT-Messdaten vom Körper. Mitte: EIT-Vorwärtsproblem mit einem Finite-Elemente-Modell des Körpers. Rechts: Inverses EIT-Problem, bei dem die Vorhersage des FEM Modells und iterative Rekonstruktionsalgorithmen verwendet werden, um die Impedanzverteilung aus den gemessenen Spannungen und dem Vorwärts-Modell zu rekonstruieren [43]

Wenn sich nun, die der Spannungsvektor $\vec{V}$ zeitlich ändert, kann daraus die Änderung der Impedanzverteilung $Z$ bestimmt werden (vergl. Abschnitt 2.3).

Die ersten Modelle nutzten jedoch ausschließlich das Vorwärts-Problem. Die Grundlagen der Technik wurden im Jahr 1978 von Ross P. Henderson und John G. Webster in ihrer Arbeit zur „Impedanz Kamera“ gelegt [44]. In [45] wurde dann der Sheffield Algorithmus zum Sammeln und Auswerten der Daten vorgestellt, welcher durch Randwert Filterung die Ergebnisse verbesserte. Dieser Sheffield Algorithmus hat jedoch einige Beschränkungen, wie z. B. eine geometrische Einschränkung für rund geformte Objekte sowie keine Flexibilität in Bezug auf die Reihenfolge der Strominjektionen und Spannungsmessungen. Weitere lineare Algorithmen sind der back-projection Algorithmus [46] und der sensitivity matrix Algorithmus [47].
Das erste Modell, dass auch das Inverse Problem zur iterativen Verbesserung nutzt, ist der Newton-Raphson-Algorithmus. Er versucht, jedem finiten Element eine Änderung der Impedanz zuzuordnen, um eine bessere Übereinstimmung der numerischen Lösung dieses inversen Problems von der FEM mit dem tatsächlich gemessenen Spannungsprofil zu erreichen [3]. Anschließend wurden noch einige Variationen des Newton-Raphson-Algorithmus veröffentlicht. Dabei wurden unterschiedliche Arten der Regularisierung verwendet (vergl. Abschnitt 2.4). Es hat sich gezeigt, dass iterative Näherungsmethoden, wie die Newton-Raphson-Algorithmen, bessere Ergebnisse liefern [3, 48]. Der Nachteil dieser Methode ist jedoch die hohe Rechendauer im Vergleich zu den nicht iterativen Methoden [20].

## 4.2 Datenbasierte Ansätze

Bei den datenbasierten Ansätzen wird kein FEM Modell des Körpers benötigt. Der zugrundeliegende Zusammenhang zwischen Input und Output wird durch die Algorithmen („Modelle“) selbst erlernt. Dafür wird ein ausreichend großer Datensatz (vergl. Abschnitt 3.2) benötigt. Ebenfalls hängt dadurch die Performance und Generalisierungsfähigkeit des Algorithmus stark von der Qualität des Datensatzes ab [49].
Einer der bekanntesten datenbasierten Ansätze ist der Graz consensus Reconstruction algorithm for EIT (GREIT) Algorithmus [16]. Dieser basiert auf auf dem Erlernen einer linearen Rekonstruktionsvorschrift aus Trainingsdaten. GREIT wurde speziell als Framework für allgemeine Lungen EIT entwickelt und erreichte eine bessere Qualität der Bildrekonstruktion als seine Vorgänger. Zusätzlich wurden in [16] ebenfalls Metriken eingeführt, mit denen die Performance von EIT-Rekonstruktionsalgorithmen verglichen werden können.
Ein weiterer Weg, um Zusammenhänge aus Daten zu extrahieren, sind neuronale Netze. Einer ihrer großen Vorteile ist, dass sie beliebige lineare und nichtlineare Zusammenhänge erlernen können [25].
Dabei werden hauptsächlich drei Ansätze genutzt, die hier näher erläutert werden [50]:

- Direkte Rekonstruktion aus den Spannungsdaten mit einem einzigen neuronalen Netz;
- Verbindung aus traditionellen Algorithmen und Netzwerken;
- Hybride Rekonstruktion mittels mehrerer neuronaler Netze.

### 4.2.1 Direkte Rekonstruktion mit einem einzigen neuronalen Netz

Es existieren mehrere Ansätze, welche die Rekonstruktion mit einem einzigen neuronalen Netz erreichen [50]. Zum einen gib es Rekostruktionsalorithmen mit Artificial Neural Network (ANN) [51, 52, 53]. Dafür wurde mittels FEM ein Datensatz simuliert [54], wobei Modelle mit wenigen Layern nicht gut für die Nichtlinearitäten

des EIT-Problems geeignet sind. Später wurden die Modelle um mehr Layer zu einem Deep Neural Network (DNN) erweitert, wodurch die Rekonstruktionsfähigkeit für Nichtlinearitäten gesteigert werden kann [50].

Ein Problem von ANNs liegt an der stark zunehmenden Anzahl an zu trainierenden Parametern, je größer der Input Vektor und je mehr Layer verwendet werden. Dies liegt daran, dass sie ausschließlich „Dense Layer“ verwenden. Eine Lösung für dieses Problem stellen Convolutional Neural Network (CNN) dar. Sie verwenden die Operation der Faltung („Convolution“) mit Filtermatrizen und benötigen dadurch deutlich weniger Parameter als „Dense Layer“. Zudem eigen sich die Convolution Layer ebenfalls, um relevante Feature zu extrahieren, sodass nicht manuell in den Signalen nach ausschlaggebenden Features gesucht werden muss. Damit CNNs gut funktionieren, muss ein räumlicher Zusammenhang in den Daten vorhanden sein, wie es bei benachbarten Pixeln von Bildern meistens der Fall ist. Dabei ist es möglich, die 1D Spannungsdaten zuerst in 2D Bilddaten für 2D Convolution Layer umzuwandeln. Dabei kann jedoch die originale Struktur der Daten verloren gehen oder inkorrekte Zusammenhänge aus den 2D Daten geschlossen werden [50]. Auch die Rekonstruktion mittels CNN wurde bereits erfolgreich durchgeführt [55]. Ein Beispiel hierfür ist in Abbildung 4.2 zu sehen. Hierbei werden mehrere Convolution Layer zur Feature-Extraktion verwendet und die Dimensionalität durch „Max-Pool Layer“ verringert.

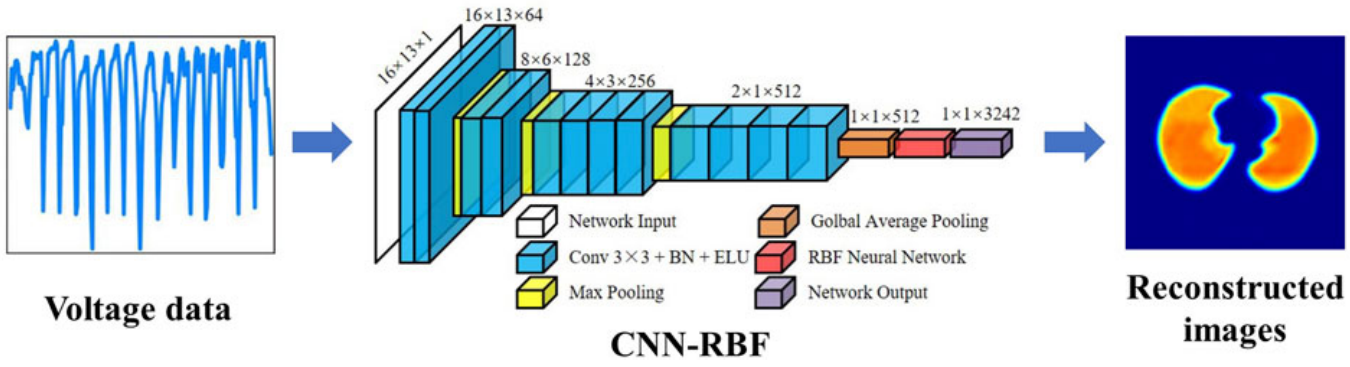



Abbildung 4.2: Beispielhafte Rekonstruktion mittels eines CNN. Als Input dienen die Spannungsdaten der Elektroden und der Output ist das rekonstruierte Bild. Als Ground Truth Daten wurden in diesem Fall CT Daten verwendet [55]

Ein Aspekt hierbei ist, dass für das Training dieser Modelle Ground Truth (G.T.) Bilddaten benötigt werden. In [55] wurden dafür CT Bilder verwendet. In vielen Fällen werden auch simulierte Daten verwendet [50, 56].

### 4.2.2 Verbindung aus traditionellen Algorithmen und Netzwerken

Teilweise haben ANNs Probleme, in realen Szenarios ausreichend gut zu generalisieren. Deshalb wurde ein Ansatz entwickelt, der die Rekonstruktion mit einem „one step Gauss-Newton“ wie dem NOSER Verfahren zu initialisieren und anschließend mit einem neuronalen Netzwerk zu verbessern [50].
In [57] wird beispielsweise eine U-Net [58] Struktur verwendet, um die geringe räumliche Auflösung der EIT zu verbessern (Abbildung 4.3). Zuerst wird eine Impedanzverteilung in geringer Auflösung mit dem sogenannten D-Bar Algorithmus erzeugt, welche anschließend durch ein U-Net in der Auflösung erhöht und um Artefakte reduziert wird.

In [59] wurde das „VDD-Net“ vorgestellt, das ebenfalls eine sequenzielle Abfolge verschiedener Netzwerke nutzt. Zuerst einen „Preimaging“ Block für die initiale Rekonstruktion, dann ein „Feature Extraction“ Block ein „Image Reconstruction“ Block und abschließend ein „Image Denoising“ Block (Abbildung 4.4).

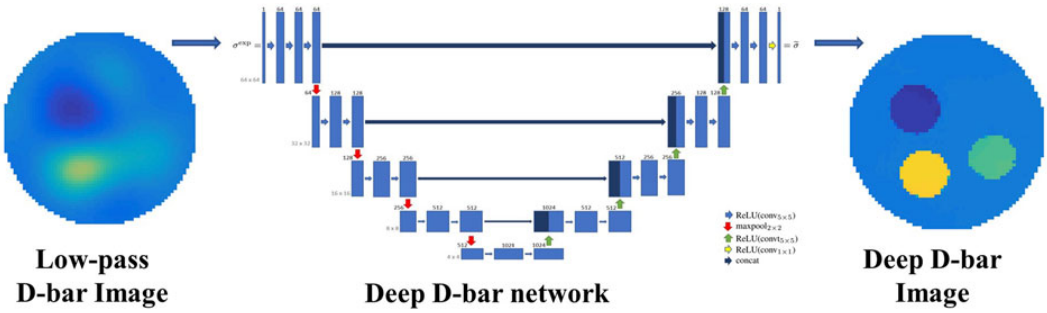



Abbildung 4.3: Aufbau einer U-Net Architektur [58] zur Verbesserung der geringen räumlichen Auflösung der EIT. Sie basiert auf einer Encoder-Decoder Architekturen. Die erste Encoder Hälfte dient zur Feature-Extraktion, um relevante Feature zu erkennen und die zweite Hälfte nutzt die Abstrakte Feature Repräsentation, um diese wieder in ein Bild umzuwandeln [57].

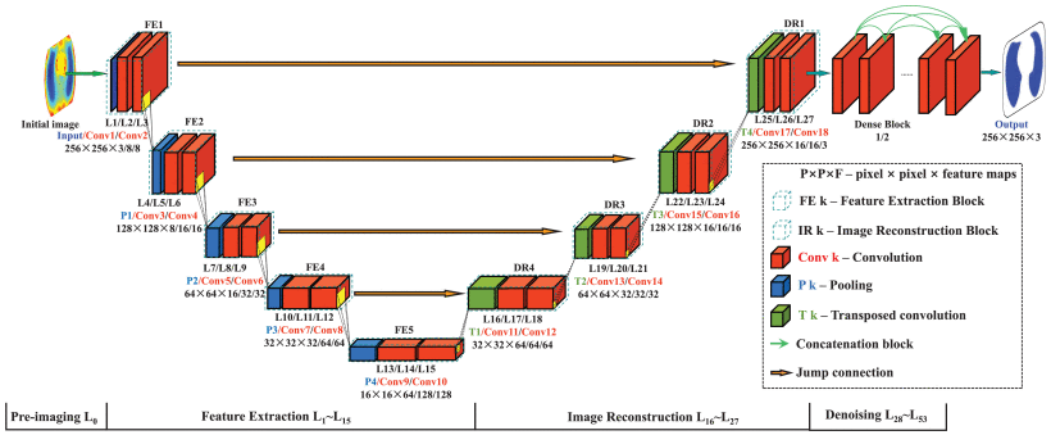



Abbildung 4.4: Das VDD-Net besteht aus mehreren Blöcken, die unterschiedliche Aufgaben in der Rekonstruktion übernehmen. Als Eingang wird eine Rekonstruktion eines Modellbasierten Algorithmus genutzt und anschließend in mehreren Schritten eine scharfe Organgrenze rekonstruiert. Als Datengrundlage wurden Lungen CT-Scans und Augmentierungen dieser genutzt [59].

### 4.2.3 Hybrides Deep Learning

Beim Hybriden Deep Learning werden mehrere getrennte Netzwerke verwendet, um die Rekonstruktionsqualität zu steigerten. In [60] wurde eine Methode vorgeschlagen, die ein ANN und ein U-Net für die EIT-Bildrekonstruktion kombiniert. Die Methode verwendet zunächst den MSE zwischen den realen Bildern und Output, um ein ANN für die Rekonstruktion eines initialen EIT-Bildes zu trainieren. Danach wird ein U-Net für die Verbesserung der Qualität genutzt. Als Trainingsdaten wurden ebenfalls Tank Experimente mittels EIDORS simuliert. In [61] wurde der Ansatz verfolgt, die Rekonstruktion mit einer Verbindung aus CNN und Recurrent Neural Networks (RNN) zu verbessern. Ein RNN ist in der Lage, die temporale Information einer Bildfolge zu nutzen und durch dieses Wissen die Rekonstruktionsqualität zu verbessern.

Der Großteil der aktuellen Forschung beschränkt sich aktuell auf Simulationen. In der praktischen Anwendung könnte sich die Herausforderung ergeben, dass diese Algorithmen, aufgrund schlechter Generalisierbarkeit, eine geringere Leistung aufweisen [50]. Daraus ergibt sich der Bedarf für die Evaluierung eines Rekonstruktionsalgorithmus, welcher auf realen Messdaten trainiert wurde.

# 5 Algorithmus Performance Kriterien

Um Algorithmen auf ihre Qualität hin zu bewerten, gibt es einige Kriterien die genutzt werden können. Diese Kriterien sollen einen idealen Rekonstruktionsalgorithmus beschreiben. Eine Möglichkeit ist die Betrachtung der Pearson Korrelation $r$ zwischen dem idealen Bild $y$ und der Rekonstruktion $x$:

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}} \,. \tag{5.1}$$

Mit $r$ wird die Stärke des linearen Zusammenhangs gemessen.

In [16] wurden spezielle Performance Kriterien für die EIT zusammengestellt. Diese sind unter anderem: Amplitude Response, Position Error, Resolution, Shape Deformation und Ringing.

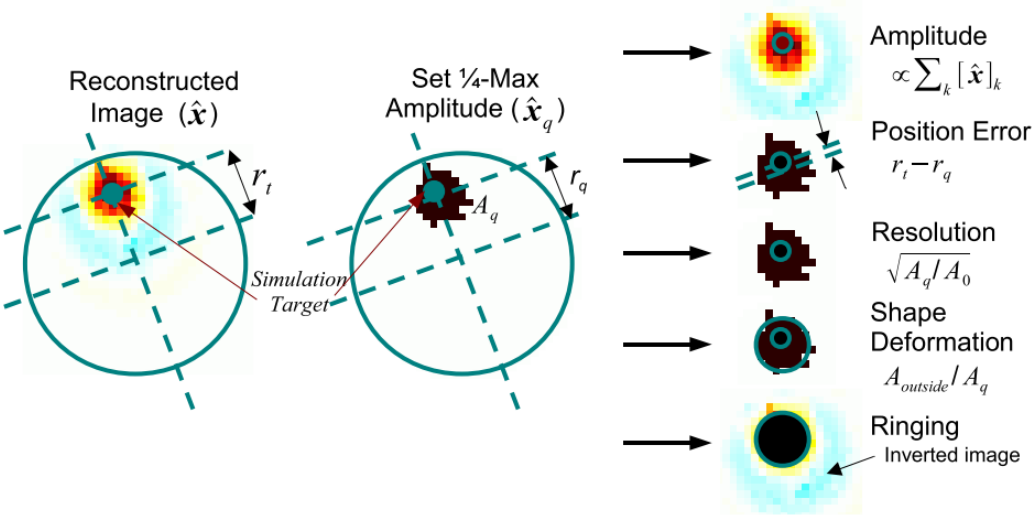



Abbildung 5.1: Übersicht der Performance Kriterien aus [16].

## 5.1 Vorverarbeitung

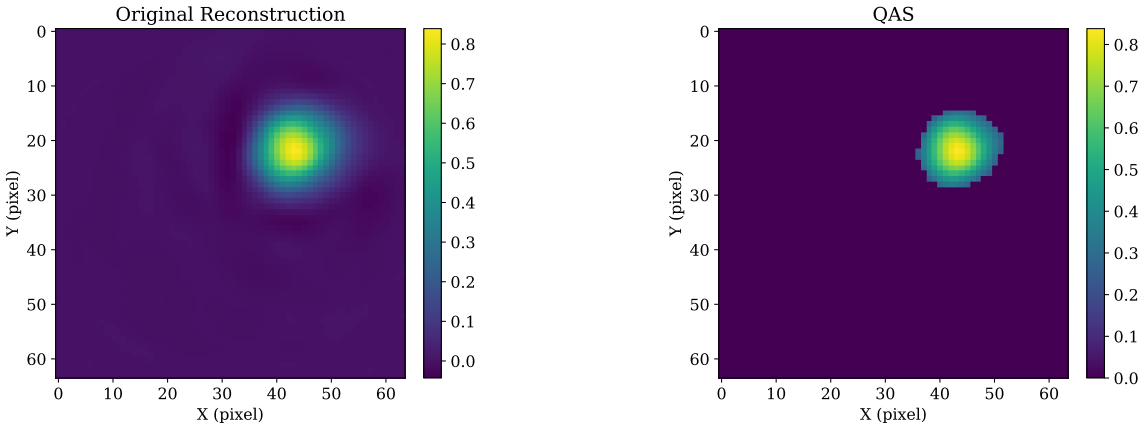
Für die Evaluation nach [16] werden einige Größen eingeführt:

- Amplitude $\hat{Z}$: Ist der Maximalwert der rekonstruierten Impedanzverteilung $Z(\vec{x})$.

$$\hat{Z} = \max Z_i(\vec{x}) \tag{5.2}$$

- Das Quater Amplitude Set (QAS): Ist die Sammlung aller Pixel, welche größer als $\frac{1}{4}$ der Amplitude sind. Diese werden auf Eins und alle darunter auf Null gesetzt (Abbildung 5.2).

$$Z(\vec{x}) = \begin{cases} 1 & \text{wenn } Z(\vec{x}) \geq \frac{1}{4}\hat{Z} \\ 0 & \text{sonst.} \end{cases} \tag{5.3}$$




(a) Originale Rekonstruktion.

(b) Vorstufe des QAS der Rekonstruktion.

Abbildung 5.2: Mittels des QAS wird ein Binärbild erstellt, um die detektierte Position festzulegen. Alle Pixel, welche unter $\frac{1}{4}\hat{Z}$ liegen werden zu Null gesetzt und alle anderen auf Eins (im Bild noch nicht angewendet).

- Center of Gravity (CoG) $\vec{r}_q$: ist der Schwerpunkt des QAS Bildes:

Dafür wird der Mittelwert aus allen Koordinaten des QAS bestimmt.

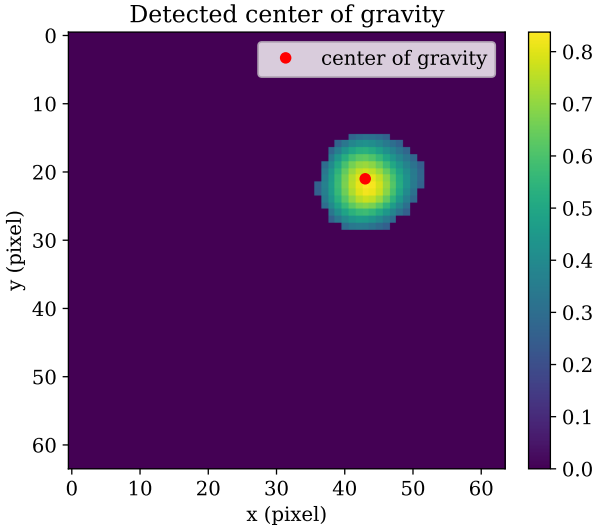



Abbildung 5.3: Um die detektierte Position des Targets ($r_q$) zu bestimmen, wird das CoG berechnet.

## 5.2 Kriterien

Nun folgen die Kriterien, welche an einem Beispiel in Abbildung 5.4 erläutert werden. Dabei handelt es sich um einen Querschnitt durch eine Anomalie mit höherer Impedanz („Target“) als der Hintergrund.

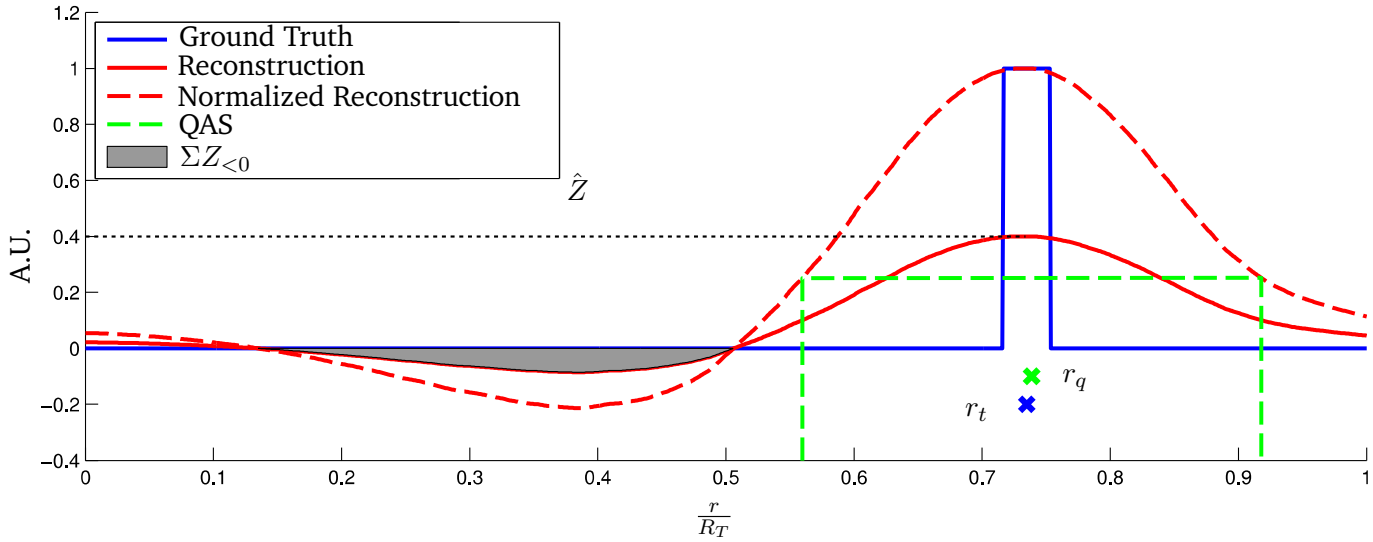



Abbildung 5.4: Beispielhafte Darstellung zur Veranschaulichung der Kriterien. In Rot ist die Rekonstruktion zu erkennen. Diese wird anschließend normiert und das QAS gebildet (Grün). Die negativen Impedanzen durch das Überschwingen sind in Grau markiert. Die G.T. Position ist $r_t$ und das aus der Rekonstruktion bestimmte CoG ist $r_q$ [17].

### 5.2.1 Amplitude Response

Die Amplitude Response (AR) gibt an, wie hoch der Ausschlag im rekonstruierten Bild ist in Relation zum G.T. Bild.

$$AR = \frac{\sum Z_{reconstruct}}{\sum Z_{gt}} \tag{5.4}$$

Die AR sollte idealerweise möglichst hoch und über die gesamte Region Of Interest (ROI) identisch sein. Je höher, desto besser ist der Kontrast im Bild.

### 5.2.2 Position Error

Der Position Error (PE) gibt an, wie gut der Rekonstruktionsalgorithmus die räumliche Position des Targets rekonstruieren kann.

$$PE = r_t - r_q \tag{5.5}$$

Dabei ist $r_t$ die reale Position des Targets und $r_q$ das aus dem rekonstruierten Bild bestimmte CoG.
Der PE ist idealerweise klein und unabhängig von der Position in der ROI.

### 5.2.3 Resolution

Gibt die minimal auflösbare Größe des Targets als Verhältnis zur Größe der ROI an.

$$RES = \sqrt{\frac{A_q}{A_0}} \tag{5.6}$$

Hierbei ist $A_q$ die Größe des Targets in Pixel und $A_0$ die Größe der ROI in Pixel. Die Wurzel sorgt dafür, dass es ein Verhältnis der Radien und nicht der Flächen ist. Je kleiner $RES$, desto besser ist die räumliche Auflösung.

### 5.2.4 Shape Deformation

Die Shape Deformation (SD) gibt an, wie gut die Form der Targets durch den Algorithmus rekonstruiert wird. In Abbildung 5.2 ist zu sehen, dass die Rekonstruktion nicht mehr exakt kreisförmig ist. Sie wird bestimmt durch das Verhältnis der Pixel, die nicht in einen Kreis um das CoG mit der Fläche aller aktivierten Pixel passen.

$$SD = \frac{\sum_{k!=c} Z_{reconstruct}}{\sum Z_{target}} \tag{5.7}$$

Die SD ist idealerweise gering und ebenfalls unabhängig von der Position in der ROI. Starke Verzerrungen können zu Missinterpretation von Bildern führen.

### 5.2.5 Ringing

Mit dem Ringing wird ein Maß für das Überschwingen am Rand von Impedanzsprüngen beschrieben. Auch dies kann in Abbildung 5.2 an den dunkelblauen Stellen um das Maximum beobachtet werden. Es wird durch das Verhältnis von negativen Impedanzen zur Summe der Beträge aller Impedanzen bestimmt.

$$RI = \frac{-\sum_{\vec{x}} Z_{<0}(\vec{x})}{\sum_{\vec{x}} |Z(\vec{x})|} \tag{5.8}$$

Das Ringing ist idealerweise gering, was weniger Überschwingung in der Rekonstruktion bedeutet.

# 6 Versuchsaufbau

Um datenbasierte Modelle zu entwickeln, müssen ausreichend große Mengen an Trainingsdaten gesammelt werden. Dafür wird in dieser Arbeit ein Aufbau entwickelt. Andere EIT Datensätze besitzen meistens eine Region mit einer konstanten Hintergrund Impedanzverteilung. In diese werden anschließend Anomalien mit einer unterschiedlichen Impedanz („Targets“) eingebracht. Dabei werden häufig kreisförmige Anomalien verwendet [16, 62].
Für eine Region mit konstanter Hintergrund Impedanz werden sog. Phantom Tanks verwendet. Dabei handelt es sich um einen Plexiglas-Tank mit äquidistant angebrachten Elektroden. Dieser wird mit Wasser befüllt. Anschließend kann ein Target im Tank positioniert werden. Dafür kann beispielsweise ein hohler Zylinder aus Plastik oder ein massiver aus Metall für eine höhere oder geringere Impedanz als Wasser verwendet werden. Es ist ebenfalls möglich, biologisches Material zu verwenden.
Um möglichst viel Variation in den Daten zu generieren, müssen Messdaten von vielen unterschiedlichen Target-Positionen gesammelt werden. Dafür wird ein System benötigt, welches die Targets präzise und wiederholungsgenau positioniert. Der Versuchsaufbau besteht also aus dem EIT Gerät, dem Wassertank und dem Positioniersystem für die Targets (Abbildung 6.1).

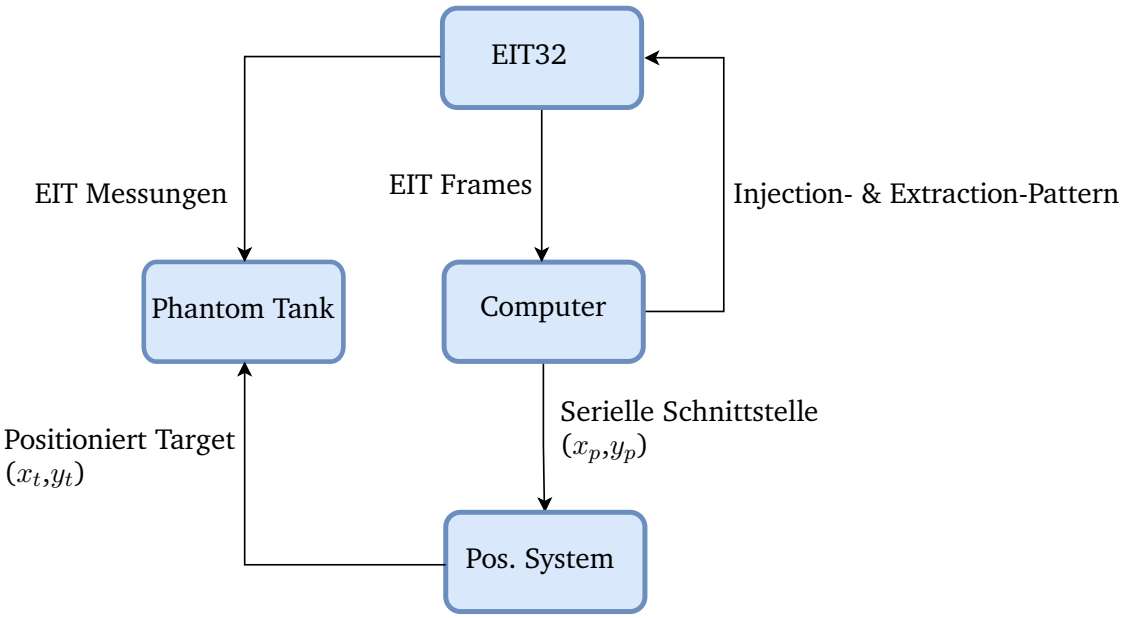



Abbildung 6.1: Übersicht über den Versuchsaufbau. Der Computer kommuniziert mit dem EIT-Gerät und gibt das zu verwendende Injection und Extraktion Pattern vor. Das EIT-Gerät nimmt über die Elektroden die Messung vor und übermittelt die EIT-Frames zurück an den Computer. Zur Positionierung der Targets werden die gewünschten Koordinaten an das Positioniersystem gesendet und das Target entsprechend verfahren.

### EIT Gerät

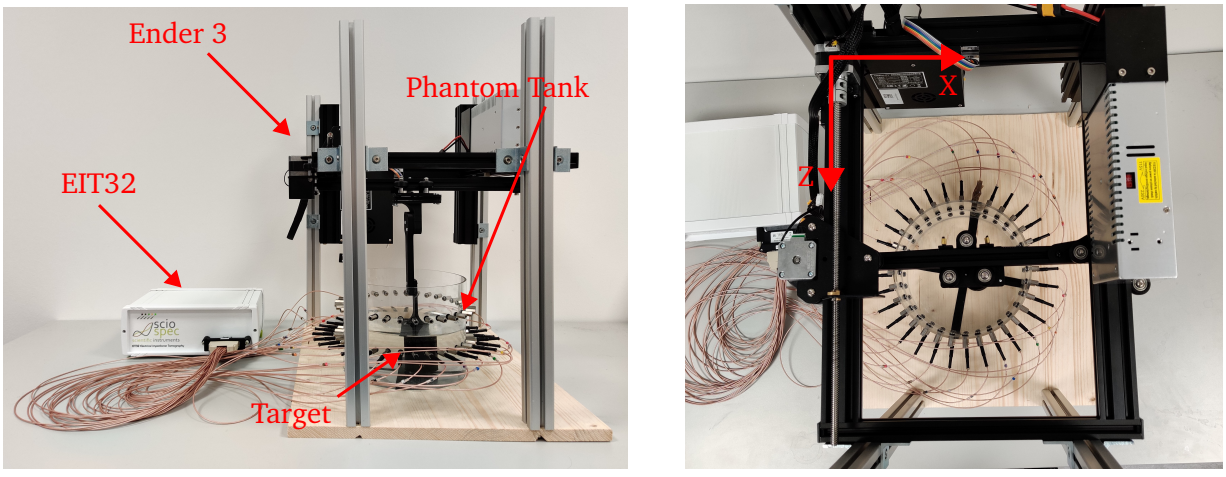
Beim EIT Gerät handelt es sich um das EIT32 der Sciospec Scientific Instruments GmbH. Es handelt sich um ein 32 Kanal EIT, einer maximalen Einspeisefrequenz von $10\,\mathrm{MHz}$ und einem maximalen Strom von $10\,\mathrm{mA}$. Es ist möglich EIT-Frames mit einer oder mehreren Frequenzen aufzunehmen und auch verschiedene Einspeise-Pattern zu erstellen. Die maximale Framerate ist abhängig von der Anzahl an verwendeten Frequenzen. Bei einer einzigen Frequenz sind bis zu $100\,\mathrm{FPS}$ möglich [11]. Bei drei Frequenzen sind es etwa $30\,\mathrm{FPS}$.

### Phantom Tank

Beim Phantom Tank handelt es sich um einen Plexiglas-Tank mit einem Innendurchmesser von $190\,\mathrm{mm}$ und einer Höhe von $150\,\mathrm{mm}$. Der Tank wird über eingeschraubte Elektroden mit dem EIT32 verbunden und kann über Adapter, entweder AC oder DC gekoppelt angeschlossen werden. Die Elektroden befinden sich auf einer Höhe von $55\,\mathrm{mm}$. Der Tank wird bis zu einer Höhe von $80\,\mathrm{mm}$ mit Wasser gefüllt.

### Positioniersystem

Die Anforderung an das Positioniersystem ist eine präzise und wiederholbare Platzierung unterschiedlicher Targets im Wassertank. Zudem sollte es ebenfalls günstig und einfach nach implementierbar sein. Günstige und zuverlässige Positioniersysteme werden beispielsweise in 3D-Druckern oder Laser-Cuttern verwendet.
Als Positioniersystem wird deshalb ein modifizierter 3D-Drucker (Ender 3, Shenzhen Creality 3D Technology Co, Ltd.) verwendet. Er verfügt über eine Positioniergenauigkeit von $\pm 0.1\,\mathrm{mm}$ [63]. Um ein Objekt in zwei Achsen bewegen zu können, wird der 3D-Drucker um $90°$ gedreht, sodass die X- und Z-Achse zum Verfahren genutzt werden (Abbildung 6.2). Zusätzlich wird das Heizbett inklusive der Y-Achse aus Platzgründen entfernt. Anschließend wird der 3D-Drucker mittels vier Aluminiumprofilen an einer Basis Platte aus Holz befestigt. Wie eine konstante relative Positionierung zwischen 3D-Drucker und Tank ermöglicht wird, ist im nächsten Kapitel beschreiben.




(a) Front Ansicht des Versuchsaufbaus

(b) Aufsicht des Versuchsaufbaus

Abbildung 6.2: Zur automatisierten Sammlung von Trainingsdaten wird ein umgebauter 3D-Drucker genutzt. Die Y-Achse und das Heizbett wurden entfernt und an die Position des Druckkopfes ein Adapter angebracht. An diesen können die Targets befestigt und im Tank verschoben werden.

Als Targets für die Trainingsdaten werden 3D gedruckte Zylinder aus Polylactide (PLA) mit unterschiedlichen Durchmessern verwendet. Diese werden mit $10\%$ Füllung („Infill“) gedruckt, wodurch sie hauptsächlich mit Luft gefüllt sind und dadurch eine höhere Impedanz als Wasser besitzen sollten (Abschnitt 9.1.6).

# 7 Datensammlung und Vorverarbeitung

Im folgendem Kapitel wird erläutert, wie der Datensammlungsprozess mit dem im vorherigen Kapitel beschriebenen Versuchsaufbau abläuft. Ziel ist ein Datensatz bestehend aus bekannten Korrespondenzen aus gemessenen EIT-Frames und G.T. Impedanzverteilungen.
In simulierten Datensätzen ist die G.T. Impedanzverteilungen leicht zu erhalten. In realen Anwendungen ist es jedoch schwierig, die konkrete Impedanzverteilung, insbesondere mit ausreichend räumlicher Auflösung, zu bestimmen. Je nach gewünschter Anwendung der EIT werden teilweise MRT oder CT Daten der Testkörper als Referenz verwendet. Dies ist jedoch, speziell für viele Samples, sehr aufwendig. In dieser Arbeit werden die G.T. Daten deshalb als Binärbilder generiert (Abbildung 7.1). Diese werden durch die bekannte Position und Radius des Targets erzeugt. Die Bilder haben eine Auflösung von 64x64 Pixeln und einen Wertebereich von $[0, 1]$ wobei die Position der Anomalie mit $1$ und der Hintergrund mit $0$ markiert wird. Um die Anomalie im Bild zu markieren, werden die Koordinaten des Positioniersystems $(x_p, y_p)$ zuerst in Tank Koordinaten $(x_t, y_t)$ und anschließend in Bildkoordinaten $(x_i, y_i)$ umgewandelt und je nach Target Durchmesser ein entsprechender Kreis mit $1$ markiert.

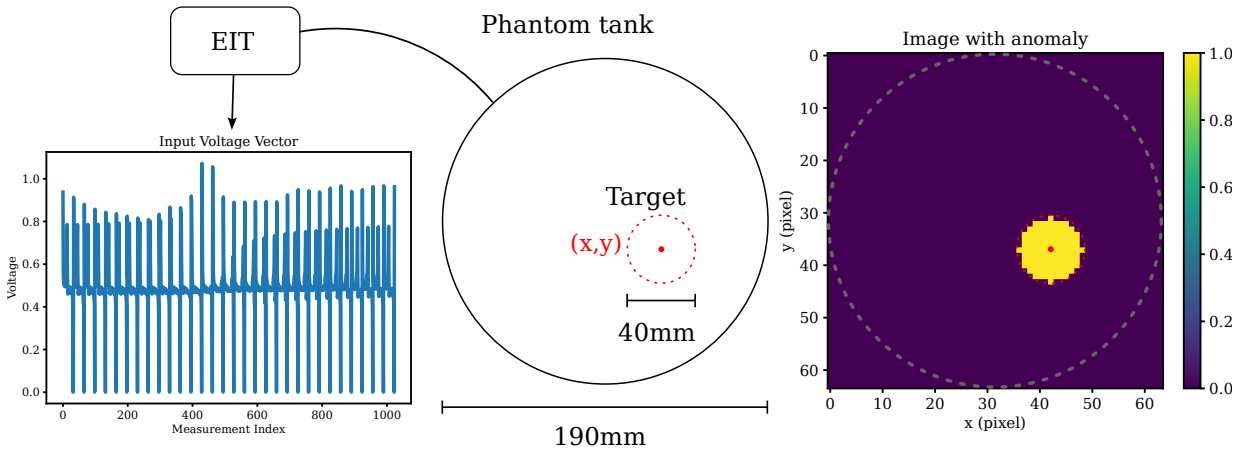



Abbildung 7.1: Das Target wird im Tank positioniert. Ein EIT-Frame wird durch das EIT32 aufgezeichnet. Entsprechend der Position und dem Durchmesser des Targets wird ein dazu passendes G.T. Bild generiert. Die Bilder haben eine Auflösung von $(64 \times 64)$ Pixeln und einen Wertebereich von [0,1] wobei die Position der Anomalie mit 1 und der Hintergrund mit 0 markiert wird.

Mit dieser Methode werden ausschließlich relative Impedanzunterschiede erfasst, ohne dabei numerische Werte für die Impedanz zu quantifizieren. Durch die Art des Versuchsaufbaus sind ausschließlich Datensätze mit jeweils einem Target gleichzeitig in der ROI möglich.

Der Datensammlungsprozess läuft folgendermaßen ab:

1. Kalibrierung der Tank Position unter dem Positioniersystem;
2. Aufnahme eines Referenz EIT-Frames (nur bei tdEIT);
3. Anfahren einer beliebigen Position im Tank;
4. Aufnahme des EIT-Frames;
5. Generierung des dazu passenden Impedanzbildes;
6. Speichern von EIT-Frame und Impedanzbild.

Schritte 3 bis 6 werden anschließend beliebig oft wiederholt.

#### Kalibrierung

Damit die Position zwischen Ender 3 und Tank immer konstant ist, wird der Aufbau in Punkt 1 kalibriert. Sollten der 3D-Drucker und der Tank eine fehlerhafte Position zueinander haben, wird das Target an einer anderen Stelle markiert, als es in Wirklichkeit befindet. Dadurch würden systematische Fehler im Datensatz entstehen. Für die Kalibrierung werden bestimmte Elektroden Positionen im Tank angefahren, anhand derer kontrolliert wird, ob die Position stimmt. Es werden die Elektroden $1$, $9$, $17$ und $25$ angefahren, sodass das Target die Elektrode gerade so berührt. Wenn dies für alle $4$ Positionen gilt, ist der Tank richtig ausgerichtet.

#### Vorbereitung des Samples

In Punkt 2 wird im Fall der tdEIT der Referenz Frame $V_0$ aufgenommen. Dies ist wichtig, da sich die Anschlussimpedanz je nach Elektrode unterscheiden kann. Nun wird die Anomalie an eine zufällige Stelle im Tank verfahren (Punkt 3). Dafür wird zusätzlich die dafür benötigte Zeit berechnet und gewartet, da der 3D-Drucker keine Rückmeldung über das Erreichen der Position übermittelt.
Diese wird über die Distanz und Bewegungsgeschwindigkeit bestimmt. Da ein 3D-Drucker in der Z-Richtung meistens langsamer ist als in den anderen Richtungen, wird dies ebenfalls berücksichtigt. Dies liegt an der Übersetzung mittels einer Schraubstange, welche auch in Abbildung 6.2 zu sehen ist.

#### Aufnahme EIT Frame und Generierung des G.T. Bildes

Anschließend nimmt das ScioSpec Gerät einen EIT Frame mit den eingestellten Injection und Extraction Pattern auf (Punkt 4). Dazu wird ein passendes Impedanzbild entsprechend der Target-Position und Größe erstellt (Punkt 5). Abschließend werden in Punkt 6 das Target Bild zusammen mit dem dazugehörigen EIT-Frame abgespeichert. Dieser Vorgang wird nun beliebig oft wiederholt, um Trainingsdaten zu generieren.

## 7.1 Augmentation

Um die Datenmenge zu vergrößern, werden unterschiedliche Methoden der Augmentation angewendet. Da die Input Daten keine Bilder wie in Abschnitt 3.4.4 sind, kommen nicht alle Augmentations Arten in Frage, wie sie in der Bildverarbeitung genutzt werden können.

### 7.1.1 Noise Augmentation

Zum einen kann der Spannungsvektor mit Rauschen überlagert werden. Dies ermöglicht, dass das Netzwerk robuster gegenüber Messrauschen wird. Dafür wird eine maximale Rausch Amplitude $A_{noise}$ in Abhängigkeit der Standardabweichung der Daten ($\sigma$) definiert:

$$A_{noise} = \sigma(\vec{V}_{train}) \cdot \lambda. \tag{7.1}$$

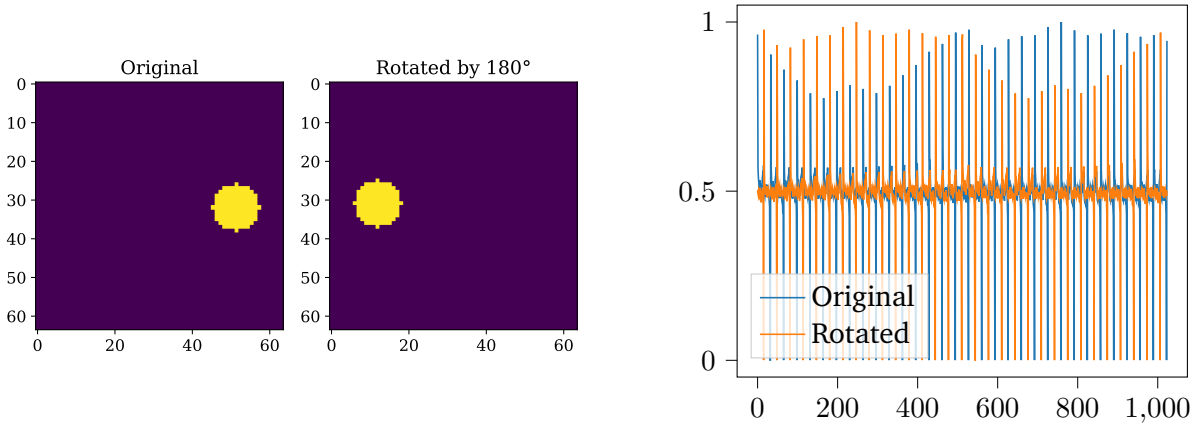
Diese kann mittels des Parameters $\lambda$ skaliert werden. Anschließend wird das Rauschen auf die Daten addiert

$$\vec{V}_{train} = \vec{V}_{train} + A_{noise} \cdot \vec{a}. \tag{7.2}$$

Dabei ist $\vec{a}$ ein Vektor mit der gleichen Länger wie $\vec{V}_{train}$, welcher Werte zwischen $-1$ und $1$ annehmen kann. Hierbei kann $\vec{a}$ verschiedene Noise Arten darstellen. Beispielsweise Gaussian Noise mit einer Normalverteilung, Salt and Pepper Noise mit Einsen und Nullen oder Speckle Noise. Für EIT wird meistens von Gaussian Noise als Messrauschen ausgegangen [64, 65].

### 7.1.2 Rotation Augmentation

Eine weitere Möglichkeit der Augmentierung ist es, eine Drehung des Tanks zu simulieren, indem das Bild sowie die Indizes des Spannungsvektors gleichmäßig rotiert werden. Dafür wird zuerst die Winkelauflösung pro Elektrode bestimmt. Bei $32$ Elektroden sind es $11.25°$.
Anschließend wird das Bild um ein ganzzahliges Vielfaches davon ($r$) gedreht und der Spannungsvektor ($\vec{V}$) um $\frac{r}{360°} * \text{len}(\vec{V})$ verschoben. Somit ergibt sich ein Datensatz, wie der Spannungsvektor aussehen müsste, wenn das Target an einer anderen Position gewesen wäre. Ein Vorteil hierbei ist, dass das Netzwerk weniger Möglichkeiten hat, auf die bestehenden Unterschiede der einzelnen Elektroden zu overfitten.




(a) Das rotierte Target Bild.

(b) Der sich theoretisch ergebende Spannungsvektor

Abbildung 7.2: Durch die Rotation der Trainingsbilder und der Spannungsvektoren können weitere Trainingsdaten erzeugt werden. Dadurch kann das Modell ebenfalls robuster gegen elektrodenspezifische Ungleichmäßigkeiten gemacht werden.

### 7.1.3 Superposition Augmentation

Eine Beschränkung des Versuchsaufbaus besteht darin, dass in den Trainingsdaten immer nur ein Target gleichzeitig pro Sample vorhanden ist. Es ist jedoch möglich, künstliche Samples mit mehreren Targets durch Superposition der EIT-Frames und Impedanzbilder zu erzeugen.

Es werden jeweils $N$ zufällige EIT-Frames kombiniert:

$$\vec{V}_{superposed} = \frac{1}{N} \sum_{n=1}^{N} V_n. \tag{7.3}$$

Die Impedanzverteilungen werden folgendermaßen kombiniert:

$$\vec{Z}_{superposed} = \sum_{n=1}^{N} Z_n. \tag{7.4}$$

Somit ergibt sich ein neues Sample (Abbildung 7.3).

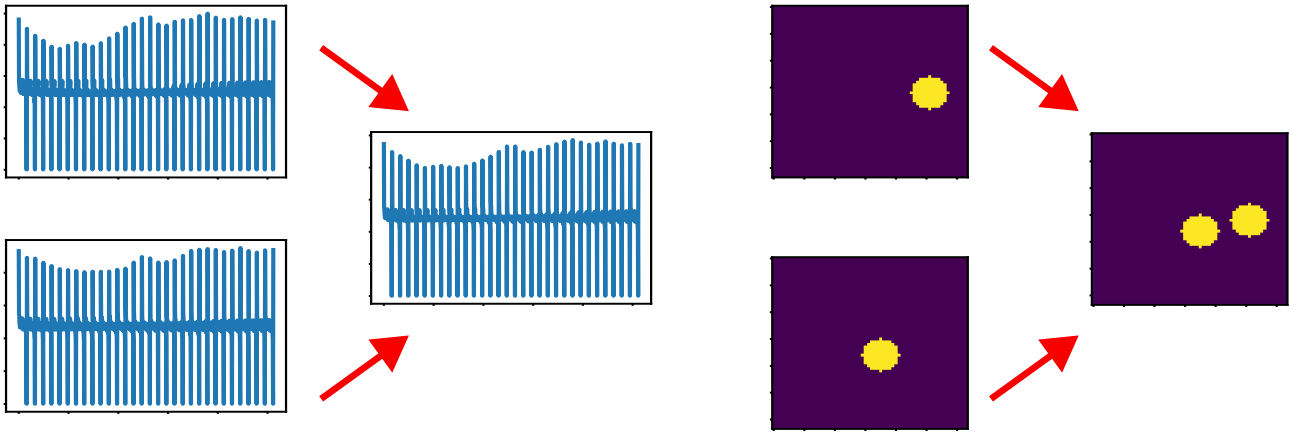


Abbildung 7.3: Eine weitere Möglichkeit einen vielfältigen Datensatz zu erzeugen ist es, mittels Superposition aus den vorhandenen Trainingsdaten neue zu generieren. Dadurch wäre es möglich, dass das Modell besser auf komplexere Szenen generalisiert.

Dadurch könnte die Einschränkung des Aufbaus ausgeglichen werden und die trainierten Modelle besser auf komplexere Szenen generalisieren. Da es sich bei der inversen EIT jedoch um ein nichtlineares Problem handelt, ist die Superposition jedoch nicht ideal anwendbar. Dies kann insbesondere bei geringen Abständen von Targets zu Problemen führen.
Im weiteren Verlauf wird eine Bewertung durchgeführt, um die Effektivität der Superposition-Augmentation zu überprüfen.

## 7.2 Dimensionality Reduction

Ein weiterer Vorverarbeitungsschritt ist die Reduzierung der Dimensionalität („Dimensionality Reduction“). Eine hohe Dimensionalität der Daten kann zu Problemen führen, insbesondere wenn es um die Modellkonvergenz geht. Modelle mit weniger Dimensionen am Eingang konvergieren in der Regel besser [66]. Zudem wird der Speicheraufwand und die Trainingsdauer bei geringere Dimensionalität der Daten reduziert. Das Hauptziel bei der Dimensionality Reduction besteht darin, die Anzahl der Features zu reduzieren, ohne dabei signifikant an relevanter Information zu verlieren. Dies ist möglich, da die einzelnen Features meist miteinander korrelieren [67]. Zudem kann auch Overfitting reduziert werden, da die reduzierten Features häufig eine allgemeinere Darstellung des Inputs bedeuten [66].
Ein Weg um die Dimensionalität zu reduzieren, ist die Hauptkomponenten Analyse, Principal Component Analysis (PCA). Dabei wird die Singular Value Decomposition (SVD) genutzt, um die linear unabhängigen Hauptkomponenten in den Daten zu finden. Ein Maß für den Informationsgehalt der Daten ist die Varianz. Je höher die Varianz einer Komponente, desto höher ist auch der Informationsgehalt. Es wird zuerst die Richtung mit der maximalen Varianz gesucht. Das ist die erste Hauptkomponente. Anschließend wird eine dazu orthogonale Richtung mit maximaler Varianz gesucht [68]. Dies wird $n$ Mal wiederholt und dabei die Hauptkomponenten nach Informationsgehalt sortiert (Abbildung 7.4).

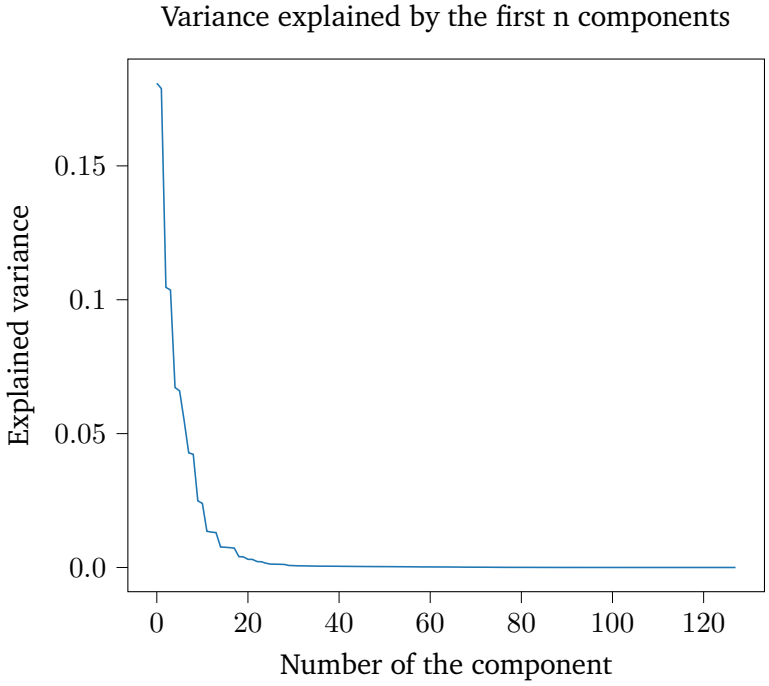



Abbildung 7.4: Es ist zu erkennen, dass ein großer Teil der Varianz in den Daten hauptsächlich durch die ersten Hauptkomponenten abgebildet werden kann. Somit kann die Dimension des Eingangs auf diese relevanten Hauptkomponenten beschränkt werden, ohne signifikant an Information zu verlieren.

Zur Veranschaulichung wird ein Datensatz aus simulierten Trainingsdaten verwendet. Dafür wurde pyEIT [19] verwendet. In Abbildung 7.5 sind die ersten drei Hauptkomponenten des Datensatzes abgebildet.

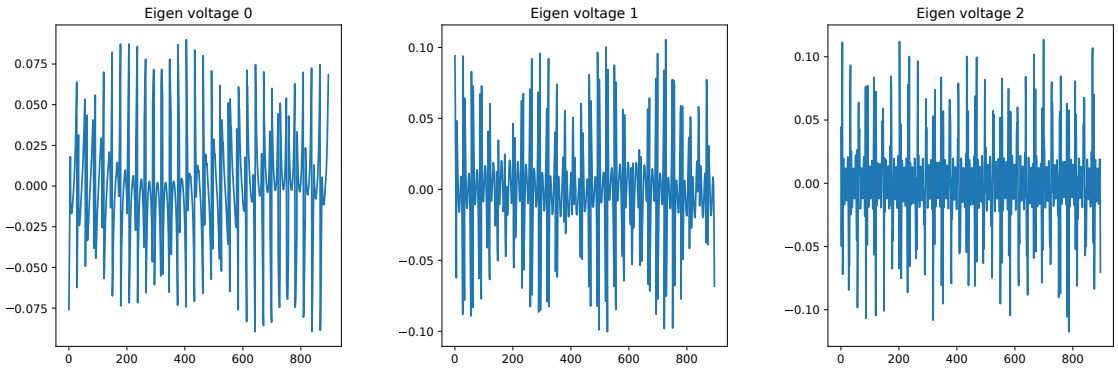
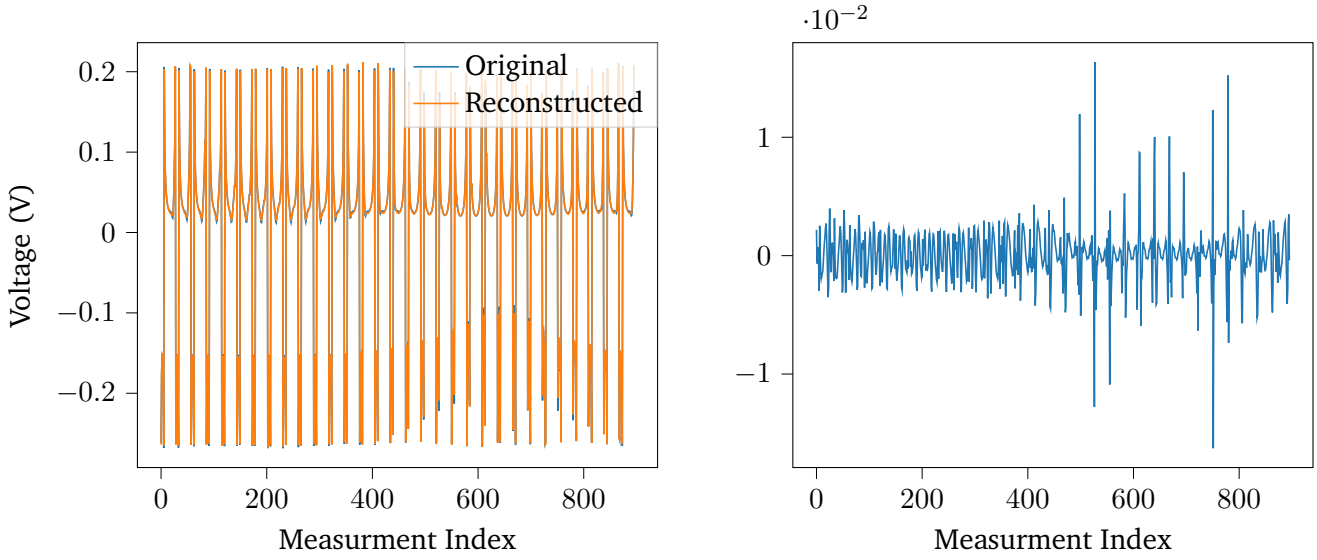



Abbildung 7.5: Zu sehen sind die ersten drei Hauptkomponenten, welche mittels der PCA bestimmt wurden. Werden diese sogenannten „Eigen“-Anteile eines Signals, entsprechend der Eigenwerte des Signals addiert, kann eine Näherung des Signals erzeugt werden. Diese Eigenwerte werden durch die SVD gefunden.

Ist nun die PCA reduzierte Form eines gemessenen Spannungsvektors gegeben, können diese skaliert und addiert werden, um eine Näherung des real gemessenen Signals zu erhalten, ohne alle $829$ Messwerte zu verwenden (Abbildung 7.6).




(a) Vergleich originaler Spannungsvektor und Rekonstruktion.

(b) Differenz zwischen original und Rekonstruktion.

Abbildung 7.6: Werden nun beispielsweise die ersten 40 Hauptkomponenten der PCA genutzt, um den Spannungsvektor zu rekonstruieren, so liegt die maximale Abweichung bereits unter 2 %.

Somit wurde die Anzahl der Features um etwa $95\,\%$ reduziert, wobei die enthaltene Information noch zu $99\,\%$ erhalten bleibt. Dies ist aufgrund der vorher erwähnten Redundanz in den Daten möglich.

## 7.3 Signal to Noise Ratio

Bei vielen EIT Rekonstruktionsalgorithmen kann beobachtet werden, dass die Qualität der Rekonstruktion im Zentrum der analysierten Region abnimmt. Dies liegt unter anderem daran, dass die gemessenen Spannungsänderungen abnehmen, je weiter die Impedanzänderung von den Elektroden entfernt ist. Dies kann mit der Signalqualität erklärt werden. Die Qualität der Messsignale kann mittels dem Signal to Noise Ratio (SNR) bestimmt werden. Dieses gibt das Verhältnis zwischen gemessenen Signal und dem Rauschen an. Es gibt unterschiedliche Möglichkeiten, ein SNR zu bestimmen [69]. In diesem Fall wird die RMS Methode verwendet:

$$SNR = 20 \cdot \lg\left(\frac{V_{signal-rms}}{V_{noise-rms}}\right). \tag{7.5}$$

Dabei ist $V_{signal-rms}$ der Effektivwert des Signals, auch Root Mean Square (RMS) genannt, für den Fall, dass sich eine Anomalie im Tank befindet. $V_{noise-rms}$ ist der RMS Wert des Signals für den Fall, dass sich keine Anomalie im Tank befindet. Dabei handelt es sich jeweils um das normierte Differenzsignal zwischen $V_0$ und $V_1$ (Gleichung (2.11)):

$$V_{signal-rms} = \text{RMS}\left(\frac{V1_{anomaly} - V0}{V0}\right), \tag{7.6}$$

$$V_{noise-rms} = \text{RMS}\left(\frac{V1_{empty} - V0}{V0}\right). \tag{7.7}$$

Als Experiment wird ein $40\,\text{mm}$ PLA Zylinder an unterschiedlichen Stellen im Tank angefahren und das sich ergebende Differenzsignal gemessen. Zusätzlich werden ebenfalls mehrere Aufnahmen eines leeren Tanks für das Rauschen aufgenommen. Das sich ergebende SNR wird in Abbildung 7.7 über dem Radius aufgetragen.

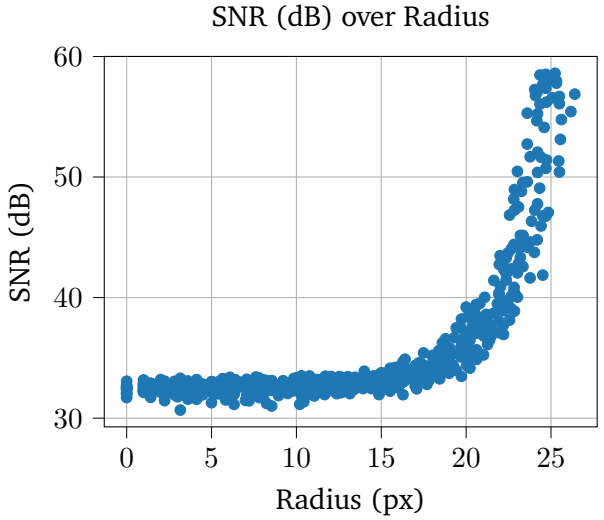



Abbildung 7.7: Das SNR nimmt zur Mitte des Tanks um bis zu $28\,\text{dB}$ ab. Dadurch ist auch die Rekonstruktion der Impedanzverteilung dort meistens ungenauer. Die Tankmitte ist befindet sich bei $0\,\text{Pixel}$. Aufgrund des Target-Durchmessers von $40\,\text{mm}$ geht der messbare Radius im Tank nur bis $26\,\text{Pixel}$.

Das SNR ist stark abhängig von der Position des Targets. Je mittiger das Target im Tank platziert ist, desto geringer das SNR.

## 7.4 Overfitting an Aufbau

Wie bereits in Abschnitt 4.2 dargestellt, hat beim Deep Learning die Qualität des Datensatzes einen großen Einfluss auf die Generalisierungsfähigkeit des Modells [49].
Beim Training der ersten Modelle ist aufgefallen, dass nach dem Ab- und wieder Aufbauen des Versuchsaufbaus die Performance der Modelle starken Schwankungen unterliegt. Ein Grund dafür kann die in Abschnitt 2.3 genannte hohe Kondition des inversen EIT Problems sein. Beispielsweise kann eine ungleichmäßige Übergangsimpedanz zwischen Medium und Elektrode die Rekonstruktion stark beeinflussen. Bereits eine geringe Variation von $20\,\%$ der Übergangsimpedanz der einzelnen Elektroden kann die Rekonstruktion nahezu bedeutungslos werden lassen [70].
Beim erneuten Anschließen der Klemmkontakte am Phantom Tank kann die Impedanz variieren. Im Fall der tdEIT wird dies teilweise umgangen, indem mit $V_0$ normiert wird. Im Fall der absoluten EIT muss ein anderer Weg zur Normierung genutzt werden. Zusätzlich kann auch eine Korrosion der Elektroden auf Dauer für eine Veränderung der aufgenommenen EIT-Frames sorgen.
Dem Overfitting an den konkreten Aufbau kann durch eine größere Variation in den Trainingsdaten entgegengewirkt werden. Dafür können Trainingsdaten für unterschiedliche Orientierungen des Phantom-Tanks aufgenommen werden, wobei der Tank dafür jedes Mal neu angeschlossen wird. Dadurch ist ein Modell, welches mit diesen Daten trainiert wurde, weniger anfällig, auf die Eigenschaften einer konkreten Konfiguration zu overfitten.
Das Testset zur Evaluierung der Performance stellt ebenfalls eine eigene Konfiguration dar, um zu prüfen, ob das Modell nicht lediglich alle Konfigurationen in den Trainingsdaten auswendig gelernt, sondern einen grundlegenden Zusammenhang in den Daten gefunden hat.

## 7.5 Gesammelte Trainingsdaten

Im Fall der tdEIT wurde das „Adjesent“ Extraction Pattern bei einer Frequenz von $1\,\mathrm{kHz}$ und einem Strom von $1\,\mathrm{mA}$ gewählt. Dabei wurden die normierten Differenzspannungen (Gleichung (2.11)) inklusive der Einspeiseelektroden verwendet, sodass $\dim(\vec{V}) = 1024$.
Es wurden insgesamt $4145$ Samples aus EIT Messungen und dazu passenden Bildern mit einer Auflösung von $(64 \times 64)$ gesammelt. Dabei gehören $10\,\%$ der Samples zum Negativset, sind also EIT-Frames des Phantom-Tanks ohne Target. Die restlichen Samples haben jeweils ein Target mit einer Größe von $40\,\mathrm{mm}$ im Tank. Dabei wurden der Tank zehn Mal in einer neuen Orientierung angeschlossen, um ein Overfitting zu vermeiden.

Für die absolute EIT wurde ebenfalls das „Adjesent“ Extraction Pattern mit den Frequenzen $1\,\mathrm{kHz}$, $500\,\mathrm{kHz}$ und $1\,\mathrm{MHz}$ bei jeweils $1\,\mathrm{mA}$ gewählt. Damit kann eine möglichst große Bandbreite abgedeckt werden um eventuelle Frequenzabhängigkeiten der Materialien nutzen zu können. Je mehr Frequenzen genutzt werden, desto länger dauert eine Messung.
Es wurden insgesamt $4711$ Samples aus EIT Messungen und dazu passenden Bildern mit einer Auflösung von $(64 \times 64)$ gesammelt, wobei $8\,\%$ der Samples zum Negativset gehören. Die Targetgröße ist ebenfalls $40\,\mathrm{mm}$. Dabei wurden $14$ unterschiedliche Orientierungen des Tanks gewählt.
Für Versuche mit unterschiedlicher Target Größe wurden ebenfalls $4744$ Samples mit $20\,\mathrm{mm}$ Targets und $402$ Samples mit $60\,\mathrm{mm}$ Targets gesammelt.

# 8 Ergebnisse und Diskussion Time Difference EIT

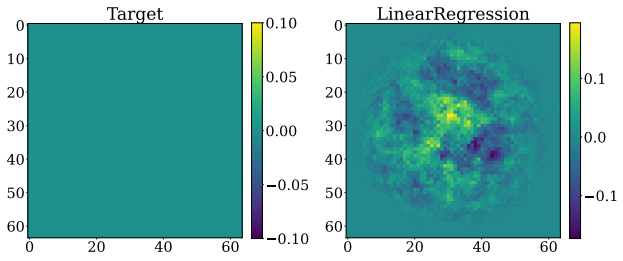
Im folgendem Kapitel werden Ansätze für die Bildrekonstruktion mittels tdEIT implementiert und verglichen. Dabei wurden eine lineare Regression, ein K-Nearest Neighbour Regressor und ein ANN genutzt. Als Trainingsdatensatz wird der in Abschnitt 7.5 erwähnte Datensatz verwendet.
Zur Evaluierung der Modelle wird ein separates Testset mit $523$ Samples verwendet.

## 8.1 Lineare Regression

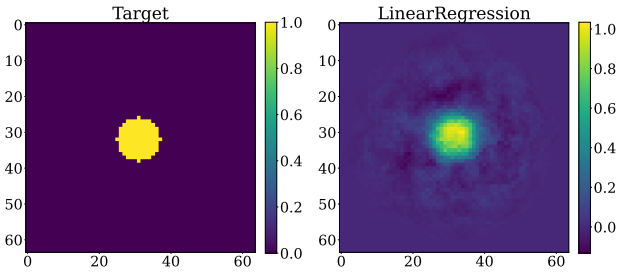
Zuerst wird zum Lösen des inversen EIT Problems eine lineare Regression genutzt. Dabei wird versucht eine lineare Funktion $f(\vec{V})$ zu finden, welche bei den Eingängen von $\vec{V}$ das gewünschte Bild $\vec{Z}(x, y)$ erzeugt:

$$\vec{V}\mathbf{W} = \vec{Z}. \tag{8.1}$$

Da es sich um eine multidimensionale Regression mit mehreren Ein- und Ausgängen handelt, ist $\mathbf{W}$ eine Weight Matrix, welche die Parameter des linearen Zusammenhangs enthält.
Da die EIT ein nichtlinearer Vorgang ist und die Daten mit Rauschen überlagert sind, wird es keine exakte Lösung geben. Deshalb existiert hierbei ebenfalls eine Loss Funktion, welche den Abstand zwischen $f(\vec{V})$ und den Datenpunkten, auch Residual Sum of Squares (RSS) genannt, minimiert. Nach dem Training ist zu erkennen, dass die lineare Regression allgemein in der Lage ist, ein Bild zu rekonstruieren (Abbildung 8.1).




(a) Repräsentatives Beispiel für ein negativ Sample



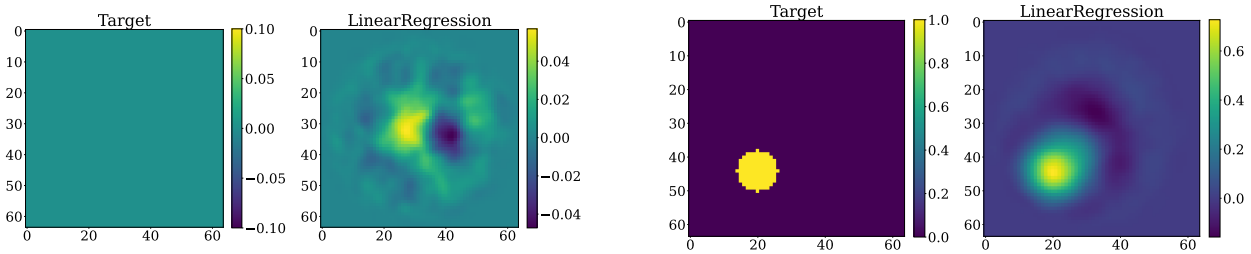

(b) Repräsentatives Beispiel für ein positiv Sample

Abbildung 8.1: Beispiele für eine Rekonstruktion mittels der linearen Regression. Die Position des Targets ist gut zu erkennen, jedoch erscheint die Rekonstruktion visuell verrauscht.

Das visuelle Rauschen kann durch die Welligkeit $w$ quantifiziert werden [17]. Diese sei $w$ definiert als:

$$w(Z(x, y)) = \frac{\text{std}(Z(x, y))}{\overline{Z(x, y)}}. \tag{8.2}$$

Die durchschnittliche Welligkeit des Modells beträgt $5.61$. Diese lässt sich durch eine Dimensionsreduzierung der Eingangsdaten verringern. Hierbei werden die Spannungsvektoren von $1024$ Dimensionen mittels einer PCA auf die ersten $128$ Hauptkomponenten reduziert. Dadurch sinkt die $w$ um etwa $20\,\%$ auf $4,51$. Dafür steigt jedoch das Ringing um $20\,\%$ von $0.19$ auf $0.23$ (Abbildung 8.2).

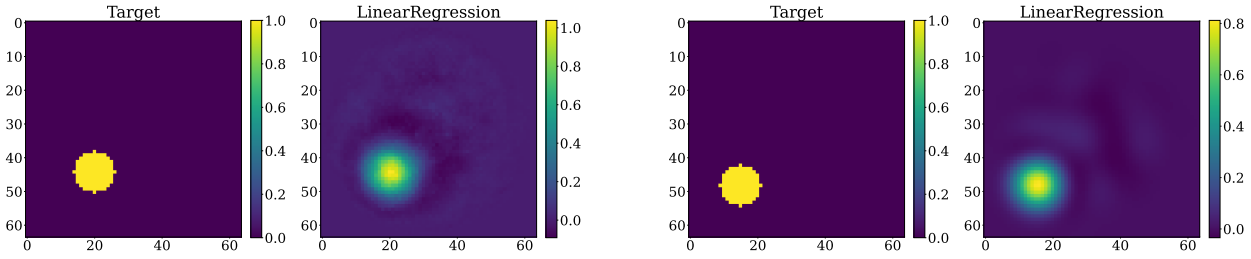



(a) Repräsentatives Beispiel für ein negativ sample

(b) Repräsentatives Beispiel für ein positiv sample

Abbildung 8.2: Beispiele für eine Rekonstruktion mittels der linearen Regression mit Verwendung einer Dimensionsreduzierung mittels PCA. Durch die geringere Dimensionalität wird das Modell in seiner Variation eingeschränkt und somit kann das Rauschen reduziert werden.

Mittels eines Gauss Tiefpass Filters können die scharfen Objektkanten in den G.T. Bildern im Trainingsset geglättet, und somit das Überschwingen der Modelle reduziert werden (Abbildung 8.3).

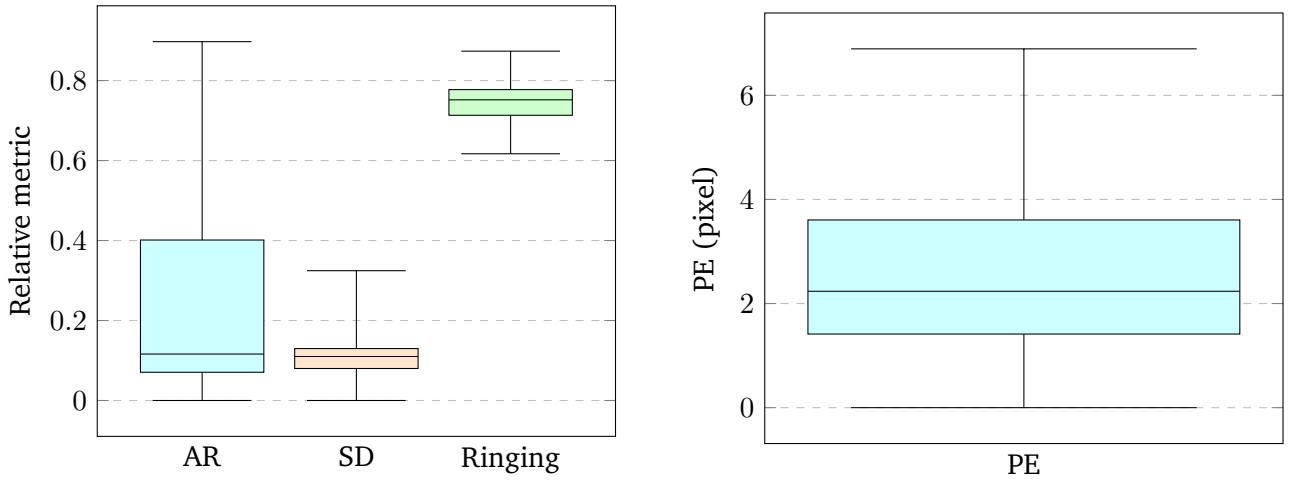



(a) Verwendung von Trainingsdaten mit scharfen Objektkanten

(b) Verwendung von weichgezeichneten Trainingsdaten

Abbildung 8.3: Durch den Gauss Filter auf den Trainingsdaten kann das Ringing reduziert werden. In (a) ist ein Kreis mit negativen Werten um das Maximum zu erkennen, welcher in (b) weniger ausgeprägt ist. Dadurch verschlechtert sich jedoch auch die Definition der Objektkanten. Die Höhe der Pixelwerte an der Target-Position verringert sich ebenfalls. In diesem Beispiel beträgt die Reduzierung etwa $20\,\%$.

Das Ringing konnte durch die Verwendung der Filter um $30\,\%$ auf $0.14$ gesenkt werden. Dadurch verschlechtern sich jedoch auch die Definition der Objektkanten und die Pixelwerte im Output sinken.
Das Modell wird anschließend an dem Testset ausgewertet. Dabei werden AR, SD, Ringing und der PE bestimmt. Die Ergebnisse sind in Abbildung 8.4 zu sehen. Dabei ist zu beobachten, dass das lineare Modell am Testset deutlich schlechter abschneidet als im Training. Insbesondere das Ringing ist vergleichsweise hoch. Der Median Positionsfehler liegt bei $2.1\,\mathrm{Pixel}$, wobei dies nur diejenigen Samples betrachtet, welche zu einer erfolgreichen Rekonstruktion geführt haben.
Die schlechtere Performance kann unter anderem an nicht zureichender Generalisierungsfähigkeit des linearen Modells oder an einem ungenügendem Dataset liegen.

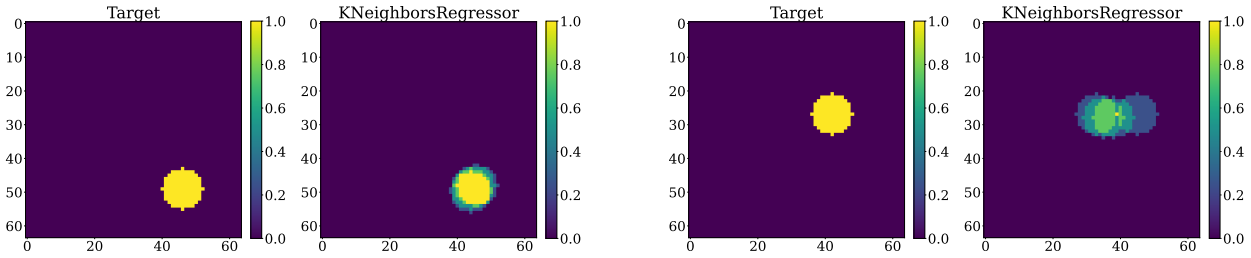



(a) (b)

Abbildung 8.4: Performance Metriken des linearen Regression Modells. Das Modell besitzt eine Median AR von $0.12$. Ebenfalls gibt es ein hohes Überschwingen der Rekonstruktion, was an dem Ringing mit einem Median von $0.75$ zu erkennen ist. Der PE ist mit einem Median von $2.1\,\mathrm{Pixel}$ jedoch gering.

## 8.2 K-Nearest Neighbors Regression

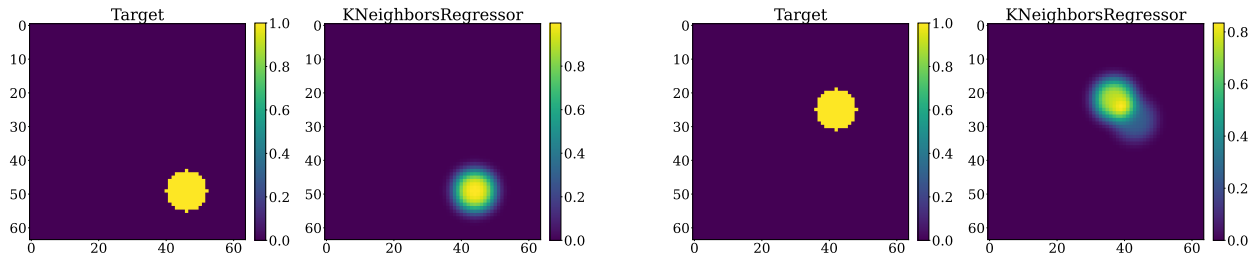
Ein weiterer Ansatz ist ein K-Nearest Neighbors (KNN) Regressor. Dieser rekonstruiert die Impedanzverteilung durch die Interpolation der $K$ ähnlichsten Samples aus den Trainingsdaten. Dabei muss „ähnlich“ durch eine Distanzfunktion definiert werden. In diesem Fall wird dafür die Euklidische Distanz genutzt.
Mittels einer Hyperparameteroptimierung wurde das optimale $K = 4$ bestimmt. Jedoch sind dabei noch deutlich die einzelnen Bilder aus der Überlagerung zu erkennen (Abbildung 8.5).




(a) Beispiel für eine visuell eher schlechte Rekonstruktion (b) Beispiel für eine visuell bessere Rekonstruktion

Abbildung 8.5: Beispielhafte Rekonstruktionen des KNN Regression Algorithmus mit $K = 4$. Die einzelnen Bilder der Interpolation sind noch zu erkennen, wodurch die Rekonstruktion wie in (b) teilweise nicht eindeutig erscheinen kann.

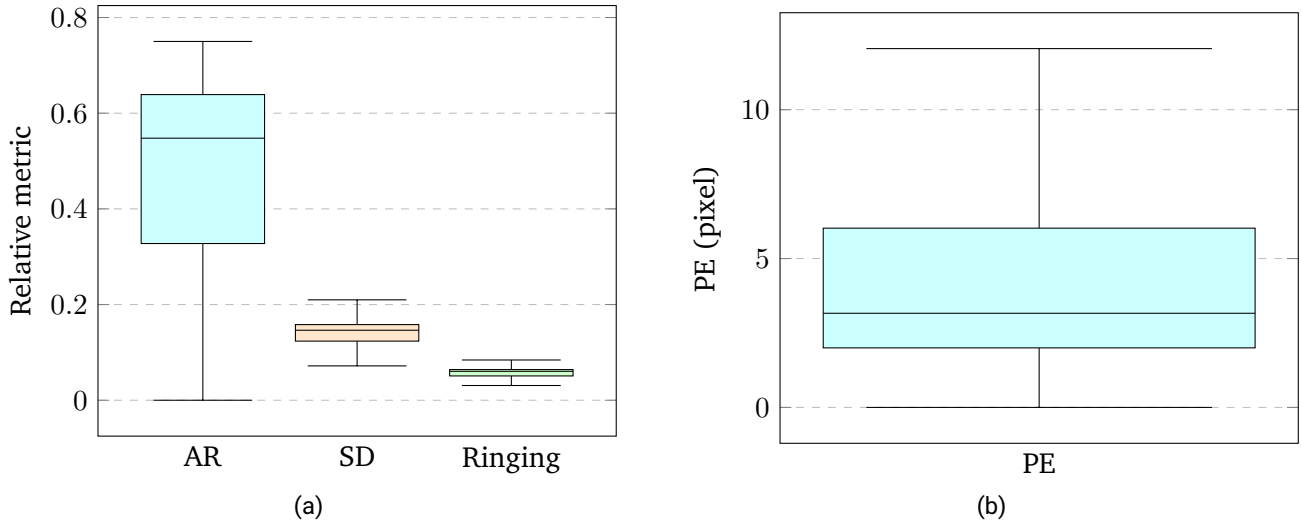
Dabei sind die Rekonstruktionen von negativ Samples ohne Target meistens ideale Bilder, ohne Rauschen wie es bei der linearen Regression der Fall ist, da es sich im Idealfall aus dem Mittelwert der $K$ nächsten Negativ Bilder handelt. In Abbildung 8.6 ist zu sehen, dass auch das Problem der sichtbaren Überlagerung durch einen Gauss Tiefpassfilter, der G.T. Trainingsbilder, verbessert werden kann.




(a) (b)

Abbildung 8.6: Durch den Gauss Filter auf den Trainingsdaten können die scharfen Kanten der Einzelbilder ausgemittelt werden und es entsteht eher der Eindruck von einem Peak. Diese Methode zeigt in bestimmten Fällen, wie in (a), eine zufriedenstellende Leistung, während sie in anderen Fällen, wie in (b), weniger gut funktioniert.

Die Evaluierung des Modells am Testset sind in Abbildung 8.7 zu sehen:




(a) (b)

Abbildung 8.7: Das KNN Regressor Modell verfügt im Vergleich zum linearen Modell über eine $4,5$-fach höhere AR mit einem Median von $0.54$ ein $90\,\%$ niedriges Ringing von $0.06$. Der PE ist jedoch mit einem Median von $3.2\,\mathrm{Pixel}$ etwa $52\,\%$ höher als der des linearen Modells.

Dabei ist zu erkennen, dass der KNN Regressor insbesondere bei AR und Ringing besser abschneidet als das lineare Modell. Da der Output lediglich der Überlagerung der Impedanzverteilungen $Z$ der $K$ ähnlichsten Spannungsvektoren $\vec{V}$ entspricht, gibt es wenig Möglichkeiten für ein Überschwingen.
Der PE ist jedoch höher, was aber unter anderem daran liegen kann, dass auch in der Tankmitte noch eine hohe AR vorhanden ist, und dort der Positionsfehler höher ist als am Rand. Eine weitere Möglichkeit ist, dass die exakte Position des Targets nicht in den Trainingsdaten vorhanden ist und somit kein passender nächster Nachbar gefunden werden kann.

## 8.3 Artificial Neural Network

Wie bereits in Kapitel 4 dargestellt, lässt sich das inverse EIT Problem gut mittels neuronaler Netze lösen. Aus diesem Grund wird der Ansatz eines neuronalen Netzwerks mit einer Encoder-Decoder-Struktur evaluiert. Dabei handelt es sich um ein ANN, wobei „Dense Layer“ verwendet werden (vergl. Abschnitt 3.1).
Das Hauptziel dieser Encoder-Decoder-Struktur ist es, ähnlich wie bei der PCA, die Extraktion relevanter Merkmale zu erreichen. Dies wird durch den Engpass („Bottleneck“) in der Mitte des Netzwerks realisiert. Aufgrund der geringeren Anzahl von Neuronen an dieser Stelle ist das Netzwerk gezwungen, nur die wichtigsten Informationen hindurch zu leiten. Ebenfalls hat sich in Kapitel 4 gezeigt, dass DNNs besser funktionieren als Netzwerke mit wenig Layern. Das Netzwerk besteht aus diesem Grund aus sieben Layern, wobei die Erste im Fall der tdEIT $1024$ Neuronen als Eingang für die Einträge des Differenzvektors $\vec{V}$ besitzt (Abbildung 8.8). Als Aktivierungsfunktion wird ReLU verwendet, da diese bei DNNs weniger Probleme mit „Vanishing Gardients“ besitzt (vergl. Abschnitt 3.3.3).
Anschließend wird die Anzahl der Neuronen in den Layern erst auf $32$ Neuronen verringert und nach dem „Bottleneck“ wieder erhöht. Der Ausgang besitzt $4096$ Neuronen um die Auflösung der Rekonstruktionen von $(64 \times 64)$ Pixeln abzubilden. Der Ausgangsvektor wird abschließend von $(1 \times 4096)$ zu $(64 \times 64)$ umgewandelt, um als Bild angezeigt zu werden.

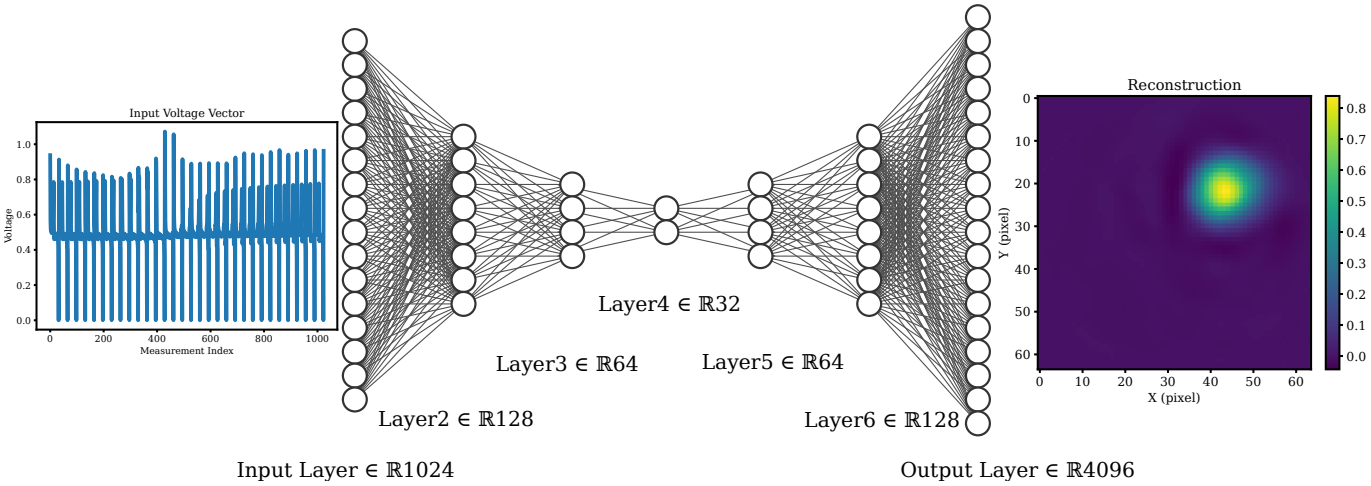
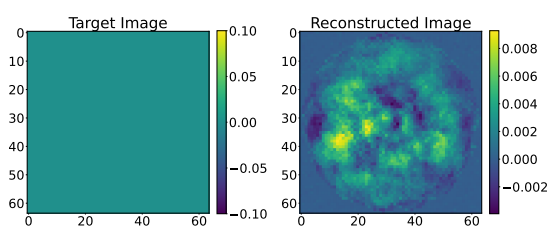
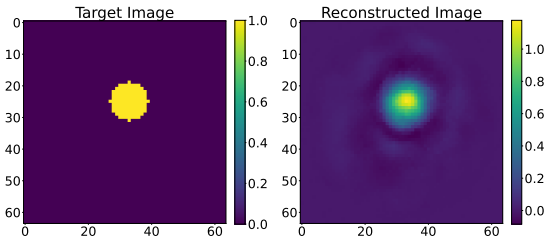



Abbildung 8.8: Schematischer Aufbau des ANN Modells. Als Eingang werden die normierten Spannungsdifferenzen verwendet. Durch das „Bottleneck“ in der Mitte des Netzwerks wird ein Engpass für die Information gebildet, der dafür sorgen soll, dass relevante Merkmale für die Rekonstruktion extrahiert werden.

Das Modell wird für $100$ Epochen mit einer LR von $0.001$ trainiert (vergl. Abschnitt 3.3.2). Als Loss Funktionen werden MAE und MSE evaluiert, wobei nur der MSE erfolgreich zu einer Lösung konvergiert.
Dabei wird Early Stopping mit einer patience von $20$ Epochen angewendet, um ein Overfitting an die Trainingsdaten zu verhindern (vergl. Abschnitt 3.4.2).
In Abbildung 8.9 sind beispielhafte Rekonstruktionen des Modells abgebildet. Das ANN Modell ist in der Lage, die Impedanzverteilung zu rekonstruieren. Dabei fällt auf, dass die Werte der Pixel im Falle eines negativ Samples meistens unter $0.01$ liegen und somit ein guter Kontrast zwischen Target und keinem Target besteht.



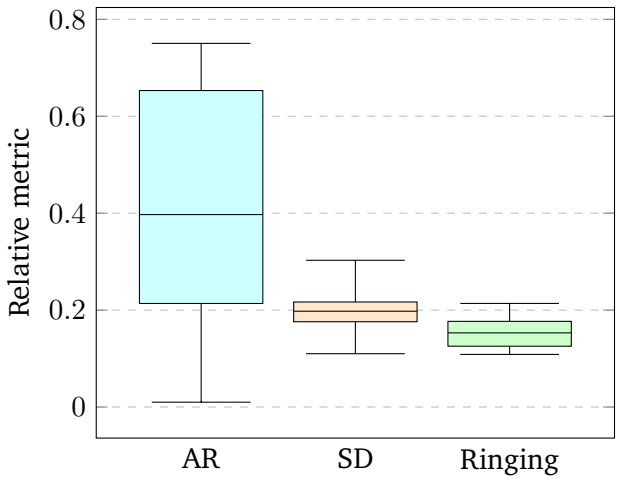

(a) Rekonstruktion eines negativ Samples



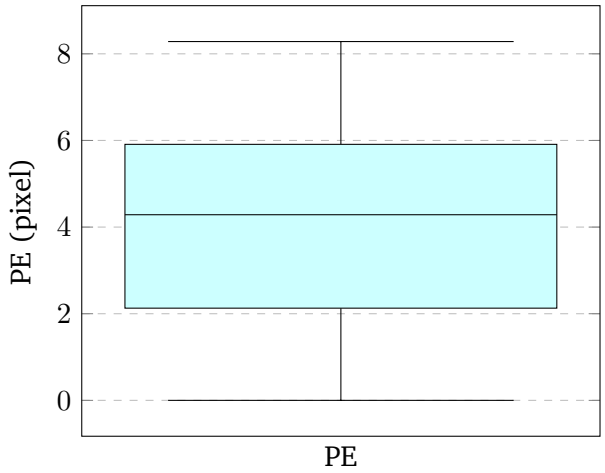

(b) Rekonstruktion eines positiv Samples

Abbildung 8.9: Beispielhafte Rekonstruktionen der ANN Architektur. Das Modell ist in der Lage, die Position des Targets im Tank sowie leere Tanks zu rekonstruieren. Die Höhe der Pixelwerte im negativen Target Bild sind mit $0.008$ dabei deutlich geringer als im linearen Modell, wodurch der Kontrast im Bild besser ist.

Das Modell wird anschließend am Testset ausgewertet. Die Ergebnisse sind in Abbildung 8.10 zu sehen.




(a)




(b)

Abbildung 8.10: Die Median AR beträgt $0.4$ und weist eine hohe interquartile range (IQR) auf, was daran liegen kann, dass Rekonstruktionen nahe am Rand des Tanks vergleichsweise gut sind und zur Mitte schlechter werden. SD und Ringing liegen im Median etwa bei $0.195$ und $0.153$. Der PE ist mit einem Median von etwa $4.3\,\mathrm{Pixel}$ ca. $34\,\%$ höher als der des KNN Regressors.

Das Modell schneidet allgemein besser ab als das lineare Modell, ist jedoch schlechter als die KNN Regression. Die AR weist eine hohe IQR auf, was daran liegen kann, dass Rekonstruktionen nahe des Tank Randes vergleichsweise gut sind und zur Mitte schlechter werden. Die SD ist mit einem Median von $0.195$ etwa $35\,\%$ höher als bei den vorherigen Modellen und das Ringing mit $0.15$ etwa 3-Fach höher als das des KNN Modells. Dabei ist zu beobachten, dass die Metriken stark von der Position des Targets abhängen. So ist die AR in der Mitte des Tanks meistens geringer als am Rand (Abbildung 8.11). Zudem ist SD und PE in der Mitte meistens höher (Abbildung 8.12).

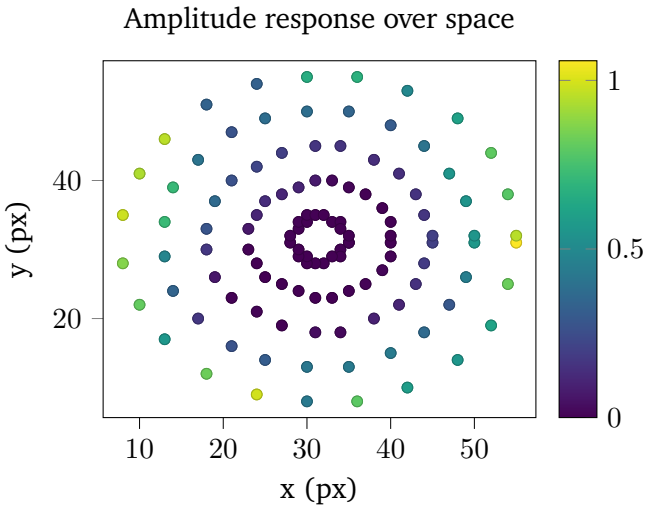



Abbildung 8.11: Um die Abhängigkeit der AR von der Position zu verdeutlichen, wird ein Testset mit Positionen in unterschiedlichen Radien und Winkeln analysiert. Dabei ist zu beobachten, dass die AR in der Tankmitte hin geringer ist als am Rand.

Es ist zu erkennen, dass die AR am Rand des Tanks deutlich höher ist als in der Mitte. Dies kann daran liegen, dass das SNR zur Mitte hin abnimmt (vergl. Abschnitt 7.3).

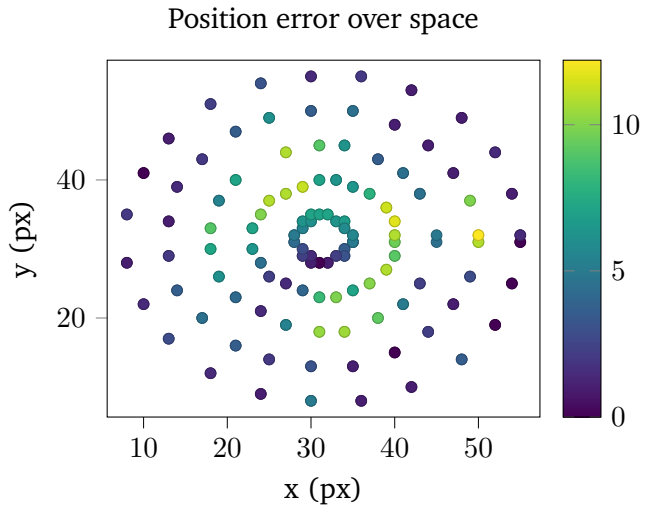



Abbildung 8.12: Der PE ist in der Mitte des Tanks höher als am Rand. Am Rand des Tanks beträgt er meistens unter $1\,\mathrm{Pixel}$, aber in der Mitte bis zu $12\,\mathrm{Pixel}$.

Der Positionsfehler ist in der Tankmitte mit bis zu $12\,\mathrm{Pixel}$ deutlich höher als am Rand. Dort wiederum hat die Position des rekonstruierten Targets meistens einen geringen Fehler von unter $1\,\mathrm{Pixel}$.

Aufgrund der besseren Vergleichbarkeit werden jedoch hauptsächlich die in den Boxplots komprimierten Metriken betrachtet.

### 8.3.1 Dropout Layer

In diesem Abschnitt wird untersucht, ob sich die Performance durch das Hinzufügen von Dropout Layern verbessern lässt (verlg. Abschnitt 3.4.3). Dafür wird nach jedem Layer aus Abbildung 8.8 ein Dropout Layer mit einer Droput Wahrscheinlichkeit $p = 10\,\%$ eingefügt. Das Modell wird anschließend ebenfalls am Testset ausgewertet (Abbildung 8.13).

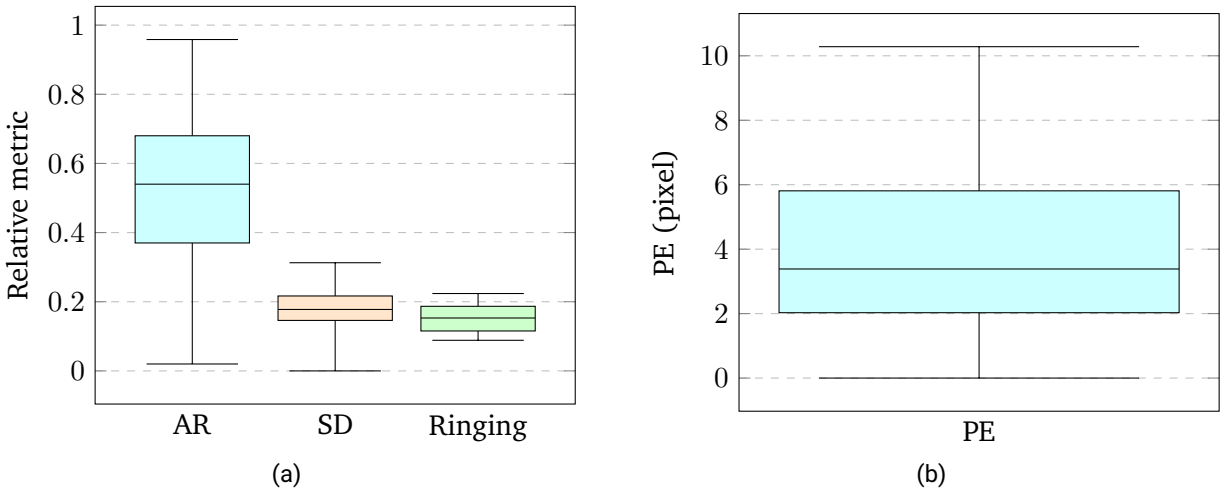



Abbildung 8.13: Durch das Hinzufügen der Dropout Layer lässt sich insbesondere die AR verbessern, wobei der Median nun bei $0.56$ liegt und die IQR gesunken ist. Dies kann daran liegen, dass das Modell durch die Dropout Layer besser generalisieren kann und deshalb auch am Testset besser abschneidet.

Durch das Hinzufügen der Dropout Layer generalisiert das Modell besser auf das Testset, wobei hauptsächlich die AR um etwa $40\,\%$ gesteigert werden konnte. Zudem ist zu erkennen, dass auch weiter in der Tankmitte noch länger eine hohe AR vorhanden ist (Abbildung 8.14).

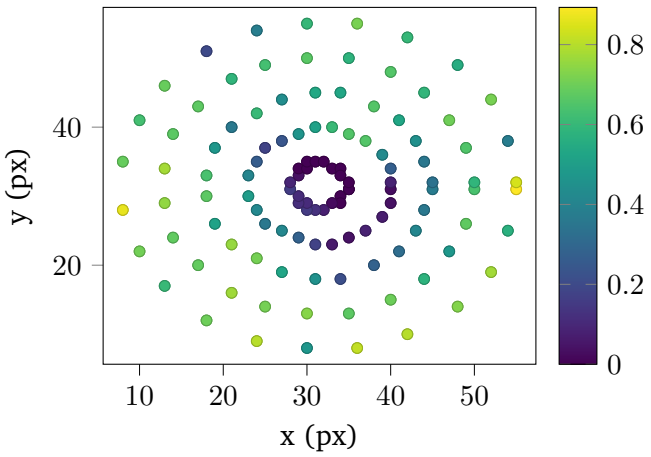



Abbildung 8.14: Das Modell mit den Dropout Layern verfügt über eine höhere AR und dies auch bei mittigerer Positionierung im Tank.

Zusätzlich wurden ebenfalls Dropout Raten von $p = 5\,\%$ und $p = 15\,\%$ evaluiert, wobei sich $p = 10\,\%$ als das Optimum herausgestellt hat.

### 8.3.2 Einfluss der Augmentation

Um den Einfluss der Augmentation zu untersuchen, wird die Datenmenge von $4145$ auf $120$ Trainings Samples reduziert. Bei dieser geringen Dataset Größe sind keine guten Rekonstruktionen mehr möglich (Abbildung 8.18). Die Metriken am Testset sind in Abbildung 8.15 zu sehen.

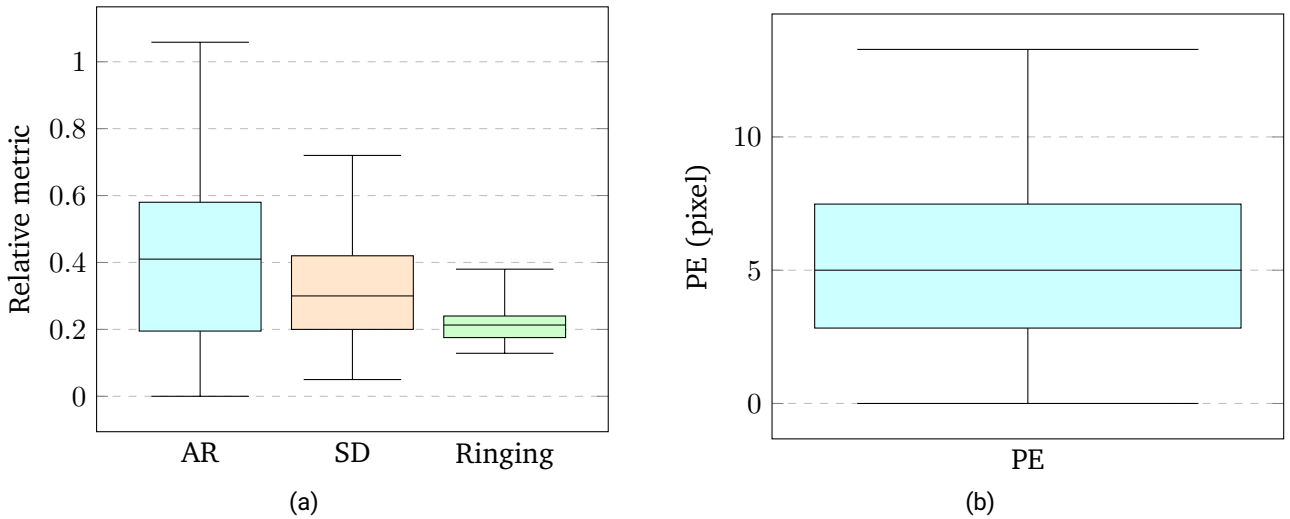



Abbildung 8.15: Bei Verwendung von weniger Trainingsdaten ist eine deutliche Verschlechterung der Ergebnisse zu erkennen.

Nun wird überprüft, ob die Performance des Modells durch das Hinzufügen von künstlich generierten Daten verbessert werden kann. Werden nun die für jedes Sample zusätzlich zehn Kopien mittels Noise Augmentation hinzugefügt, so ist bereits eine Verbesserung der AR um $50\,\%$ zu erkennen (Abbildung 8.16). Dabei wurde der Parameter für die Noise Amplitude $\lambda = 0.02$ gesetzt (vergl. Abschnitt 7.1).

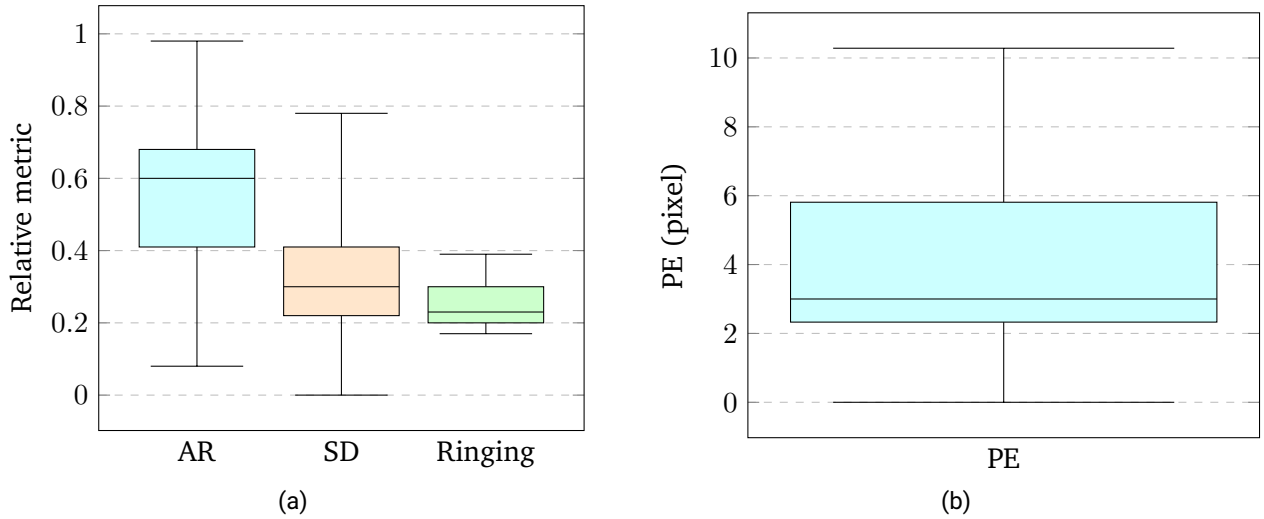
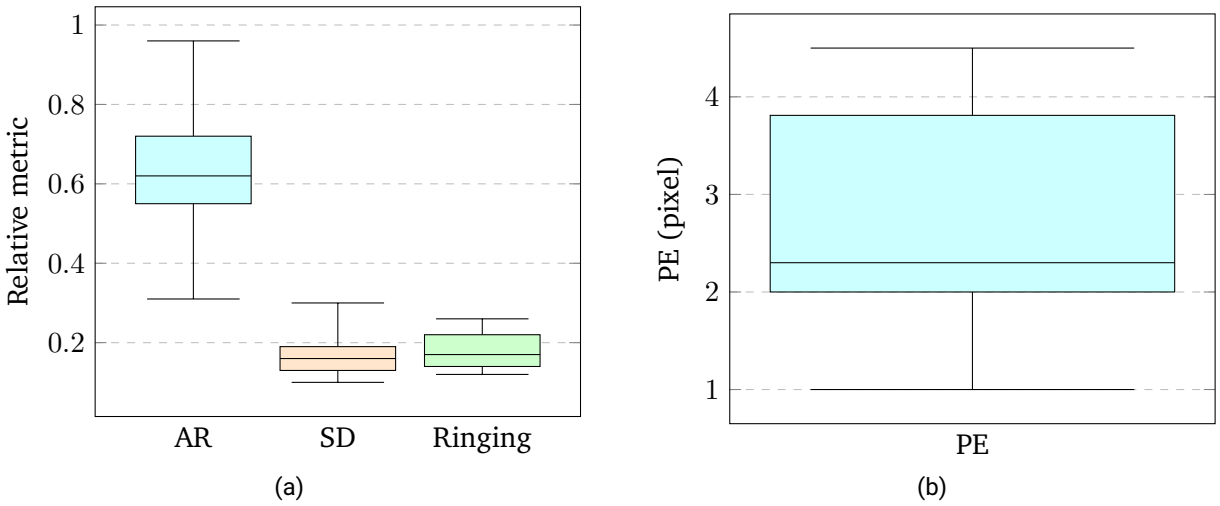



Abbildung 8.16: Durch die mittels Noise Augmentation zusätzlichen generierten Daten lässt sich die Performance am Testset verbessern. Dies ist insbesondere für die AR und den PE der Fall.

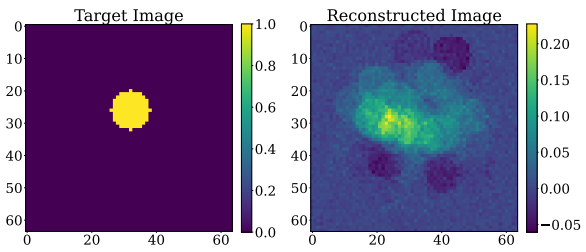
Anschließend kann die Rotation Augmentation hinzugenommen werden. Wird der Datensatz um jeweils fünf Kopien pro Sample mittels Noise Augmentation und mit fünf Kopien pro Sample mit der in Abschnitt 7.1 beschriebenen Rotation Augmentation erweitert, verbessert sich das Ergebnis erneut (Abbildung 8.17). Dabei ist insbesondere eine Verbesserung der SD um etwa $47\,\%$ zu beobachten.



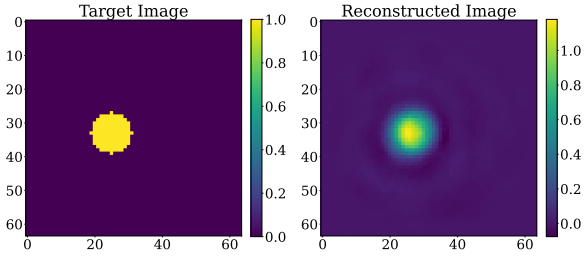

(a) (b)

Abbildung 8.17: Die Kombination aus zusätzlich generierten Daten aus Noise- und Rotation Augmentation liefert eine weitere Verbesserung der Ergebnisse bei geringer Datensatz Größe. Hierbei ist insbesondere eine Verbesserung der SD um etwa $47\,\%$ zu beobachten. Die IQR des PE ist um $52\,\%$ gesunken.

In Abbildung 8.18 kann die Verbesserung der Rekonstruktionsergebnisse anhand von Beispielen veranschaulicht werden:




(a) Rekonstruktion vom Modell, welches mit 120 echten Samples trainiert wurde.




(b) Rekonstruktion vom Modell, welches mit 120 echten Samples und 1200 augmentierten Samples trainiert wurde.

Abbildung 8.18: Obwohl beide Modelle den gleichen Ursprungs-Datensatz verwenden, ist erkennbar, dass Modell (b) durch die Vergrößerung der Datenmenge durch Augmentation deutlich bessere Rekonstruktionsergebnisse produzieren kann.

Dabei ist zu erkennen, dass ohne die Augmentation keine genaue Position des Targets auszumachen ist. Wenn dem Datensatz jedoch mit künstlichen augmentierten Daten erweitert wird, sind die Rekonstruktionen qualitativ besser. Somit können bereits mit einer geringen Datenmenge qualitativ gute Modelle trainiert werden.

Eine weitere Möglichkeit ist es, die scharfen Impedanzsprünge in den G.T. Bildern mittels Glättungsfiltern abzuflachen. Dadurch können die Rekonstruktionen realistischer sowie das Ringing reduziert werden [17]. Als Glättungsfilter wird ein 2D Gauss Blur Filter mit einer Kernel Size von $3 \times 3$ und $\sigma = 1$ verwendet. Dafür wird das Modell $15$ Mal mit der vorherigen Anwendung von $[0, 2, 4, 6, 8]$ Filtern trainiert. In Abbildung 8.19 werden die Pearson Korrelation und das Ringing über der Anzahl von Filterungen aufgetragen.

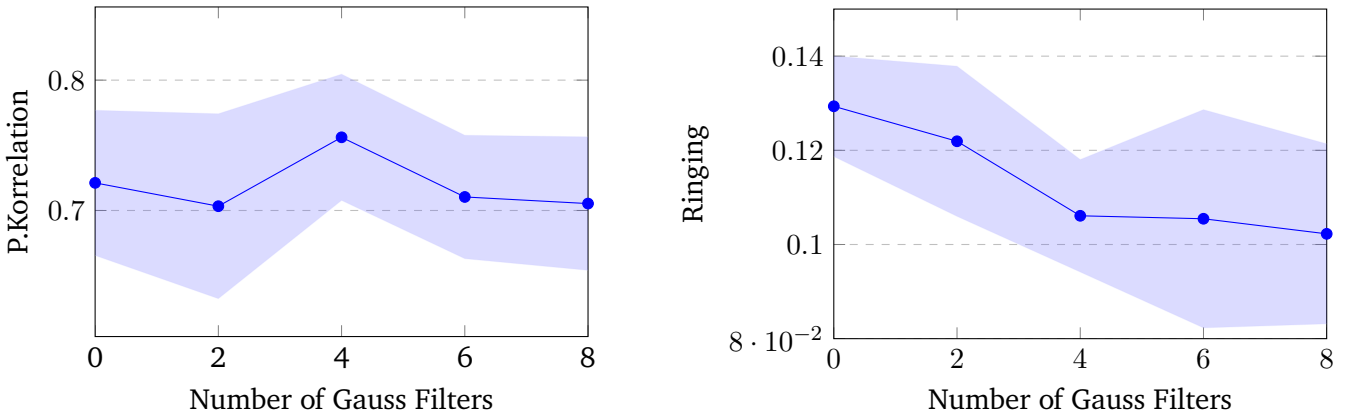



Abbildung 8.19: Durch das Hinzufügen der Gauss Filter lässt sich die Pearson Korrelation der Outputs zu den Targets um etwa $5\,\%$ steigern und das Ringing um bis zu $15\,\%$ verringern. Bei einer Verwendung von vier Glättungsfiltern ist die Pearson Korrelation am höchsten.

Durch die Gauss Filter lässt sich nicht nur der visuelle Eindruck der Rekonstruktionen, sondern auch die Pearson Korrelation Steigern und das Ringing verbessern. Bei der Verwendung von mehr als $4$ Filtern verschlechtert sich die Korrelation jedoch wieder. Der PE ist leicht geringer, aber die SD steigt mit zunehmender Anzahl an Gauss Filtern (Abbildung 8.20).

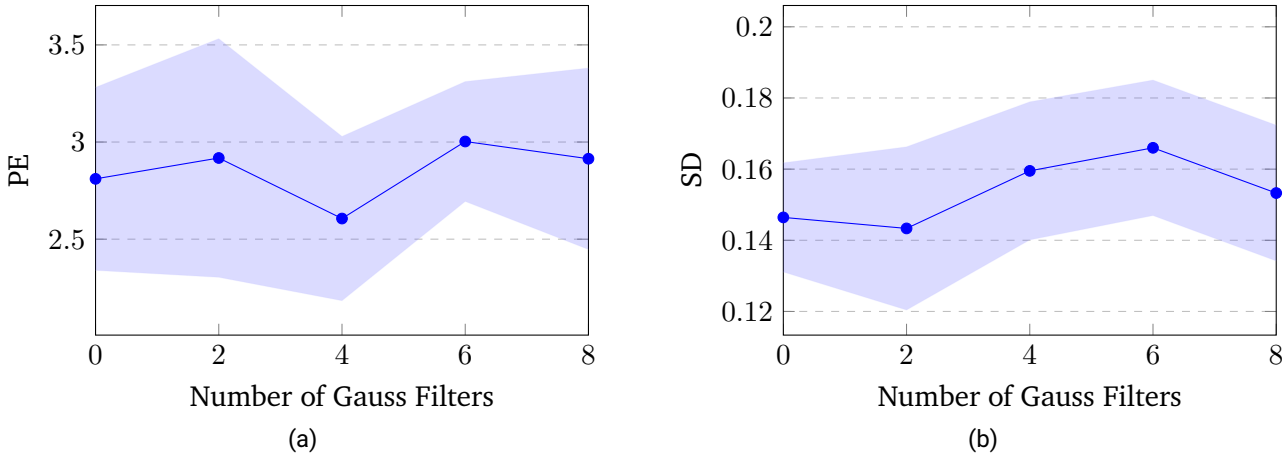



Abbildung 8.20: Der PE ist bei der Verwendung von $4$ Filtern $8\,\%$ geringer als bei $0$ Filtern. Die SD hingegen verschlechtert sich durch das Hinzufügen von Gauss Filtern um bis zu $13\,\%$.

Insgesamt kann der Gauss Filter für eine qualitative Verbesserung der Rekonstruktionsergebnisse sorgen. Jedoch steigt durch die weicheren Kanten auch die SD in den Rekonstruktionen.

### 8.3.3 Einfluss Weight Decay

In diesem Abschnitt wird der Einfluss des WD Parameters auf Modell betrachtet.

Dafür wird das Modell mit $wd = [1e-05, 0.0001, 0.001, 0.01]$ 15 Mal für 60 Epochen ohne Augmentation trainiert und die AR sowie die Pearson Korrelation der Output und Target Bilder betrachtet (Abbildung 8.21).

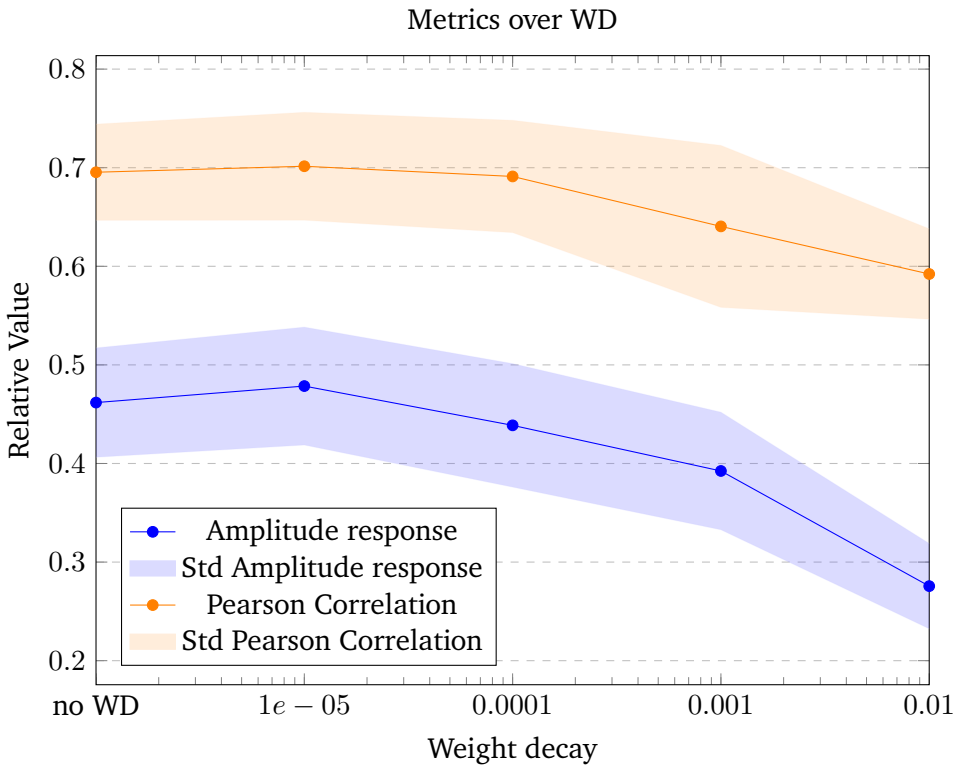



Abbildung 8.21: Bei einem WD von $1e-05$ ist die AR am höchsten. Die Verbesserung in der Korrelation ist sehr gering. Die Performance lässt sich durch das Hinzufügen von WD also in Bezug auf die AR um ca. $4\,\%$ verbessern. Jedoch darf der Parameter nicht zu hoch gewählt werden, da die Performance ab $0.001$ stark abnimmt.

Es ist zu erkennen, dass der WD Parameter bei etwa $1e-05$ eine Verbesserung der AR um $4\,\%$ im Vergleich zu keiner solchen Regularisierung erreichen kann. Jedoch kann sich das Ergebnis bei zu hoch gewähltem WD Parameter stark verschlechtern.

### 8.3.4 Optimale Lerarning Rate

In diesem Abschnitt wird der Einfluss der gewählten LR untersucht (vergl. Abschnitt 3.3.2). Um die Optimale LR zu finden, wurde das Modell $15$ Mal ohne Augmentation und WD für $60$ Epochen mit $\alpha = [1e-05, 0.0001, 0.001, 0.01]$ trainiert und die Pearson Korrelation sowie die AR betrachtet. Es wird ebenfalls Early Stopping mit einer patience von $20$ genutzt. Die Ergebnisse sind in Abbildung 8.22 zu sehen.

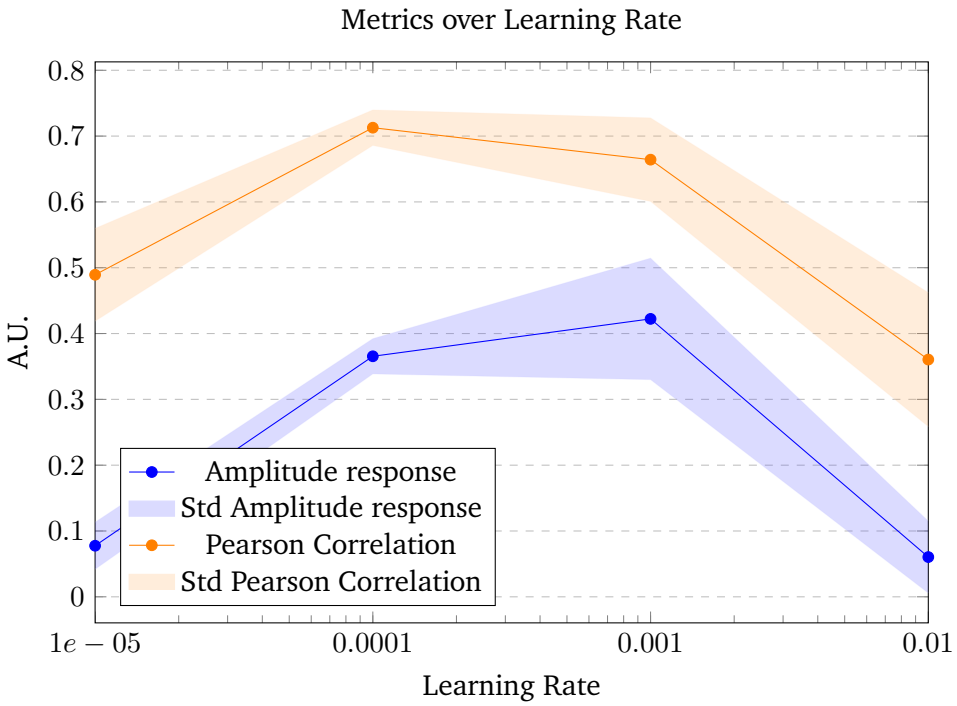



Abbildung 8.22: Bei einer LR von $\alpha = 0.0001$ ist die Korrelation mit $0.72$ am höchsten und bei $0.001$ ist die AR mit $0.42$ am höchsten.

Es ist zu erkennen, dass eine LR von $0.0001$ in Bezug auf die Pearson Korrelation am besten geeignet ist. Bei Betrachtung der AR ist jedoch $0.001$ besser geeignet. Das Optimum liegt also vermutlich zwischen $0.0001$ und $0.001$, wobei $0.001$ eine geringere Trainingsdauer aufweist.
Zu hohe oder zu geringe LR führen, wie vermutet, zu einer schlechteren Performance der Modelle (vergl. Abschnitt 3.3.2).

### 8.3.5 Einfluss Dimensionality Reduction

Aufgrund der in Abschnitt 7.2 erwähnten möglichen Vorteile, wird der Einfluss einer Dimensionsreduzierung auf die Modellperformance untersucht. Dafür wird das Modell aus Abschnitt 8.3.1 zehn Mal mit $n = [1024, 512, 128, 64, 32]$ für $60$ Epochen trainiert und Korrelation sowie AR betrachtet (Abbildung 8.24). In Abbildung 8.23 ist die kumulativ erklärte Varianz der ersten $n$ Hauptkomponenten zu sehen.

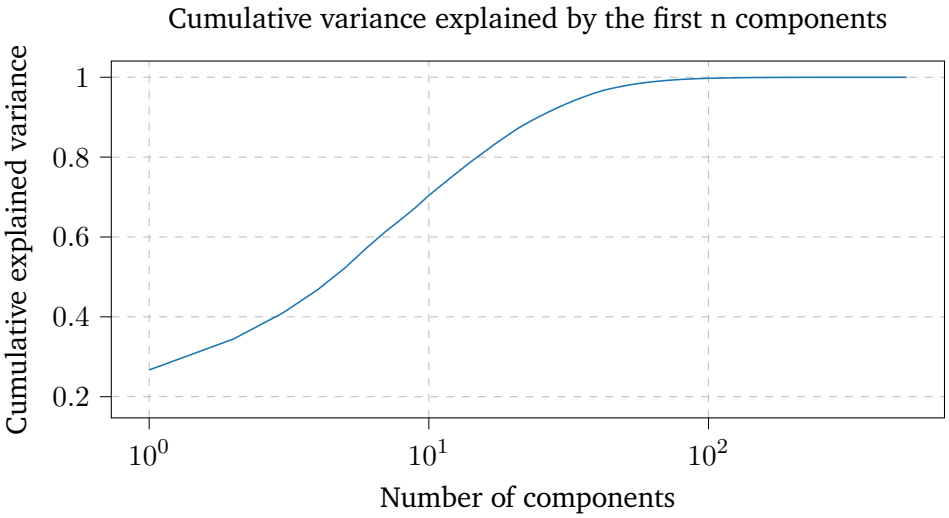



Abbildung 8.23: Kumulativ erklärte Varianz durch die ersten $n$ Hauptkomponenten.

Nach den ersten $100$ Hauptkomponenten ist etwa $99\,\%$ der Varianz in den Daten abgedeckt.

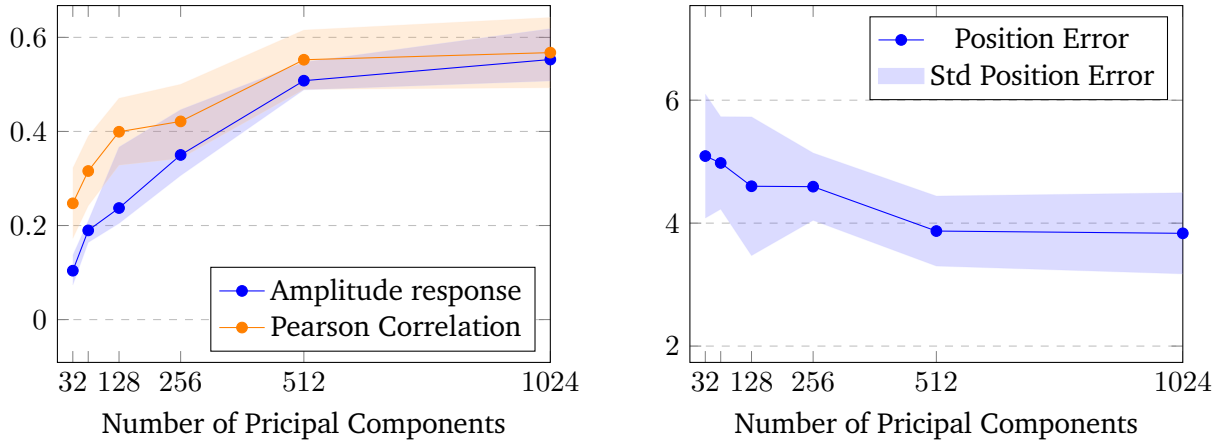



Abbildung 8.24: Es ist zu erkennen, dass die Korrelation und AR mit abnehmender Feature Zahl abnimmt. Bei einer Halbierung der Features von $1024$ auf $512$ ist eine Reduzierung der Korrelation von $2\,\%$ und eine Reduzierung der AR von $10\,\%$ zu beobachten. Der PE steigt bei einer Halbierung der Features um $2\,\%$

Es ist also möglich, mit einer geringfügigen Reduzierung der Performance des Modells die Anzahl der Features von $1024$ auf $512$ zu halbieren.

### 8.3.6 Performance mit optimalen Parametern

Abschließend wird ein Modell mit den in den vorherigen Abschnitten ermittelten optimalen Parametern trainiert. Dabei wird mit WD von $1e-05$ regularisiert und keine Dimensionsreduzierung vorgenommen.
Es wird ein Modell mit Dropout Layern mit $p = 10\,\%$ mit einer LR von $0.0001$ und den folgenden Augmentationen trainiert:

Tabelle 8.1: Augmentation Schritte für das Modell.

| Augmentierung | Augmentierte Kopien / Filter | Nr. of Samples |
|---|---|---|
| Default | - | 4 145 |
| Noise ($\lambda = 0.02$) | 5 | 24 870 |
| Rotations | 5 | 149 220 |
| Gauss | 4 | 149 220 |

Durch die Noise- und Rotation Augmentation wird die Anzahl der Samples von $4\,145$ auf $149\,220$ erhöht. Durch eine Filterung mit $4$ Gauss Tiefpass Filtern, werden anschließend scharfe Kanten geglättet.

Es wird insgesamt für $100$ Epochen trainiert und Early Stopping mit einer patience von $20$ genutzt. Die Metriken am Testset sind in Abbildung 8.25 zu sehen.

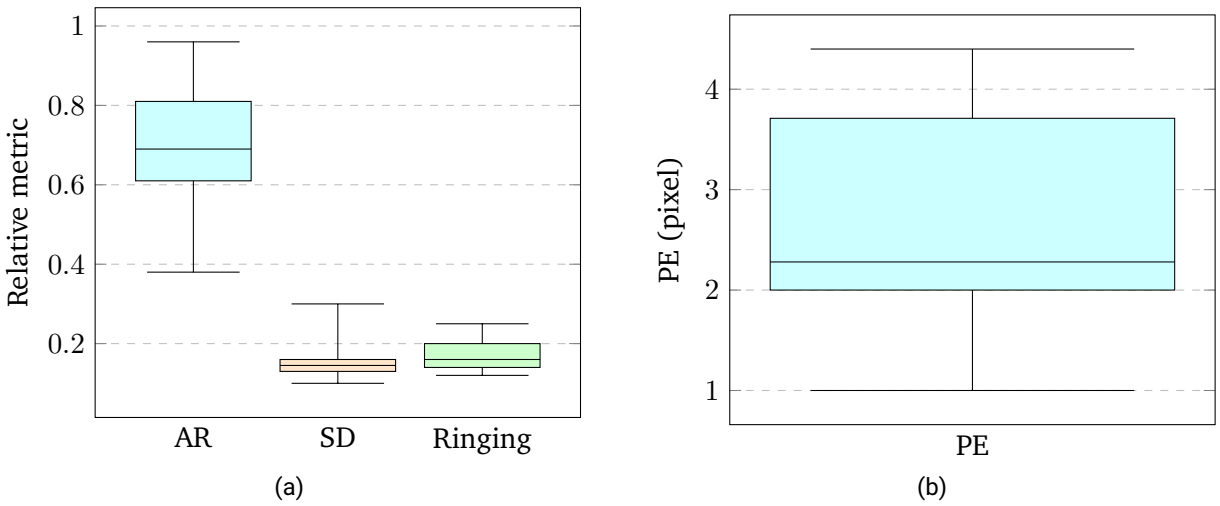



Abbildung 8.25: Das Modell mit den optimal ermittelten Parametern. Es besitzt eine Median AR von $0.69$ was etwa $23\,\%$ über dem unoptimierten Modell aus Abschnitt 8.3.1 liegt. Die SD ist etwa $20\,\%$ geringer und das Ringing ist ähnlich hoch. Der PE ist mit $2.3\,\mathrm{Pixel}$ fast halbiert.

Das optimierte Modell verfügt über eine hohe Median AR von $0.69$, wenig SD mit einem Median von $0.145$ und ebenfalls wenig Ringing mit einem Median von $0.165$. Der PE besitzt einen Median von $2.3\,\mathrm{Pixel}$, was mit $2.96\,\frac{\mathrm{mm}}{\mathrm{pixel}}$ etwa $6.1\,\mathrm{mm}$ entspricht.
Die finale Modellarchitektur mit den gewählten Parametern ist in den Performance Metriken besser als einfache lineare oder KNN Modelle. Insbesondere bei geringer Dataset Größe kann die Performace durch Augmentation deutlich gesteigert werden.

### 8.3.7 Unterschiedliche Target-Materialien

Um die Generalisierungsfähigkeit auf andere Materialien und Szenarien zu bewerten, wird ein Testset mit einem $40\,\mathrm{mm}$ Target aus einer Kartoffel verwendet (Abbildung 8.26). Dafür wurde diese mittels einer Stanze in die gleiche Form wie das PLA Target geschnitten. Die Kartoffel weist als biologisches Material, eine niedrigere Impedanz als das mit Luft gefüllte PLA-Target auf.

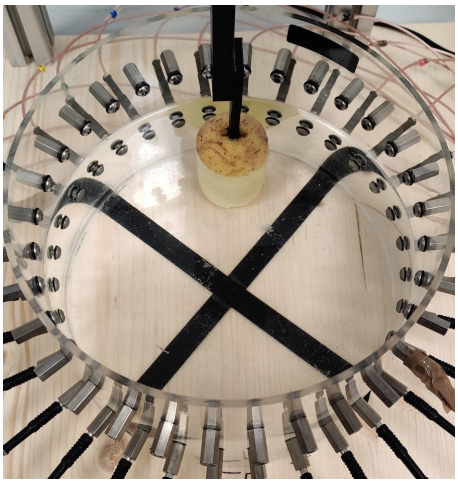


Abbildung 8.26: Aufnahme des Testsets mit Target aus einer Kartoffel. Die Kartoffel wurde mit einer Stanze zu einem $40\,\mathrm{mm}$ Zylinder ausgestanzt und mit einer Halterung am Positioniersystem befestigt.

Es wurden insgesamt $240$ Samples aufgezeichnet und anschließend in Abbildung 8.27 die Performance Metriken, mit dem Modell aus Abschnitt 8.3.6, ausgewertet.

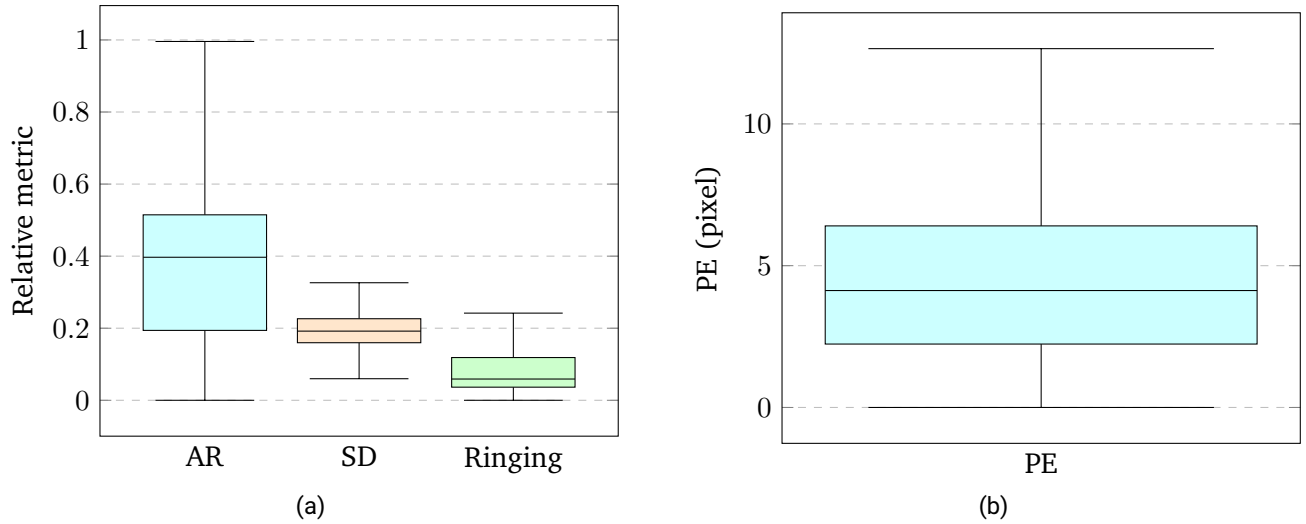



Abbildung 8.27: Die Performance Metriken am Testset mit organischem Material fallen schlechter aus als an dem PLA Testset. Die Median AR ist um $42\,\%$ reduziert und SD und PE sind um etwa $50\,\%$ bzw. $80\,\%$ angestiegen.

Allgemein lässt sich sagen, dass das Modell in der Lage ist, Targets mit anderer Impedanz zu erkennen. Dabei fällt auf, dass die Performance jedoch schlechter ausfällt als bei dem PLA Target Testset.

# 9 Ergebnisse und Diskussion Absolute EIT

Im folgendem Kapitel werden unterschiedliche Ansätze für die Bildrekonstruktion mittels absoluter EIT implementiert und verglichen. Bei der absoluten EIT wird die Rekonstruktion ohne Referenz Frame erzeugt (vergl. Abschnitt 2.3). Dafür wird der in Abschnitt 7.5 beschriebene Datensatz zum Training genutzt. Dabei ist das Ziel zu untersuchen, ob die Algorithmen in der Lage sind, auch ohne Referenz eine Rekonstruktion zu erzeugen. Das Testset ist dabei wieder eine Anordnung der Elektroden, welche nicht zum Training genutzt wurde und besitzt $973$ Samples.

## 9.1 Artificial Neural Network

Es wird die gleiche Netzwerkarchitektur mit Dropout Layern mit $p = 10\,\%$ wie bei den tdEIT Daten verwendet. Dafür wird die Input-Größe der ersten Layer entsprechend angepasst. Im Fall der mfEIT steigt die Dimension der Eingangsvektors $\vec{V}$ je nach Anzahl der verwendeten Frequenzen $n_{freq}$ an:

$$\dim(\vec{V}) = 2 \cdot n_{freq}(n_{el}^2). \tag{9.1}$$

Um den komplexen Anteil abzubilden, werden Real- und Imaginärteil als zwei separate Eingänge hinzugefügt. Im Fall von drei verwendeten Frequenzen ist $\dim(\vec{V}) = 6\,144$. Die Struktur des Netzwerks ist in Abbildung 9.1 zu sehen.

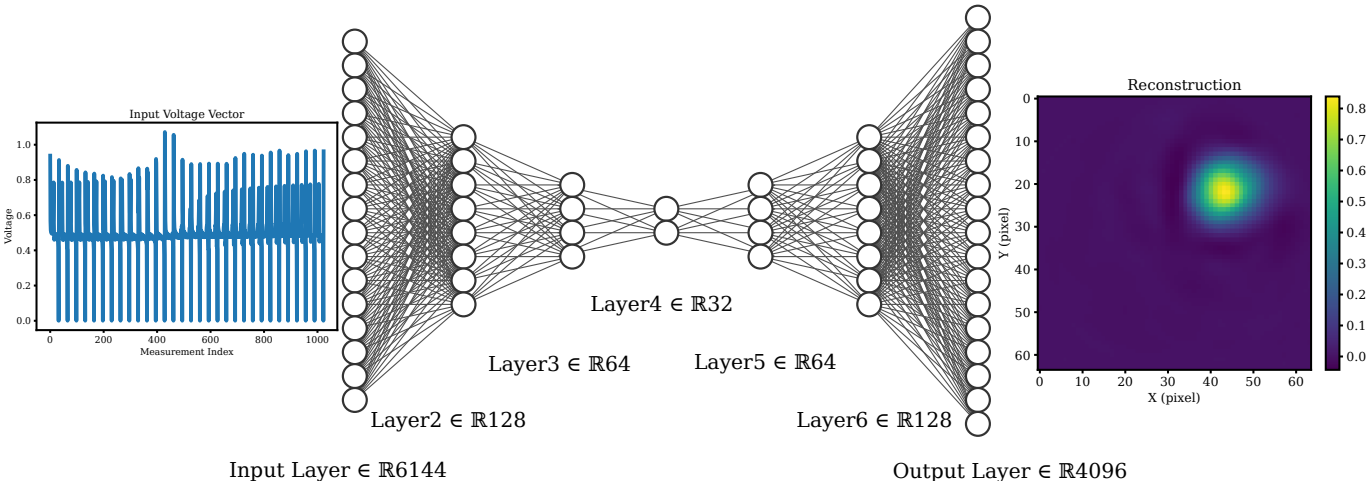



Abbildung 9.1: Schematischer Aufbau des mfEIT ANN Modells. Die Dimension des Eingangs wurde entsprechend angepasst, aber der Rest des Netzwerks ist identisch zu dem Netzwerk aus Abschnitt 8.3.

### 9.1.1 Dimensionality Reduction

Beim Versuch, das Modell mit $\dim(\vec{V}) = 6.144$ zu trainieren, tritt keine Konvergenz des Losses auf. Der Validation Loss beträgt nach $30$ Epochen noch mehr als $20$. Dies kann daran liegen, dass für mehr Inputs auch mehr Daten notwendig wären (vergl. Kapitel 4).
Deshalb wird im Voraus mittels einer PCA die Dimension der Eingangsdaten auf die ersten $256$ Hauptkomponenten reduziert, wodurch über $99\,\%$ der Variation in den Daten abgebildet ist.
Da die Modelle nicht deterministisch sind, wurde das Modell $n = 10$ Mal trainiert. Dabei ist in Abbildung 9.2 zu erkennen, dass das Modell nun erfolgreich zu einer Lösung konvergieren kann.

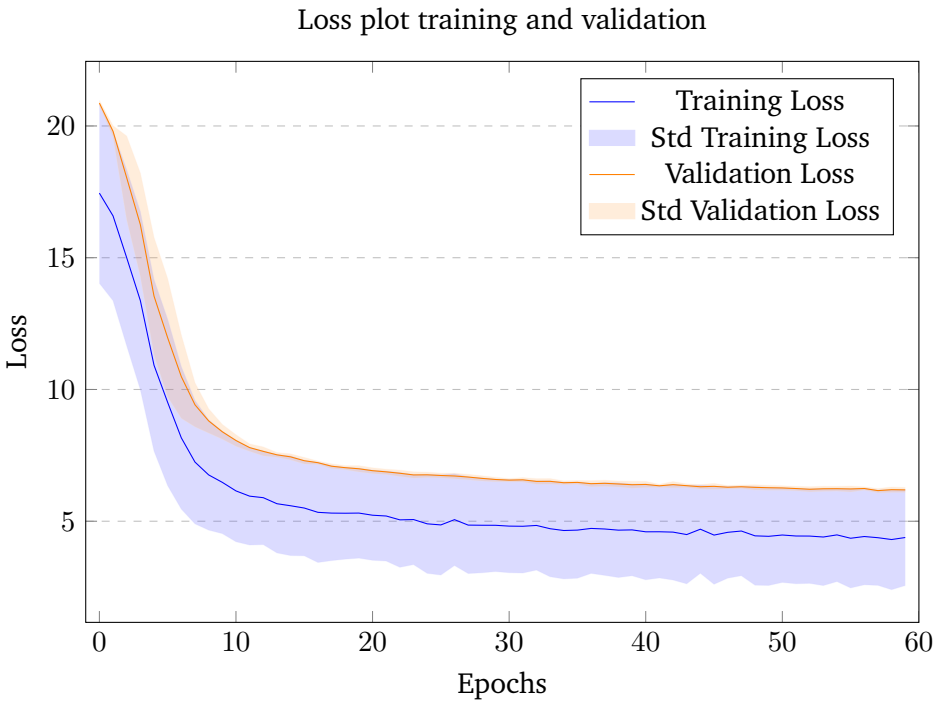



Abbildung 9.2: Das Modell wurde zehn Mal mit $60$ Epochen und Early Stopping trainiert. Es ist zu erkennen, dass das Modell durch die geringere Dimensionalität des Eingangs zu einer Lösung konvergieren kann.

Ab einer Anzahl von $4096$ Inputs fängt das Modell an zu konvergieren. Jedoch dauert dies lange, wobei das Training nach $200$ Epochen immer noch einen Loss über $10$ ergibt. Um die optimale Anzahl an Hauptkomponenten zu finden, wird das Modell zehn Mal mit $n = [1024, 512, 128, 64]$ für je $60$ Epochen trainiert. Es wird die AR, Pearson Korrelation und der PE betrachtet (Abbildung 9.3).
Es ist zu erkennen, dass mit geringer Anzahl an verwendeten Hauptkomponenten die AR und Korrelation abnehmen. Bis zu $512$ Hauptkomponenten bleibt die AR über $0.68$ und die Korrelation bei $0.7$. Der PE verändert sich jedoch wenig und liegt bei etwa $2.9\,\mathrm{Pixel}$.

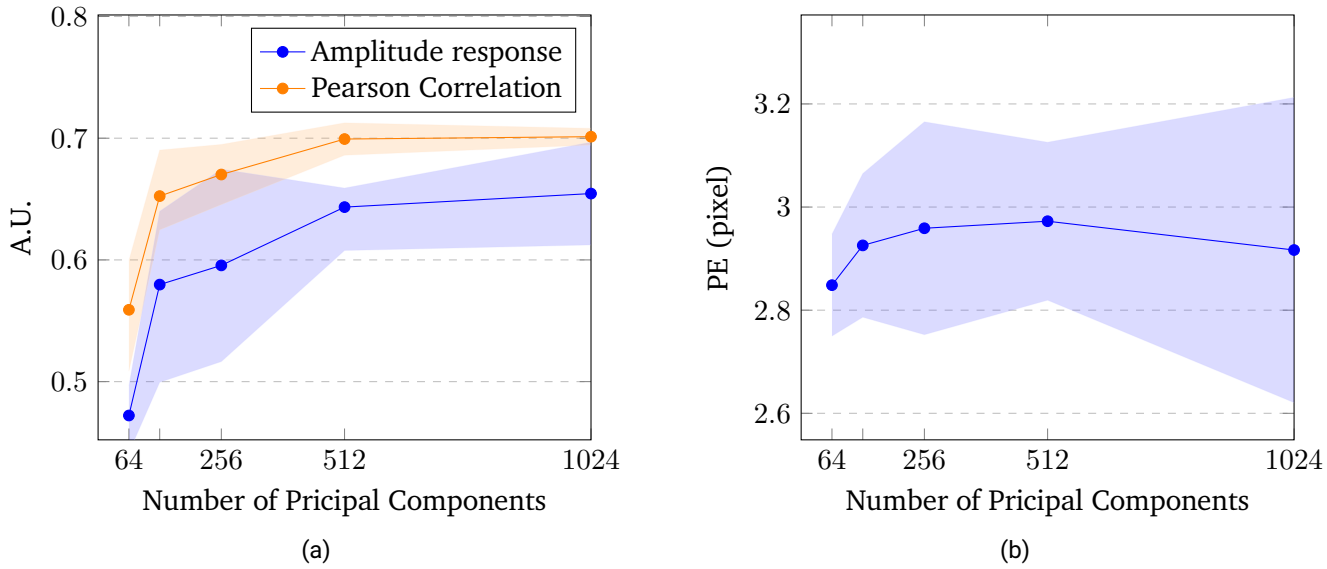



Abbildung 9.3: Je weniger Hauptkomponenten verwendet werden, desto geringer fällt die Korrelation und AR aus. Der PE steigt erst mit weniger Hauptkomponenten, sinkt gegen Ende, jedoch wieder leicht ab. Dies kann daran liegen, dass insgesamt weniger Rekonstruktionen erfolgreich waren und sich diese hauptsächlich am Rand des Tanks befinden.

Bei Verwendung von $512$ Hauptkomponenten wird mit den hier getroffenen Einstellungen eine Korrelation von über $0.7$ und eine AR von $0.68$ erreicht. Die Kurven können bei anders gewählten Hyperparametern auch höher oder geringer ausfallen. Jedoch kann ein genereller Trend in der Abhängigkeit der Hauptkomponenten erkannt werden. Dabei erscheint $512$ als ein guter Kompromiss zwischen Trainingsdauer und Performance.

### 9.1.2 Einfluss der Normierung

Im Vergleich zur tdEIT sind die absoluten EIT Frames nicht auf eine Referenz $\vec{V}_0$ bezogen. Deshalb kann es sinnvoll sein, eine eigene Normierung vorzunehmen. Eine Normierung kann die Performance verbessern und den Trainingsprozess beschleunigen.
Zum Vergleich wird das Modell mit und ohne Normierung jeweils zehn Mal für $60$ Epochen trainiert. Die Entwicklung des Losses ohne Normierung ist in Abbildung 9.4 zu sehen. Es ist zu erkennen, dass das Modell über $12$ Epochen benötigt, bis der Validation Loss unter $10$ liegt. Aufgrund der Augmentierung und der Dropout Layer kann es passieren, dass das Modell während am Evaluationset besser abschneidet als an den Trainingsdaten, da zur Evaluierung keine Dropouts aktiv sind.

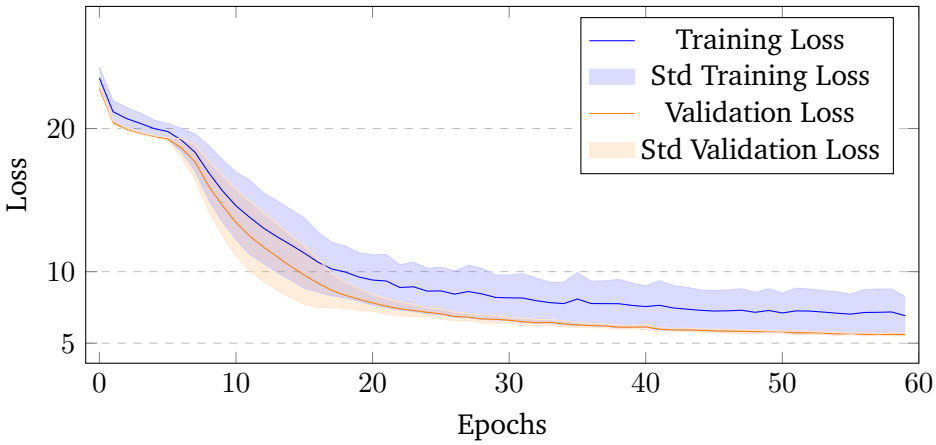



Abbildung 9.4: Es ist zu erkennen, dass die Modelle anfangs nur langsam konvergieren. Es sind über $12$ Epochen nötig, bis der Validation Loss unter $10$ liegt.

Nun wird im Anschluss ein Modell mit folgender Normierung getestet:

$$V_{1-norm} = \frac{V_1 - \text{median}(V_1)}{\text{median}(V_1)}. \tag{9.2}$$

Nach der Normierung ist in Abbildung 9.5 zu erkennen, dass der Trainingsfortschritt, insbesondere in den ersten $10$ Epochen, schneller vorangeht.

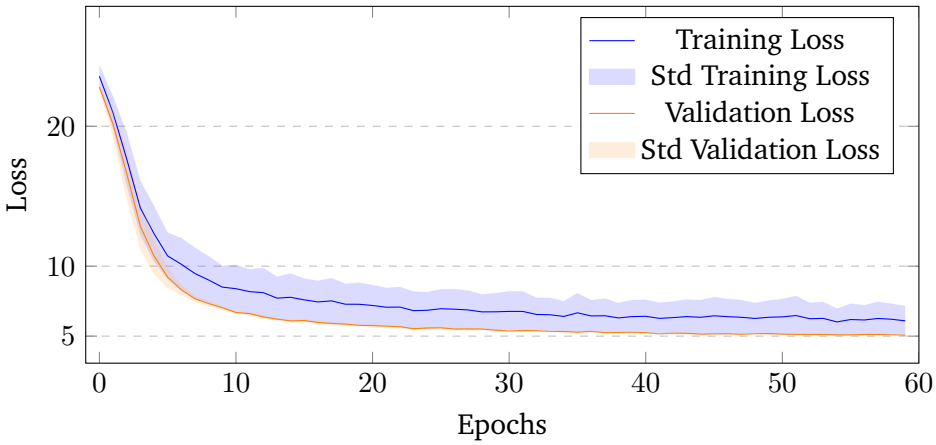



Abbildung 9.5: Nach der Normierung ist zu erkennen, dass die Modelle deutlich besser konvergieren und der Validation Loss bereits nach etwa $5$ Epochen unter $10$ liegt.

Die Geschwindigkeit des Trainings kann also durch eine Normierung der EIT-Frames erhöht werden. Der Loss konvergiert ohne Normierung nach $60$ Epochen gegen $5.5$ und mit Normierung gegen $5$. Die finale Performance unterscheidet sich also nur geringfügig.

### 9.1.3 Performance

Es wird ein Modell mit Normierung und den ersten $512$ Hauptkomponenten der PCA für $100$ Epochen mit Early Stopping mit einer patience von $20$ Epochen trainiert. Anschließend werden die Performance Metriken am Testset bestimmt (Abbildung 9.6).

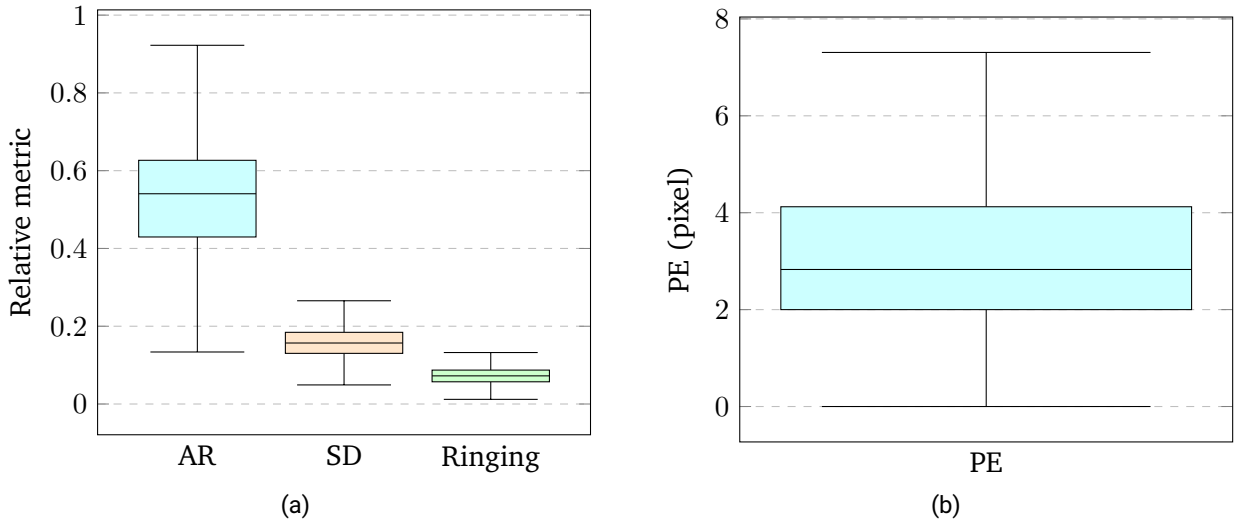



Abbildung 9.6: Metriken des ANN Modells. Es verfügt über eine Median AR von $0.54$ und eine Median SD von $0.16$ . Auch der PE ist mit etwa $2.8\,\mathrm{Pixel}$ vergleichbar mit den tdEIT Modellen.

Dabei ergibt sich eine homogenere Verteilung der AR bis zur Mitte des Tanks (Abbildung 9.7).

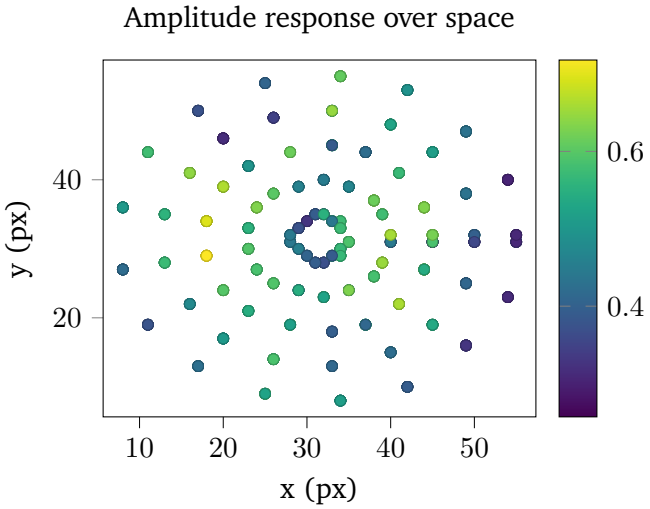



Abbildung 9.7: Das ANN Modell mit den mfEIT Datensatz verfügt über eine homogenere Verteilung der AR bis zur Tankmitte als in Abschnitt 8.3.

Das mfEIT Modell ist in der Lage, das Target an beliebigen Stellen im Tank zu rekonstruieren.
Jedoch besteht noch ein Bias auf die Target-Größe von $40\,\mathrm{mm}$. Im nächsten Abschnitt wird versucht, diesen Bias zu umgehen.

### 9.1.4 Unterschiedliche Target-Größen

Bis jetzt bestehen die Trainingsdaten ausschließlich aus Targets mit einem Durchmesser von $40\,\mathrm{mm}$. In allgemeinen Körpern, die untersucht werden sollen, können jedoch Impedanzanomalien unterschiedlicher Größe vorkommen.
Um die Generalisierungsfähigkeit der Modelle zu verbessern, werden dem Dataset Samples mit unterschiedlichen Target-Größen hinzugefügt. Da das Modell nun nicht nur die Position des Targets, sondern auch die Größe unterscheiden muss, werden mehr Daten benötigt. Zum einen wird ein Target mit einem Durchmesser von $20\,\mathrm{mm}$ hinzugefügt und zusätzlich auch eins mit einem größeren Durchmesser von $60\,\mathrm{mm}$.
Dadurch steigt der Datensatz auf $9695$ Samples mit der folgenden Verteilung:

Tabelle 9.1: Verteilung der Target-Größe im mfEIT Datensatz.

| $20\,\mathrm{mm}$ | $40\,\mathrm{mm}$ | $60\,\mathrm{mm}$ |
|---|---|---|
| 4744 | 4711 | 402 |

Es hat sich gezeigt, dass mehr Samples des Kleineren als von dem größeren Target benötigt werden, um eine erfolgreiche Rekonstruktion zu erreichen. Dies kann daran liegen, dass es weniger mögliche Platzierungen gibt, oder einen eindeutigeren Ausschlag im Spannungsvektor erzeugt und somit einfacher gelernt wird.
Das Modell wird mit dem neuen Datensatz trainiert und überprüft, ob es anschließend in der Lage ist unterschiedlich große Targets zu rekonstruieren. Da der Phantom-Tank einen Durchmesser von $190\,\mathrm{mm}$ hat und die Bilder eine Auflösung von $(64 \times 64)$ Pixel, ergibt sich ein Umrechnungsfaktor von etwa $2.96\,\frac{\mathrm{mm}}{\mathrm{pixel}}$.
In Abbildung 9.8 wurden das Modell qualitativ an unterschiedlichen Targets evaluiert.

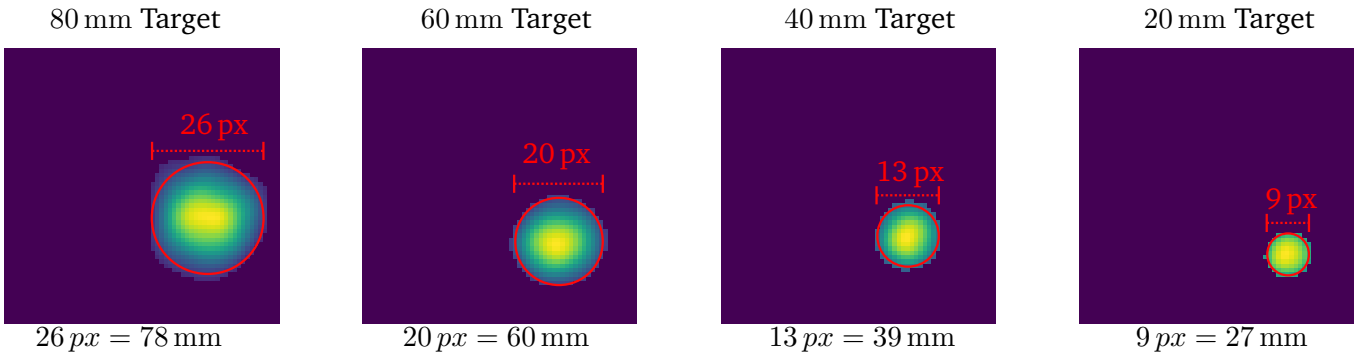



Abbildung 9.8: Es ist zu erkennen, dass das Modell anschließend in der Lage ist unterschiedlich große Targets im Tank zu rekonstruieren. Auch Targets mit $d = 80\,\mathrm{mm}$, welche nicht in den Trainingsdaten vorhanden sind, werden richtig rekonstruiert. Targets mit $d = 20\,\mathrm{mm}$ ist die kleinste Größe, welche durch das System aufgelöst werden kann, wobei diese etwas zu groß abgebildet werden.

Durch das Hinzufügen von Samples mit unterschiedlichen Größen ist das Modell in der Lage, dies bei der Rekonstruktion abzubilden. Auch Targets mit $d = 80\,\mathrm{mm}$, welche nicht in den Trainingsdaten vorhanden sind, werden richtig rekonstruiert. Es wurde auch ein Target mit $d = 10\,\mathrm{mm}$ evaluiert. Die kleinste rekonstruierte Target Größe ist dabei $20\,\mathrm{mm}$. Es ist denkbar, dass mit vorhanden Trainingsdaten auch $d = 10\,\mathrm{mm}$ rekonstruiert werden könnte. Die Auflösung des Systems ergibt sich nach Gleichung (5.6) zu:

$$RES = \sqrt{\frac{A_q}{A_0}} = \sqrt{\frac{20\,\mathrm{mm}}{190\,\mathrm{mm}}} \approx 0,324. \tag{9.3}$$

### 9.1.5 Superposition Augmentation

In diesem Abschnitt wird untersucht, ob die in Abschnitt 7.1.3 beschriebene Superposition Augmentation in der Lage ist, die Modell Performance zu verbessern und die Generalisierungsfähigkeit zu steigern. Es wird hierbei das Dataset mit den unterschiedlichen Target-Größen genutzt.
Dafür wird das Dataset um drei augmentierte Kopien pro Sample erweitert. Dabei hat jede Kopie zwischen null und drei Targets im Bild. In Tabelle 9.2 können die verwendeten Augmentierungen und die sich daraus ergebende Sample Anzahl betrachtet werden.

Tabelle 9.2: Augmentation Schritte für das Modell mit Superposition Augmentation.

| Augmentierung | Augmentierte Kopien / Filter | Nr. of Samples |
|---|---|---|
| Default | - | 9695 |
| Noise ($\lambda = 0.02$) | 4 | 81598 |
| Superposition | 3 | 244 794 |
| Gauss | 4 | 244 794 |

In Abbildung 9.9 sind oben und unten jeweils Rekonstruktion der identischen Szene dargestellt. Die Bilder der oberen Reihe (a) sind von dem Modell ohne Superposition Augmentation. Die untere Reihe (b) ist mit Superposition Augmentation. Es ist zu erkennen, dass das Modell ohne die Augmentation nicht in der Lage ist, mehrere Targets im Tank zu erkennen. Dabei wird vom Modell präferiert das Target abgebildet, das sich weiter außen im Tank befindet.
Das Modell, welches jedoch die Augmentierung nutzt, kann mehrere Targets im Tank rekonstruieren. Dabei fällt auf, dass die Targets einen gewissen Mindestabstand aufweisen müssen, bevor sie nicht mehr differenziert werden und zu einem verschmelzen.

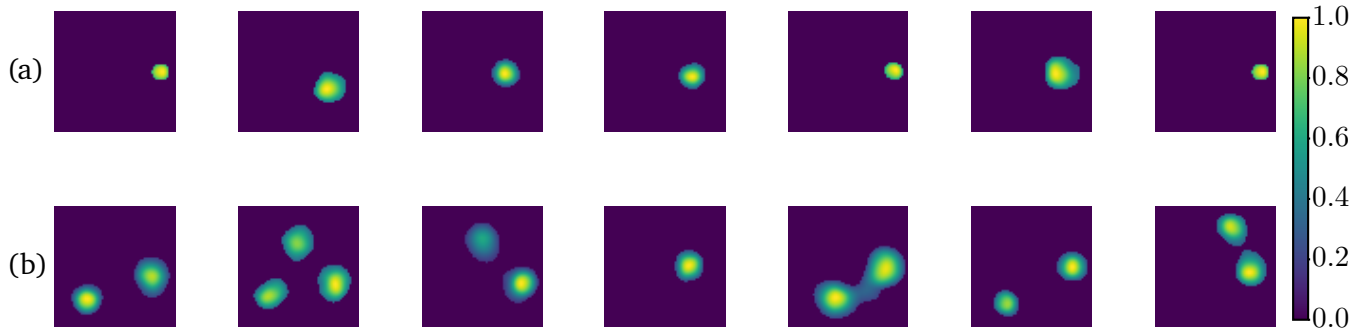



Abbildung 9.9: Die Bilder der oberen Reihe (a) sind von dem Modell ohne Superposition Augmentation. Die untere Reihe (b) ist mit Superposition Augmentation. Es befinden sich jeweils ein bis drei Targets im Tank. Es ist zu erkennen, dass das Modell mit der Augmentation in der Lage ist, mehrere Targets im Tank zu erkennen.

Somit ist qualitativ gezeigt, dass das Modell mit Superposition Augmentation besser auf komplexere Szenen mit mehreren Targets im Tank generalisieren kann. Wenn sich die Targets jedoch näher positioniert sind, verschmelzen sie in der Rekonstruktion und sind nicht mehr differenzierbar.
Dies liegt vermutlich an der Nichtlinearität der EIT, welche nicht korrekt durch die einfache Superposition der Samples abgebildet werden kann.

In Abbildung 9.10 sind die Performance Parameter am Testset abgebildet.

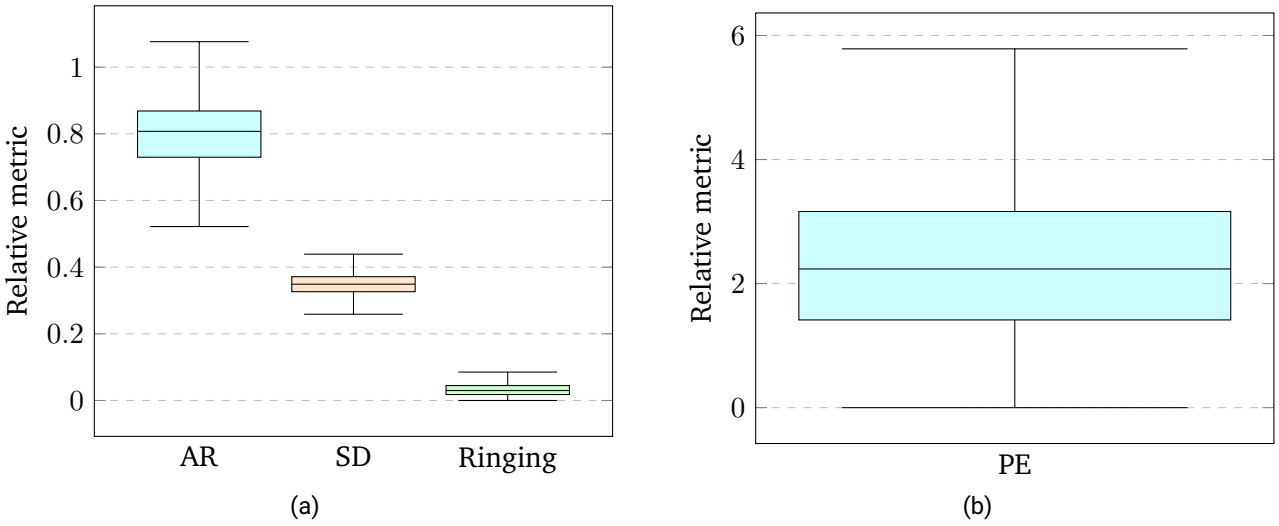



Abbildung 9.10: Das Modell mit Superposition Augmentation besitzt eine $50\,\%$ höhere AR, aber auch über eine etwa doppelt so hohe SD. Dies liegt daran, dass die Targets im Vergleich zu den vorherigen Modellen immer etwas größer rekonstruiert werden, als sie eigentlich sind.

Es ist zu erkennen, dass die AR höher ist als bei dem Modell ohne die Augmentierung. Dafür ist aber die SD vergleichsweise höher, was daran liegt, dass die Targets mit diesem Modell immer etwas größer rekonstruiert werden, als sie in Wirklichkeit sind.
Es scheint also einen Kompromiss zwischen besserer Generalisierung auf mehrere Targets und der SD zu geben. Das Modell mit der Superposition Augmentation ist nicht mehr ausschließlich auf Kreise fokussiert, worauf die Metrik der SD basiert. Somit könnte es sich deshalb negativ auf die SD auswirken. In Abbildung 9.11 sind weitere beispielhafte Rekonstruktionen des Modells zu erkennen.

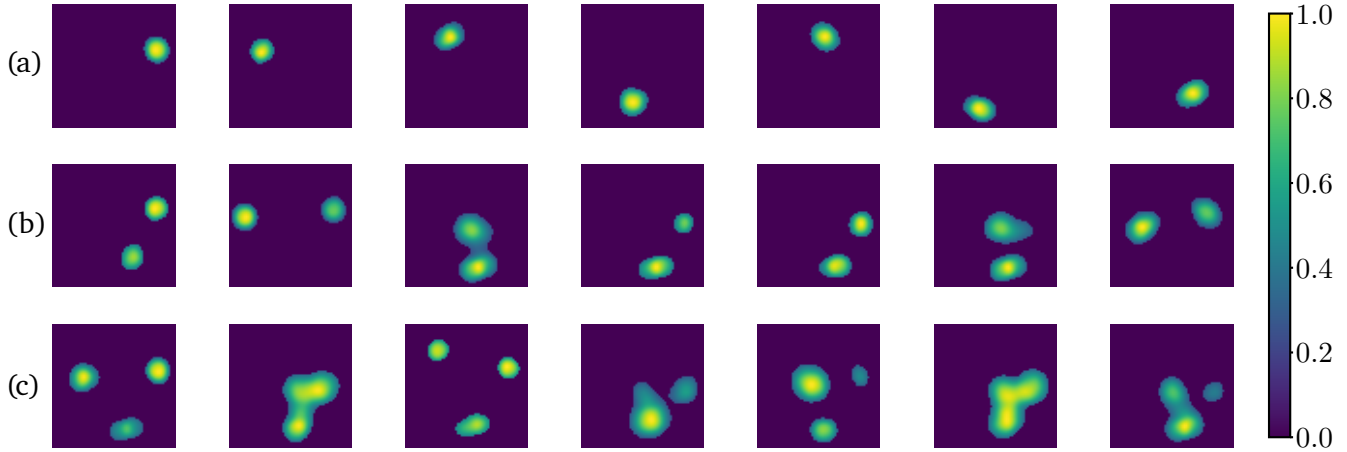
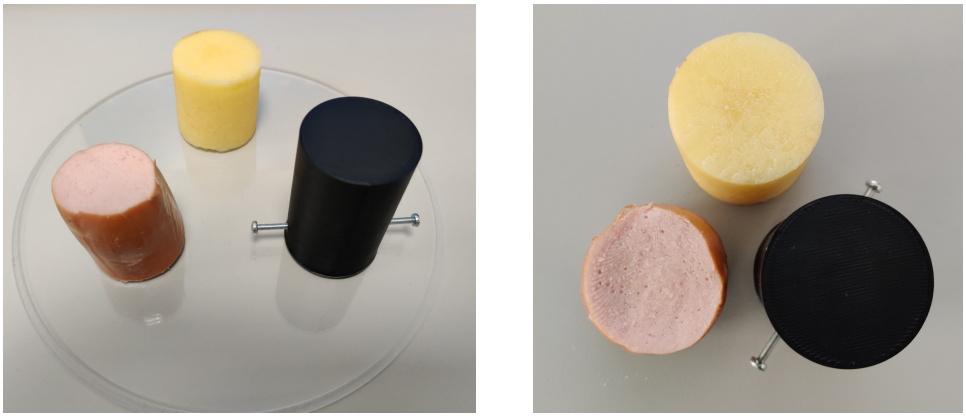



Abbildung 9.11: Rekonstruktionen des Modells mit Superposition Augmentation mit einem (a) zwei (b) und drei (c) Targets. Trotz der Nichtlinearität der EIT, ist es häufig möglich, die Targets zu differenzieren. Wenn sie sich jedoch zu nahe kommen, verschmelzen sie zu einem Objekt in der Rekonstruktion.

Durch die Superposition Augmentation kann das Modell besser auf komplexere Szenen angewendet werden. Jedoch geht dadurch Performance in der SD Metrik verloren.

### 9.1.6 Unterschiedliche Target-Materialien

In diesem Abschnitt wird qualitativ untersucht, ob das Modell in der Lage ist, auch Materialien mit anderer Impedanz zu rekonstruieren. Dafür wurden zusätzlich wieder das Target aus Kartoffel und eins aus Fleischwurst verwendet, um pflanzliche und tierische Zellen abzudecken (Abbildung 9.12).



(a) Side Ansicht (b) Top Ansicht

Abbildung 9.12: Zu sehen sind die verwendeten Targets aus Kartoffel, Fleischwurst und PLA. Alle haben einen Durchmesser von etwa $40\,\mathrm{mm}$. Bei den biologischen Targets wurden zum Vermessen BNC Tastköpfe an gegenüberliegenden Seiten in das Target gesteckt. Da dies beim PLA nicht möglich ist, wurden Schrauben als Elektroden verwendet.

Anschließend wurde mittels eines Impedanz-Spektrometers (ScioSpec ISX-3) die Impedanz der Materialien vermessen und in einem Bode Plot aufgetragen. Dabei ließ sich die Messung des PLA Targets nicht von der Open Circuit Messung unterscheiden. Die Amplitude lag dabei konstant bei etwa $2\,\mathrm{M\Omega}$.

In Abbildung 9.13 ist der Bode Plot des Kartoffel-Targets zu sehen.

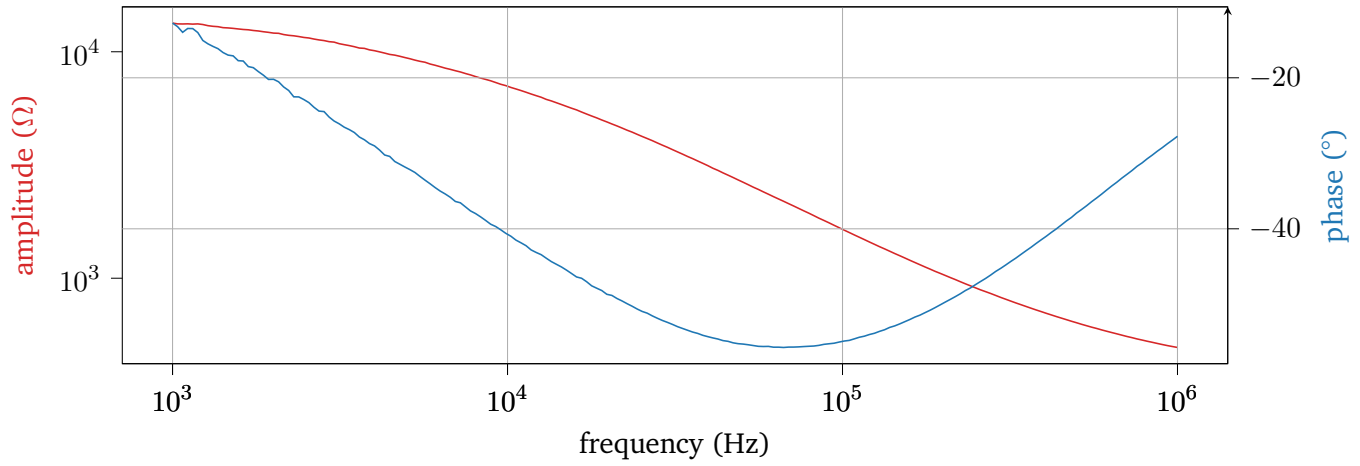



Abbildung 9.13: Die Amplitude nimmt mit steigender Frequenz von $1300\,\Omega$ auf $500\,\Omega$ ab. Die Phase startet bei etwa $-10°$ und fällt erst bis zu einer Frequenz von $74\,\mathrm{kHz}$ und steigt anschließend wieder auf $-28°$.

Im Vergleich zum PLA Target ist auch ein Abfall der Amplitude zu beobachten. Die Werte liegen zwischen $1300\,\Omega$ und $500\,\Omega$. Es hat sich also bestätigt, dass die Impedanz der Kartoffel deutlich geringer als die des PLA Targets ist (∼Faktor $10^3$).
Die Phase weist ebenfalls eine Frequenzabhängigkeit auf, was an kapazitiven und induktiven Effekten liegen kann. Sie startet bei etwa $-10°$ und fällt erst bis zu einer Frequenz von $74\,\mathrm{kHz}$ auf ein Minimum von $-56°$ und steigt anschließend wieder auf $-28°$.

In Abbildung 9.14 ist der Bode Plot des Fleischwurst-Targets zu sehen.

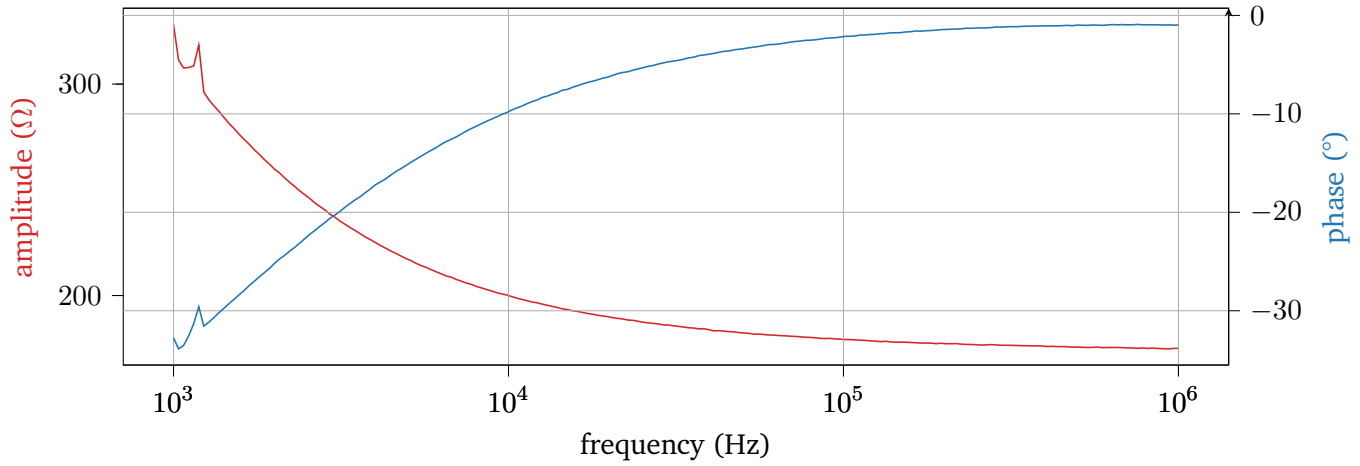



Abbildung 9.14: Das Fleischwurst-Target startet mit einer Amplitude von $340\,\Omega$ bei $1\,\mathrm{kHz}$ und sinkt dann bis auf $180\,\Omega$ bei $1\,\mathrm{MHz}$. Die Phase steigt währenddessen von $-32°$ auf $0°$. Damit ist die Impedanz geringer als die des PLA und Kartoffel-Targets.

Das Fleischwurst-Target besitzt eine noch geringere Impedanz als das Kartoffel-Target. Die Amplitude nimmt mit steigender Frequenz ab. Sie liegt zwischen $340\,\Omega$ und $180\,\Omega$. Dies kann mit dem kapazitiven Verhalten von Zellmembranen erklärt werden (vergl. Kapitel 1). Die Phase steigt von $-32°$ auf $0°$, was gegen ein rein kapazitives Verhalten spricht. Dabei muss beachtet werden, dass Fleischwurst ein verarbeitetes Fleischprodukt ist, wodurch sich die Zellstruktur im Vergleich zu frischen Zellen unterscheiden kann. Durch enthaltenes Salz kann sich ebenfalls die Impedanz ändern. Es ist auch zu berücksichtigen, dass die Bedingungen der Anschlussimpedanz nicht identisch waren und die Messung mittels einer Zwei-Leiter-Methode durchgeführt wurde.

Die Targets unterscheiden sich bei den ausgewählten Messfrequenzen $1\,\mathrm{kHz}$, $500\,\mathrm{kHz}$ und $1\,\mathrm{MHz}$ jedoch deutlich. Um die Generalisierungsfähigkeit des Modells zu evaluieren, werden die unterschiedlichen Targets im Phantom-Tank positioniert. Mit dem Fleischwurst-Target konnte keine erfolgreiche Rekonstruktion erreicht werden. Dies kann daran liegen, dass dieses auch die geringste Impedanz aufweist. Dadurch besteht ein zu geringer Kontrast zwischen Target und Hintergrund.

Die Kartoffel hingegen konnte erfolgreich rekonstruiert werden. Zur Evaluierung werden vier Szenen mit unterschiedlichen Target-Materialien und Kombinationen im Phantom-Tank erstellt (Abbildung 9.15).

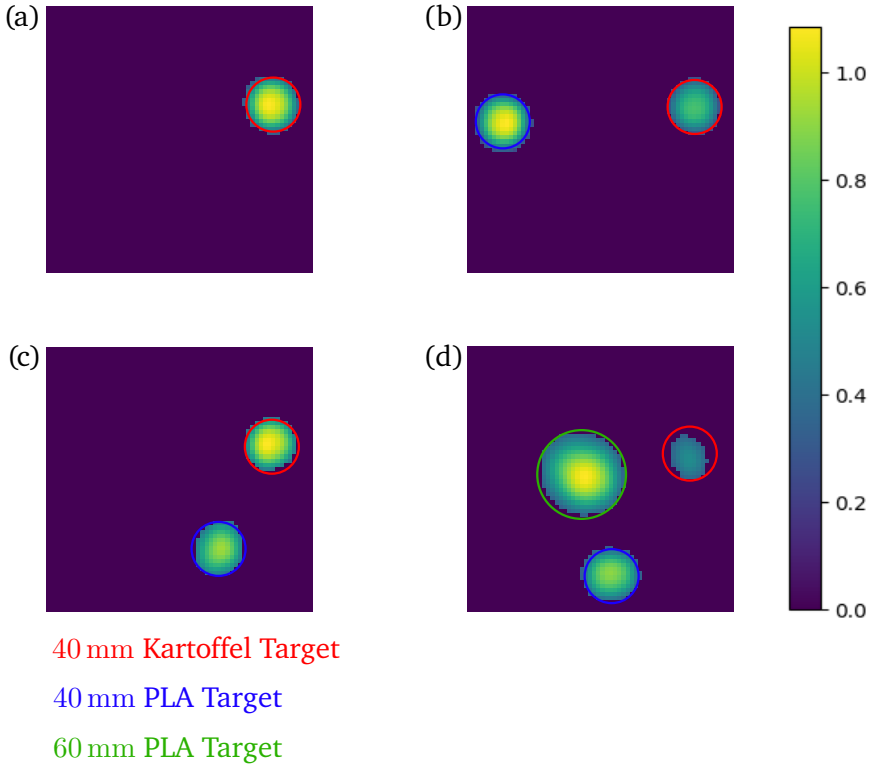



Abbildung 9.15: Es sind mehrere Szenen mit unterschiedlichen Größen und Materialien zu sehen. Dabei ist zu erkennen, dass das Modell auch unterschiedliche Materialien, die sich gleichzeitig im Tank befinden, erfolgreich rekonstruieren kann.

Im ersten Fall (a) befindet sich wie in Abbildung 8.26 eine ausgestanzte Kartoffel mit einem Durchmesser von $40\,\mathrm{mm}$ im Tank, welche erfolgreich rekonstruiert wird. Im zweiten (b) und dritten (c) Fall sind es die Kartoffel und das $40\,\mathrm{mm}$ Target aus PLA. Dabei lässt sich der Unterschied der Impedanz nicht in der Rekonstruktion erkennen. Mal hat die Kartoffel und mal das PLA die höheren Werte im Bild.
Im vierten Fall (d) wird zusätzlich ein $60\,\mathrm{mm}$ Target aus PLA hinzugefügt. Es ist zu erkennen, dass die Rekonstruktion der Kartoffel nun doch deutlich schwächer ist. Dies kann daran liegen, dass die anderen beiden Targets aufgrund ihrer höheren Impedanz einen höheren Kontrast im EIT-Frame erzeugen und somit stärker auf das Netzwerk einwirken können.

## 9.2 Lineare Regression

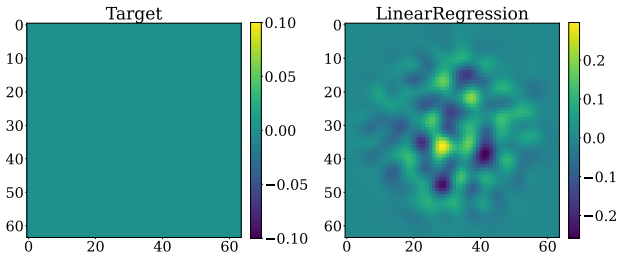
Zum Vergleich wird erneut ein Lineares Regression Modell trainiert. Als Datensatz wird zuerst ausschließlich das Dataset mit dem $40\,\mathrm{mm}$ Target verwendet. Für ein schnelleres Training wurde ebenfalls eine Dimensionsreduzierung vorgenommen. Dabei wurden als Input Features die ersten 512 Hauptkomponenten der PCA genutzt.

In Tabelle 9.3 können die verwendeten Augmentierungen betrachtet werden.

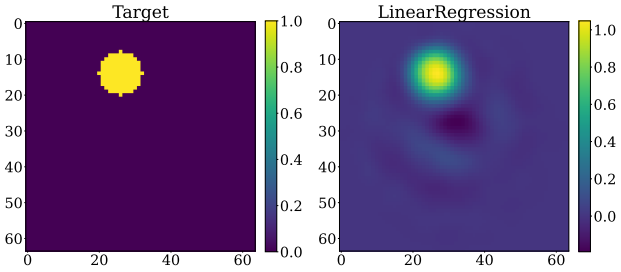
Tabelle 9.3: Augmentation Schritte für das Lineare Regression Modell.

| Augmentierung | Augmentierte Kopien / Filter | Nr. of Samples |
|---|---|---|
| Default | - | 9695 |
| Noise | 4 | 81598 |
| Superposition | 3 | 244 794 |
| Gauss | 4 | 244 794 |

In Abbildung 9.16 sind beispielhafte Rekonstruktionen aus dem Trainingsset zu sehen.




(a) Repräsentatives Beispiel für ein negativ Sample




(b) Repräsentatives Beispiel für ein positiv Sample

Abbildung 9.16: Beispiele für eine Rekonstruktion der mfEIT mittels der Linearen Regression. Es ist zu erkennen, dass die Regression ebenso wie bei der tdEIT in der Lage ist, eine visuell gute Rekonstruktion zu erzeugen.

Es ist zu erkennen, dass die Regression genau wie bei der tdEIT in der Lage ist eine visuell gute Rekonstruktion zu erzeugen. Jedoch ist wie bei der tdEIT der Fall, dass die Performance am Testset deutlich schlechter ausfällt (Abbildung 9.17).

Das Modell verfügt über eine Median AR von $0.49$, Median SD von $0.24$ und ein Median Ringing von auch $0.49$. Bei erfolgreicher Rekonstruktion beträgt der Median PE $2.8\,\mathrm{Pixel}$.
Die Performance ist insgesamt schlechter als die des ANN. Dabei ist insbesondere das Ringing um etwa das Fünffache höher.

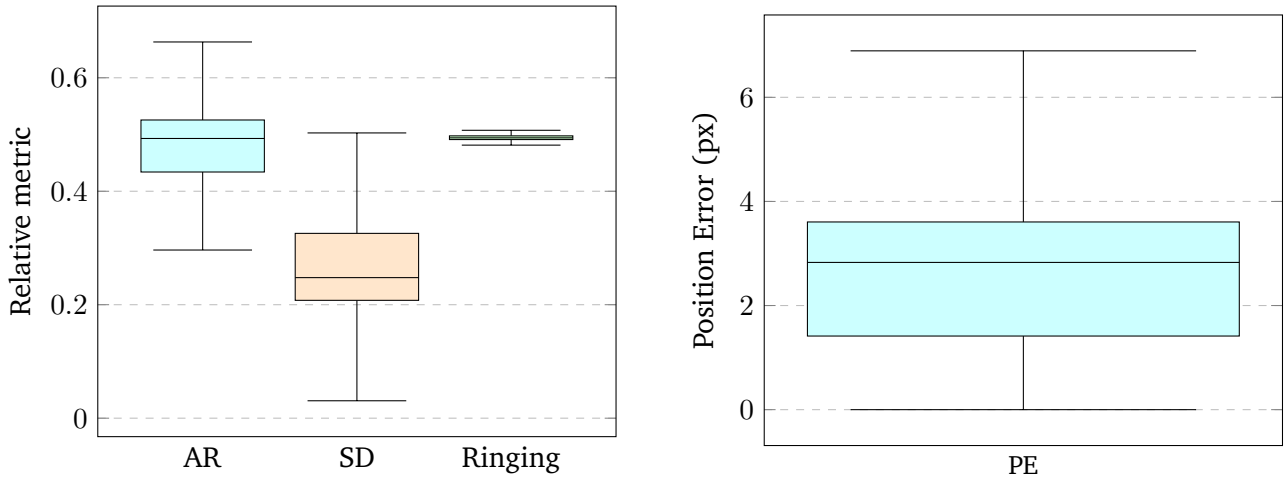



Abbildung 9.17: Metriken des Linear Regression Modells. Wie bereits im Fall der tdEIT, ist das Ringing vergleichsweise hoch, die AR ist jedoch besser. Die SD weist eine breitere IQR als die vorherigen Modelle auf. Bei erfolgreicher Rekonstruktion ist der PE vergleichbar gut wie bei den vorherigen Modellen.

Zur Evaluierung der Generalisierbarkeit auf mehrere Targets wird nun ebenfalls das Dataset mit den unterschiedlichen Target-Größen zum Training mit Superposition Augmentierung genutzt. Die Performance für Samples mit mehreren Targets lässt sich rein qualitativ evaluieren, da keine realen G.T. Samples existieren. Es werden Beispiele aus einem Testset mittel Superposition Augmentation erzeugt (Abbildung 9.18).

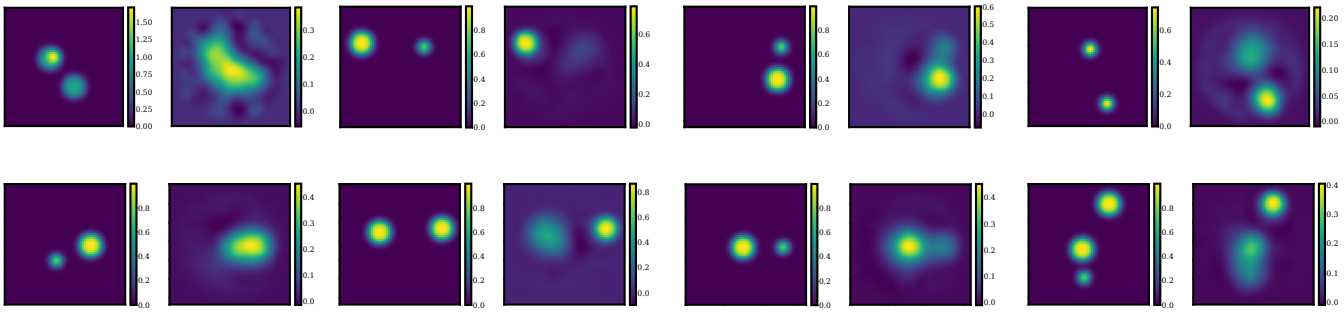


Abbildung 9.18: Zu sehen sind Beispiel Rekonstruktionen aus einem Testset mit Superposition Augmentierung. Links ist jeweils das künstlich generierte G.T. Bild und rechts die dazugehörige Rekonstruktion des Linear Regression Modells. abei wirkte die Rekonstruktion mehrerer Targets im Tank visuell schlechter als die des ANN.

Auch das Linear Regression Modell ist bis zu einem gewissen Maß in der Lage, mehrere Targets im Tank zu rekonstruieren. Jedoch ist dabei der visuelle Eindruck qualitativ nicht so gut wie das ANN Modell.

## 9.3 K-Nearest Neighbors Regression

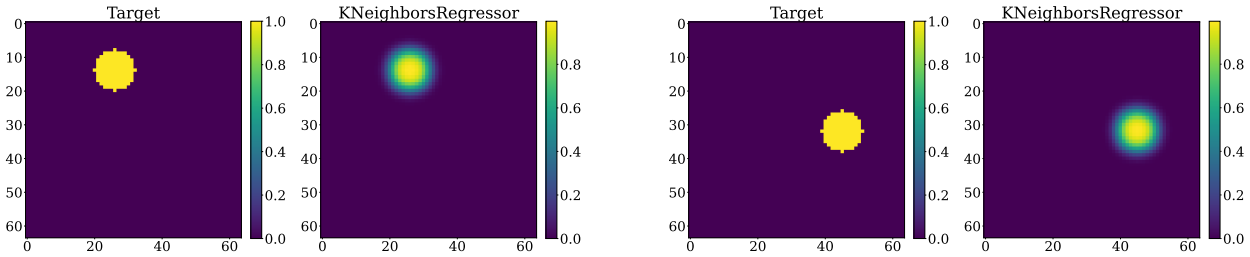
Als Nächstes wird ebenfalls wie im Fall der tdEIT ein KNN Regression Modell evaluiert. Dabei wird erneut das Dataset mit $40\,\mathrm{mm}$ Target mit einer Dimensionsreduzierung auf die ersten $512$ Hauptkomponenten genutzt. Dafür wurde der optimale Hyperparameter $K$ bestimmt, welcher in diesem Fall bei $K = 2$ liegt.

In Tabelle 9.4 können die verwendeten Augmentierungen betrachtet werden.

Tabelle 9.4: Augmentation Schritte für das KNN-Regressor Modell.

| Augmentierung | Augmentierte Kopien / Filter | Nr. of Samples |
|---|---|---|
| Default | - | 9695 |
| Noise | 4 | 81598 |
| Superposition | 3 | 244 794 |
| Gauss | 4 | 244 794 |

In Abbildung 9.19 können beispielhafte Rekonstruktionen von zwei positiv Samples betrachtet werden. Die negativ Samples ergeben, wie bereits im Fall der tdEIT, ideale komplett leere Bilder.




(a) (b)

Abbildung 9.19: Beispielhafte Rekonstruktionen des KNN Regression Algorithmus mit $K = 2$ aus dem Tariningsset. An den Trainingsdaten kann der KNN Regressor visuell sehr gute Rekonstruktionen erzeugen.

Am Trainingsset ist das KNN Modell in der Lage, visuell gute Rekonstruktionen zu erzeugen. Anschließend wird das Modell auch am identischen Testset evaluiert.

In Abbildung 9.20 ist die Performance am Testset zu sehen.

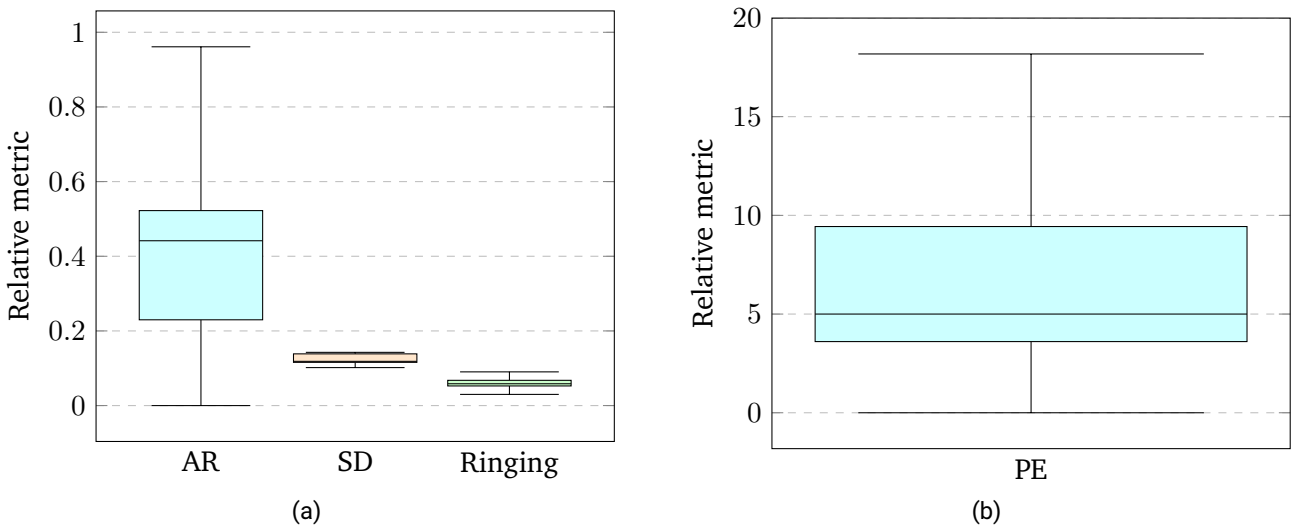



Abbildung 9.20: Die Median AR ist dabei mit $0.44$ etwa $22\,\%$ geringer als beim linearen Modell. SD und Ringing sind wie bereits im Fall der tdEIT mit $0.11$ und $0.05$ vergleichsweise gering. Sie sind jeweils um den Faktor $2$ und $10$ geringer als beim linearen Modell. Der Median PE ist mit $5\,\mathrm{Pixel}$ jedoch etwa doppelt so hoch.

Die Median AR des KNN Modells beträgt $0.44$. SD und Ringing sind wie bereits im Fall der tdEIT mit $0.11$ und $0.05$ vergleichsweise gering. Der PE ist mit einem Median von $5\,\mathrm{Pixel}$ jedoch vergleichsweise hoch.
Im Falle einer erfolgreichen Rekonstruktion liefert der KNN Ansatz gute Ergebnisse, jedoch gibt er häufig auch ein leeres Bild zurück.

Zur Evaluierung der Generalisierbarkeit auf mehrere Targets wird nun ebenfalls das Dataset mit den unterschiedlichen Target-Größen und Superposition Augmentation zum Training genutzt.
Die Performance für Samples mit mehreren Targets lässt sich wieder rein qualitativ evaluieren, da keine realen G.T. Samples existieren (Abbildung 9.21).

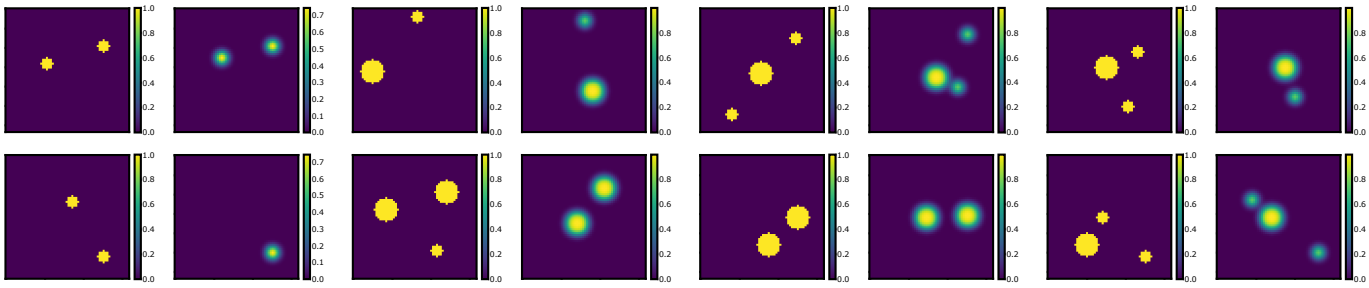


Abbildung 9.21: Zu sehen sind Beispiel Rekonstruktionen aus dem Trainingsset mit Superposition Augmentierung. Links ist jeweils das, durch Augmentation künstlich erzeugte, G.T. Bild und rechts die dazugehörige Rekonstruktion des KNN Modells. Die Anzahl und Größe der Targets sind oft richtig, jedoch stimmen die Positionen meistens nicht.

Dabei fällt auf, dass das Modell die Anzahl und Größe der Targets oft richtig erkennt, die Position ist jedoch meistens nicht korrekt. Dies deckt sich mit dem hohen Positionsfehler, der bereits am Testset aufgefallen ist. Dies kann eventuell durch eine größere Datenmenge mit mehr Konfigurationen verbessert werden.

# 10 Diskussion

Im folgendem Abschnitt werden die Ergebnisse dieser Arbeit diskutiert. Es konnte gezeigt werden, dass datenbasierte Rekonstruktionsalgorithmen mit realen Messdaten trainiert werden können. Der Prozess der Datensammlung kann mit einem vergleichsweise einfachen und kostengünstigem Versuchsaufbau realisiert werden.

### Vergleich der Modelle

Im Bereich der tdEIT hat sich die Vermutung aus Kapitel 4 bestätigt, dass DNNs eine bessere Rekonstruktionsperformance erreichen können als einfachere Ansätze wie die lineare- oder KNN-Regression. In Tabelle 10.1 kann ein Vergleich der Performance Metriken betrachtet werden.

Tabelle 10.1: Vergleich der Modelle.

| Metrik | Lineare Regression | KNN Regression | ANN (unoptimiert) | ANN (optimiert) |
|---|---|---|---|---|
| AR | 0.12 | 0.54 | 0.4 | 0.69 |
| SD | 0.11 | 0.14 | 0.2 | 0.14 |
| Ringing | 0.75 | 0.06 | 0.15 | 0.16 |
| PE (Pixel) | 2.1 | 3.2 | 4.3 | 2.3 |

Dabei ist zu sehen, dass das optimierte ANN Modell die höchste AR aufweist. Sie ist ca. $28\,\%$ höher als die des KNN Regressors. In Bezug auf die SD ist das lineare Modell leicht besser als KNN und ANN. Der KNN Regressor weist eine vergleichsweise geringes Ringing auf, hat dafür aber einen höheren PE. Das lineare Modell hat mit einem Ringing von $0.75$ ein starkes Überschwingen in der Rekonstruktion.
In Abschnitt 8.3.1 hat sich ebenfalls gezeigt, dass die Verwendung von Dropout Layern die ANN Modelle besser auf veränderte Umstände generalisieren lassen. Dies kann daran liegen, dass während dem Training einzelne Neuronen wegfallen. Dadurch wird die Gefahr verringert, dass sich das Netzwerk zu sehr auf einzelne Features verlässt und somit ist auch die Gefahr des Overfittings reduziert.

### Regularisierung, Dimensionsreduzierung und Normierung

Bei geringer Datenmenge hat sich in Abschnitt 8.3.2 gezeigt, dass die Performance durch die Verwendung der Data Augmentation verbessert werden kann. Durch die Verwendung von Noise- und Rotation-Augmentation konnte aus einer nahezu unbrauchbaren Rekonstruktion eine visuell deutlich bessere Rekonstruktion erzeugt werden (Abbildung 8.18). Somit lassen sich also schon mit geringer Anzahl an realen Messdaten (120 Samples) datenbasierte Modelle erfolgreich trainieren.
Es hat sich bestätigt, dass durch die Verwendung einer räumlichen Tiefpassfilterung der visuelle Eindruck und auch die Performance Metriken gesteigert werden können. Insbesondere das Ringing kann so reduziert werden. Das Optimum lag dabei bei $4$ Filterungen eines Gauss Filters mit einem $\sigma$ von $1$.

Zusätzlich wurde das Zusammenspiel aus Dimensionsreduzierung und Performanceverlust untersucht. Im Fall der tdEIT kann die Dimension der Features mittels PCA um die Hälfte reduziert werden, ohne signifikant an Performance einzubüßen (Abschnitt 8.3.5). Im Fall der absoluten EIT war bereits für die Konvergenz der Modelle eine Dimensionsreduzierung erforderlich. Nach der Dimensionsreduzierung ist jedoch auch ein absolutes EIT Modelle in der Lage, ohne eine Referenz eine Rekonstruktion zu erzeugen (Abschnitt 9.1.3).

Häufig können Normierungen dafür sorgen, dass Deep Learning basierte Algorithmen effizienter konvergieren können. In Abschnitt 9.1.2 hat sich auch im Fall der mfEIT bestätigt, dass die Verwendung einer Normierung den Trainingsprozess beschleunigen kann.

#### Steigerung der Generalisierungsfähigkeit

Da die Modelle durch die Trainingsdaten einen Bias auf Impedanzanomalien mit einem festen Radius besitzen, wurden in Abschnitt 9.1.4 weitere Targetgrößen mit in die Trainingsdaten aufgenommen. Anschließend konnte qualitativ gezeigt werden, dass das Modell dadurch in der Lage ist, unterschiedliche Targetgrößen im Tank zu erkennen (Abbildung 9.8). Hierbei müsste noch quantitativ an einem Testset evaluiert werden, wie gut die Performance je nach Targetgröße ausfällt. Insbesondere in der Tankmitte ist das kleinste Target häufig nicht mehr sichtbar.
Dabei ist zu beobachten, dass deutlich mehr Samples des kleineren Targets benötigt werden. Dies kann unter anderem daran liegen, dass das kleine Target lediglich eine kleinere Veränderung des Spannungsvektors hervorruft. Das kleinste erkennbare Target hatte dabei einen Durchmesser von $20\,\mathrm{mm}$, wodurch sich nach Gleichung (5.6) eine Auflösung des Systems von $0,324$ ergibt.

Ein weiterer Bias, der sich durch die Trainingsdaten ergeben hat, ist die Fokussierung auf ein einziges Target. Die trainierten Modelle zeigen eine Tendenz, maximal einen Peak in den Daten zu berücksichtigen und streben danach, alle anderen Werte möglichst nahe an Null zu halten. Dieses Verhalten basiert auf den Trainingsdaten, in denen die Modelle die Präsenz von nur einem Peak gelernt haben. Dabei wird vom Modell präferiert das Target abgebildet, welches sich weiter außen im Tank befindet. Dies kann am höheren SNR am Tankrand liegen, welches in Abschnitt 7.3 gezeigt wurde. Dadurch hat dieses Target eventuell den größeren Einfluss auf die Features und somit bestimmt es den Output des Modells.
Aus diesem Grund wurde in Abschnitt 9.1.5 untersucht, ob diese Einschränkung mittels einer Superposition Augmentation behoben werden kann. Es hat sich gezeigt, dass trotz der Nichtlinearität der EIT die lineare Überlagerung der Trainingsdaten hilft, das Modell auf komplexere Szenen mit mehreren Targets zu generalisieren. Diese Auswertung konnte jedoch nur qualitativ erfolgen, da keine G.T. Test Samples mit mehreren Targets existieren. Es fällt auf, dass ein gewisser Mindestabstand bestehen muss, ohne den das Modell nicht mehr in der Lage ist, die einzelnen Targets zu differenzieren. Ein Vergleich der Metriken an einem Testset mit jeweils einem Target pro Sample ist in Tabelle 10.2 zu sehen.

Tabelle 10.2: Vergleich der Modelle mit und ohne Superposition Augmentation.

| Metrik | ANN mfEIT | ANN mfEIT (Superposition Augmentation) |
|---|---|---|
| AR | 0.54 | 0.81 |
| SD | 0.16 | 0.35 |
| Ringing | 0.07 | 0.03 |
| PE (Pixel) | 2.8 | 2.2 |

Es ist zu erkennen, dass die AR um $30\,\%$ gesteigert ist. Dafür hat sich die SD im Gegenzug mehr als verdoppelt. Bei der Verwendung der Superposition Augmentation gibt es also ein gegensätzliches Verhalten zwischen AR

und SD. Durch die Superposition Augmentation wurden die Targets etwas größer und mit weicheren Kanten abgebildet, wodurch die SD steigt.

### Vergleich tdEIT und mfEIT

Aufgrund der unterschiedlichen Traings- und Test-Datasets ist es schwierig, einen Vergleich zwischen den tdEIT und mfEIT Modellen zu betrachten. Am besten vergleichbar ist die Performance beider ANN Modelle am $40\,\mathrm{mm}$ Datensatz (Tabelle 10.3).

Tabelle 10.3: Vergleich der tdEIT und mfEIT ANN Modelle.

| Metrik | ANN tdEIT | ANN mfEIT |
|---|---|---|
| AR | 0.69 | 0.54 |
| SD | 0.14 | 0.16 |
| Ringing | 0.16 | 0.07 |
| PE (Pixel) | 2.3 | 2.8 |

Es ist zu erkennen, dass das mfEIT Modell in allen Metriken bis auf dem Ringing schlechter abschneidet als das tdEIT Modell. Dies kann daran liegen, dass das Modell den Zusammenhang durch die zusätzliche Information in $V_0$ besser lernen kann.
Für einen kompletten Vergleich müssten für die tdEIT ebenfalls zusätzliche Daten unterschiedlicher Targetgrößen gesammelt werden sowie beide Modelle mit der Superposition Augmentation verglichen werden.

### Mögliche Anwendungen und Rechenaufwand

In Abschnitt 8.3.7 und Abschnitt 9.1.6 wurden die Modelle der tdEIT und mfEIT mit biologischem Material evaluiert. Dabei konnte gezeigt werden, dass die Modelle ebenfalls in der Lage sind, Materialien mit geringerer Impedanz zu rekonstruieren. Es hat sich jedoch gezeigt, dass die Rekonstruktion tierischer Zellen nicht erfolgreich war. Dies kann an der zu geringen Impedanz liegen, wodurch sie sich zu wenig vom Hintergrund abhebt. Für eine besser Generalisierbarkeit, könnten Targets mit geringerer Impedanz mit in die Trainingsdaten aufgenommen werden.

Durch den Bias auf ein einziges kreisförmiges Target im Bild wären diese Modelle vermutlich nicht in der Lage, komplexere Impedanzverteilungen, wie beispielsweise eine Lunge, abzubilden. Durch die Superposition Augmentation konnte dies qualitativ verbessert werden.
Trotz der gesteigerten Generalisierungsfähigkeit der Modelle muss überprüft werden, ob und wie gut sie für eventuelle medizinische Zwecke anwendbar sein können. Dafür müssten idealerweise G.T. Daten eines CT oder MRT vorliegen.

Die industrielle Anwendung für Rohrleitungs-Monitorung und Kontaminations-Tracking (Kapitel 1) ist denkbar, da diese nicht auf die Rekonstruktion komplexer Formen angewiesen sein muss. Wobei mit den hier entwickelten Modellen ausschließlich Kontaminationen mit ausreichend hoher Impedanz von mehr als ca. $1\,\mathrm{k\Omega}$ erkannt werden können. Ebenfalls die Größe der Kontamination müsste oberhalb der Auflösung des Systems von $0,324$ (Gleichung (5.6)) liegen.

Der Rechenaufwand der Modelle ist ebenfalls ausreichend gering, sodass bereits in einer nicht auf Performance ausgelegte Python-Implementierung bis zu $25\,\mathrm{FPS}$ möglich waren. Dadurch wären die Modelle prinzipiell für eine Realtime-Überwachung geeignet.

# 11 Schlussfolgerung und Ausblick

Im Rahmen dieser Arbeit wurde ein Versuchsaufbau entwickelt, der für das automatisierte Sammeln von Trainingsdaten für die EIT Rekonstruktion geeignet ist. Dabei ist das System vergleichsweise einfach zu konstruieren und ebenfalls kostengünstig. Dadurch ist es möglich, EIT Rekonstruktionsalgorithmen auf der Basis von realen Messdaten zu entwickeln.
Anschließend wurden über $14\,000$ Samples mit dem Aufbau gesammelt und die Möglichkeiten zur Data Augmentation von EIT Daten betrachtet. Dabei ist aufgefallen, dass die Qualität des Datasets einen großen Einfluss auf die Generalisierbarkeit der Modelle hat. Beispielsweise hat die Übergangsimpedanz der einzelnen Elektroden am Tank einen so großen Einfluss, dass sich die Rekonstruktion bei einem erneuten Anschließen des Tanks an andere Elektroden stark verschlechtert. Dies kann an einem Overfitting liegen. Um dieses Overfitting zu verhindern, wurde der Datensatz um verschiedene Drehungen des Tanks erweitert.
Danach wurden erste Rekonstruktionsalgorithmen anhand der tdEIT an den Messdaten evaluiert. Dabei wurden Deep Learning Modelle mit der linearen Regression und KNN-Regressoren verglichen. Dabei hat sich die Vermutung aus dem Stand der Technik bestätigt, dass mit Deep Learning Modellen bessere Ergebnisse erzielt werden können. Sie haben dabei in relevanten Metriken bis zu $28\,\%$ besser abgeschnitten als die Ansätze der linearen- oder der K-Nearest-Neighbour-Regression.

Es hat sich gezeigt, dass sich die Rekonstruktionen der Modelle durch die Erweiterung der Datasets um augmentierte Samples verbessern lassen. Dabei wurden folgende Arten der Augmentierung verwendet: Noise-, Rotation- und Gaussian-Blur-Augmentation. Es wurde nachgewiesen, dass Modelle, die bei einer geringen Datenmenge ($120$ Samples), Rekonstruktionen schlechter Qualität erzeugen, durch Augmentation signifikant (je nach Metrik um bis zu $50\,\%$) verbessert werden können.
Es wurde auch die Möglichkeit der absoluten EIT mittels mfEIT evaluiert. Es konnte bestätigt werden, dass die Bildrekonstruktion auch mittels absoluter EIT anhand von realen Messdaten möglich ist. Dabei hat sich gezeigt, dass aufgrund der größeren EIT-Frames der mfEIT eine Dimensionsreduzierung erforderlich sein kann, um eine Konvergenz der Modelle zu erreichen. Ebenfalls wurde ein positiver Einfluss einer Normierung der Eingangsdaten auf die Geschwindigkeit der Modellkonvergenz festgestellt.
Anschließend wurde überprüft, ob die Generalisierbarkeit der Modelle mit Messdaten unterschiedlicher Targetgrößen gesteigert werden kann. Es konnte qualitativ gezeigt werden, dass durch das Verwenden unterschiedlicher Targetgrößen im Trainingsdatensatz die Generalisierbarkeit gesteigert werden konnte.
Zusätzlich wurde evaluiert, ob es möglich ist, durch Superposition der Trainingsdaten neue Samples zu generieren, anhand derer die Modelle die Rekonstruktion komplexerer Szenen erlernen können. Dabei konnte qualitativ gezeigt werden, dass dies trotz der Nichtlinearität der EIT möglich ist.
Ebenfalls wurden die Modelle abschließend qualitativ mit Targets aus biologischem Material validiert. Dabei wurde bestätigt, dass die Modelle in der Lage sind, Targets mit unterschiedlichen Materialien und Größen gleichzeitig im Tank zu rekonstruieren.
Insgesamt konnte bestätigt werden, dass EIT Rekonstruktionsalgorithmen basierend auf realen Messdaten trainiert werden können.

### Ausblick

Zum einen kann der Aufbau genutzt werden, um eine größere Menge an Traningsdaten zu sammeln. Damit könnte die Modellperformance weiter verbessert werden. Aktuell ist die Faustformel von zehn Mal mehr Samples als Parameter noch nicht erreicht. Dabei kann eine größere Variation an Targets mit anderen Formen oder höherer und geringerer Impedanz genutzt werden. Dafür müssten die G.T. Bilder entsprechend angepasst werden.
Insbesondere der KNN Ansatz hat beim Training gute Ergebnisse geliefert, welche am Testset jedoch stark nachgelassen hat. Dies kann eventuell durch eine größere Datenbasis verbessert werden.

Zusätzlich könnten weitere Modell Architekturen entwickelt werden, die nun anhand der vorhandenen Daten trainiert werden können. Es können Hyperparameter wie die Anzahl der Layer und die darin enthaltenen Neuronen verglichen werden. Ebenfalls könnte der im Stand der Technik häufig genutzte CNN Ansatz evaluiert werden.

Zusätzlich kann die Tauglichkeit der Modelle für medizinische Anwendungen wie die Lungenüberwachung evaluiert werden. Eventuell ist es mittels „Transfer Learning“ möglich, das Modell auf Lungen-Daten zu adaptieren.

# Abbildungsverzeichnis


1.1 Elektrisch äquivalentes Schaltungsmodell einer Zelle. . . . . 9

2.1 Überblick über EIT Prozess. . . . . 11
2.2 Schema EIT Gerät. . . . . 12
2.3 Beispiel Injection Pattern. . . . . 13
2.4 Spannungs-Äquipotentiallinien während einer Messung. . . . . 13
2.5 Spannungs-Äquipotentiallinien während einer Messung mit Anomalie. . . . . 14
2.6 Plot eines EIT-Frames. . . . . 14

3.1 Aufbau eines einzelnen Neurons. . . . . 21
3.2 Aktivierungsfunktionen. . . . . 22
3.3 Deep Neural Network. . . . . 23
3.4 Data Split. . . . . 24
3.5 Gradient Decent. . . . . 25
3.6 Optimale LR. . . . . 26
3.7 Backpropagation Algorithmus. . . . . 27
3.8 Overfitting und Underfitting. . . . . 28
3.9 Early Stopping. . . . . 29
3.10 Dropout Layer. . . . . 30
3.11 Mögliche Augmentationen in der Bild Domäne. . . . . 31

4.1 Typisches Schema der Bildrekonstruktion. . . . . 32
4.2 Rekonstruktion mittels CNN . . . . . 34
4.3 Aufbau einer U-Net Architektur [58] zur Verbesserung der geringen räumlichen Auflösung von EIT [57]. . . . . 35
4.4 Die VDD-Net Architektur [59]. . . . . 35

5.1 Übersicht der Performance Kriterien. . . . . 36
5.2 Das QAS . . . . . 37
5.3 Detektion CoG. . . . . 37
5.4 Beispielhafte Darstellung zur Veranschaulichung der Kriterien. . . . . 38

6.1 Übersicht über den Versuchsaufbau . . . . . 40
6.2 Bilder Versuchsaufbau. . . . . 41

7.1 Datensammlung Beispiel. . . . . 42
7.2 Rotation Augmentation. . . . . 44
7.3 Superposition Augmentation. . . . . 45
7.4 Kumulativ erklärte Varianz der PCA. . . . . 46
7.5 Hauptkomponenten in den Daten. . . . . 47
7.6 Beispiel Spannungsvektor Rekonstruktion mittels PCA. . . . . 47
7.7 SNR Analyse der Daten. . . . . 48

8.1 Beispiele für eine Rekonstruktion mittels der linearen Regression. . . . . 50
8.2 Rekonstruktion mittels der linearen Regression mit Verwendung einer Dimensionsreduzierung. 51
8.3 Rekonstruktion mittels der linearen Regression unter Verwendung von Glättungsfiltern. . . . . 51
8.4 Performance Metriken des linearen Regression Modells . . . . . 52
8.5 Rekonstruktionen des KNN Regression Algorithmus mit $K = 4$. . . . . 52
8.6 Rekonstruktionen des KNN Regression Algorithmus unter Verwendung von Glättungsfiltern. . 53
8.7 Performance KNN Regressor Modell. . . . . 53
8.8 Schematischer Aufbau des ANN Modells. . . . . 54
8.9 Beispielhafte Rekonstruktionen der ANN Architektur. . . . . 55
8.10 Performance des ANN Modells. . . . . 55
8.11 Ortsabhängigkeit der AR des ANN Modells. . . . . 56
8.12 Ortsabhängigkeit des PE des ANN Modells. . . . . 56
8.13 Performance ANN Modell mit Dropout von $p = 10\,\%$. . . . . 57
8.14 Ortsabhängigkeit der AR des ANN Modells mit Dropout von $p = 10\,\%$. . . . . 57
8.15 Performance bei Verwendung weniger Samples. . . . . 58
8.16 Performance mit Niose Augmentation. . . . . 58
8.17 Performance mit Niose und Rotation Augmentation. . . . . 59

8.18 Visuelles Beispiel für Bessere Rekonstruktionen mittels Augmentation. . . . . 59
8.19 Effekt der Gauss Filter. . . . . 60
8.20 Effekt der Gauss Filter. . . . . 60
8.21 Performance über WD. . . . . 61
8.22 Performance über LR. . . . . 62
8.23 Kumulativ erklärte Varianz durch die ersten $n$ Hauptkomponenten. . . . . 63
8.24 Performance über der Anzahl der verwendeten Hauptkomponenten. . . . . 63
8.25 Das Modell mit den optimal ermittelten Parametern. . . . . 64
8.26 Versuchsaufbau organisches Material. . . . . 65
8.27 Performance an organischem Material. . . . . 65

9.1 Schematischer Aufbau des mfEIT ANN Modells. . . . . 66
9.2 Loss Funktion Training mfEIT ANN. . . . . 67
9.3 Metriken über der Anzahl an verwendeten Hauptkomponenten bei der mfEIT. . . . . 68
9.4 Loss Funktion vor der Normalisierung. . . . . 69
9.5 Loss Funktion nach der Normierung. . . . . 69
9.6 Metriken des ANN Modells mit absoluten EIT Daten. . . . . 70
9.7 Absolut EIT AR des Modells mit Dropout Layern. . . . . 70
9.8 Experiment mit unterschiedlichen Target Durchmessern. . . . . 71
9.9 Beispielbilder Superposition Augmentation. . . . . 72
9.10 Metriken des ANN Modells mit Superposition Augmentierung. . . . . 73
9.11 Beispielbilder Superposition Augmentation mit 1 - 3 Targets. . . . . 73
9.12 Unterschiedliche Target Materialien. . . . . 74
9.13 Bode Plot Kartoffel-Target. . . . . 74
9.14 Bode Plot Fleischwurst-Target. . . . . 75
9.15 Beispielhafte Szenen mit unterschiedlichen Materialien. . . . . 76
9.16 Beispiele für eine Rekonstruktion der mfEIT mittels der Linearen Regression. . . . . 77
9.17 Metriken des Linear Regression Modells. . . . . 78
9.18 Multi Target bei der Linearen Regression. . . . . 78
9.19 Beispielhafte Rekonstruktionen des KNN Regression Algorithmus aus dem Trainingset. . . . . 79
9.20 Metriken des KNN Regressor Modells mit Absoluten EIT Daten. . . . . 80
9.21 Multi Target bei des KNN Modells. . . . . 80

# Tabellenverzeichnis

1.1 Vergleich der medizinischen Bildgebungsverfahren [2, 5]. . . . . 8

2.1 Beispiel für einen EIT-Frame. Die einspeisenden Elektroden rotieren ein Mal im Kreis. Während jeder Einspeisung messen die restlichen Elektroden die Differenzspannungen. . . . . 14

8.1 Augmentation Schritte für das Modell. . . . . 64

9.1 Verteilung der Target-Größe im mfEIT Datensatz. . . . . 71
9.2 Augmentation Schritte für das Modell mit Superposition Augmentation. . . . . 72
9.3 Augmentation Schritte für das Lineare Regression Modell. . . . . 77
9.4 Augmentation Schritte für das KNN-Regressor Modell. . . . . 79

10.1 Vergleich der Modelle. . . . . 81
10.2 Vergleich der Modelle mit und ohne Superposition Augmentation. . . . . 82
10.3 Vergleich der tdEIT und mfEIT ANN Modelle. . . . . 83

# Akronyme

**ADC** Analog-Digital Wandler.

**ANN** Artificial Neural Network.

**AR** Amplitude Response.

**CNN** Convolutional Neural Network.

**CoG** Center of Gravity.

**CT** Computertomografie.

**DMUX** Demultiplexer.

**DNN** Deep Neural Network.

**EIDORS** Electrical Impedance Tomography and Diffuse Optical Tomography Reconstruction Software.

**EIT** Elektrische Impedanz Tomographie.

**fdEIT** frequencie difference EIT.

**FEM** Finite Elemente Methode.

**FPS** Frames per Second.

**G.T.** Ground Truth.

**GREIT** Graz consensus Reconstruction algorithm for EIT.

**IQR** interquartile range.

**KNN** K-Nearest Neighbors.

**LR** Learning Rate.

**MAE** Mean Absolute Error.

**mfEIT** multi frequency EIT.

**MRT** Magnetresonanztomographie.

**MSE** Mean Squared Error.

**MUX** Multiplexer.

**NOSER** Newton's One-Step Error Reconstructor.

**PCA** Principal Component Analysis.

**PE** Position Error.

**PLA** Polylactide.

**QAS** Quater Amplitude Set.

**ReLU** Rectified Linear Unit.

**RMS** Root Mean Square.

**RNN** Recurrent Neural Networks.

**ROI** Region Of Interest.

**RSS** Residual Sum of Squares.

**SD** Shape Deformation.

**SNR** Signal to Noise Ratio.

**SVD** Singular Value Decomposition.

**tdEIT** time difference EIT.

**WD** Weight Decay.

# Literatur


[1] *Diagnostische Bildgebungsgeräte - Weltweits*. URL: https://de.statista.com/outlook/hmo/medizintechnik/medizinische-geraete/diagnostische-bildgebungsgeraete/weltweit.

[2] Sofiene Mansouri u. a. „Electrical Impedance Tomography – Recent Applications and Developments“. In: *Journal of Electrical Bioimpedance* 12.1 (20. Nov. 2021). ISSN: 1891-5469. DOI: 10.2478/joeb-2021-0007. URL: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8667811/ (besucht am 25. 12. 2023).

[3] Sofiene Mansouri u. a. „Electrical Impedance tomography – recent applications and developments“. In: *Journal of Electrical Bioimpedance* 12.1 (2021), S. 50–62. DOI: doi:10.2478/joeb-2021-0007. URL: https://doi.org/10.2478/joeb-2021-0007.

[4] *Monitoring mit elektrischer Impedanztomographie*. URL: https://www.draeger.com/de_de/Hospital/Electrical-Impedance-Tomography.

[5] Eugene Lin und Adam Alessio. „What are the basic concepts of temporal, contrast, and spatial resolution in cardiac CT?“ In: *Journal of cardiovascular computed tomography* 3.6 (2009), S. 403–408. ISSN: 1934-5925. DOI: 10.1016/j.jcct.2009.07.003. URL: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4752333/ (besucht am 11. 01. 2024).

[6] *Electrical Impedance Tomography (EIT): A Harmless Medical Imaging Modality*. URL: https://www.igi-global.com/gateway/chapter/159711.

[7] Qusai Hassan, Soha Ahmadi und Kagan Kerman. „Recent Advances in Monitoring Cell Behavior Using Cell-Based Impedance Spectroscopy“. In: *Micromachines* 11.6 (13. Juni 2020), S. 590. ISSN: 2072-666X. DOI: 10.3390/mi11060590. URL: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7345285/ (besucht am 03. 01. 2024).

[8] Yunjie Yang u. a. „A Miniature Electrical Impedance Tomography Sensor and 3-D Image Reconstruction for Cell Imaging“. In: *IEEE Sensors Journal* 17.2 (2017), S. 514–523. DOI: 10.1109/JSEN.2016.2631263.

[9] Zhou Chen, Yunjie Yang und Pierre-Olivier Bagnaninchi. „Hybrid Learning-Based Cell Aggregate Imaging With Miniature Electrical Impedance Tomography“. In: *IEEE Transactions on Instrumentation and Measurement* 70 (2021), S. 1–10. DOI: 10.1109/TIM.2020.3035384.

[10] *Elektrische Impedanztomographie*. URL: https://www.sciospec.com/de/eit/.

[11] *das Sciospec EIT32/64/128+ Platform für Elektrische Impedanztomographie*. URL: https://www.sciospec.com/de/produkt/eit32-64-128/.

[12] Andy Adler und David Holder. *Electrical Impedance Tomography: Methods, History and Applications 2nd Edition*. 2022.

[13] Huaijin Chen u. a. „Development of a Portable Electrical Impedance Tomography Device for Online Thrombus Detection in Extracorporeal-Circulation Equipment“. In: *IEEE Sensors Journal* 21 (Feb. 2021), S. 3653–3659. DOI: 10.1109/JSEN.2020.3022078.

[14] Olavo Luppi Silva u. a. „Influence of current injection pattern and electric potential measurement strategies in electrical impedance tomography“. In: *Control Engineering Practice* 58 (2017), S. 276–286. ISSN: 0967-0661. DOI: https://doi.org/10.1016/j.conengprac.2016.03.003. URL: https://www.sciencedirect.com/science/article/pii/S0967066116300351.

[15] Taweechai Ouypornkochagorn. „Misinterpretation of Scalp Voltage Response in the Application of Electrical Impedance Tomography to the Head“. In: *Journal of Applied Science and Engineering* 22 (3 Sep. 2019), S. 501–508. ISSN: 1560-6686. DOI: 10.6180/jase.201909_22(3).0011. URL: https://doi.org/10.6180/jase.201909_22(3).0011.

[16] Andy Adler u. a. „GREIT: a unified approach to 2D linear EIT reconstruction of lung images“. In: *Physiological Measurement* 30.6 (Juni 2009), S35. DOI: 10.1088/0967-3334/30/6/S03. URL: https://dx.doi.org/10.1088/0967-3334/30/6/S03.

[17] Christoph Bernhard Hoog Antink. *Adaptive Rekonstruktionsoptimierung in der elektrischen Impedanztomographie*. Diplomarbeit. 2. Juni 2012.

[18] *EIDORS: Electrical Impedance Tomography and Diffuse Optical Tomography Reconstruction Software*. URL: https://eidors3d.sourceforge.net/.

[19] Benyuan Liu u. a. „pyEIT: A python based framework for Electrical Impedance Tomography“. In: *SoftwareX* 7 (2018), S. 304–308.

[20] Talha Ali Khan und Sai Ho Ling. „Review on Electrical Impedance Tomography: Artificial Intelligence Methods and its Applications“. In: *Algorithms* 12.5 (Mai 2019). Number: 5 Publisher: Multidisciplinary Digital Publishing Institute, S. 88. ISSN: 1999-4893. DOI: 10.3390/a12050088. URL: https://www.mdpi.com/1999-4893/12/5/88 (besucht am 08. 12. 2023).

[21] Jacques Hadamard. *Sur les probèmes aux dérivés partielles et leur signification physique*. Princeton University Bulletin, März 1902. URL: https://onlinelibrary.wiley.com/doi/abs/10.1002/ima.1850020203.

[22] *Kondition (Mathematik)*. URL: https://www.biancahoegel.de/mathe/verfahr/kondition.html.

[23] *Everything You Need To Know About Regularization*. URL: https://towardsdatascience.com/everything-you-need-to-know-about-regularization-64734f240622.

[24] M. Cheney u. a. „NOSER: An algorithm for solving the inverse conductivity problem“. In: *International Journal of Imaging Systems and Technology* 2.2 (1990), S. 66–75. ISSN: 1098-1098. DOI: 10.1002/ima.1850020203. URL: https://onlinelibrary.wiley.com/doi/abs/10.1002/ima.1850020203 (besucht am 02. 11. 2023).

[25] *Why Neural Nets Can Approximate Any Function*. URL: https://towardsdatascience.com/why-neural-nets-can-approximate-any-function-a878768502f0#:~:text=The%5C%20key%5C%20to%5C%20neural%5C%20networks,the%5C%20output%5C%20of%5C%20that%5C%20layer..

[26] *Why Deep Learning over Traditional Machine Learning?* URL: https://towardsdatascience.com/why-deep-learning-is-needed-over-traditional-machine-learning-1b6a99177063.

[27] *Neural Networks: The Basics and a Collection of YouTube Videos*. URL: https://francescolelli.info/tutorial/neural-networks-a-collection-of-youtube-videos-for-learning-the-basics/.

[28] *How Much Data Is Needed For Machine Learning?* URL: https://graphite-note.com/how-much-data-is-needed-for-machine-learning#:~:text=Generally%5C%20speaking%5C%

2C%5C%20the%5C%20rule%5C%20of,100%5C%20rows%5C%20for%5C%20optimal%5C%20results..

[29] Mohamed Alloghani u. a. „A Systematic Review on Supervised and Unsupervised Machine Learning Algorithms for Data Science“. In: *Supervised and Unsupervised Learning for Data Science*. Hrsg. von Michael W. Berry, Azlinah Mohamed und Bee Wah Yap. Cham: Springer International Publishing, 2020, S. 3–21. ISBN: 978-3-030-22475-2. DOI: 10.1007/978-3-030-22475-2_1. URL: https://doi.org/10.1007/978-3-030-22475-2_1.

[30] *Understanding Loss Function in Deep Learning*. URL: https://www.analyticsvidhya.com/blog/2022/06/understanding-loss-function-in-deep-learning/#:~:text=In%5C%20deep%5C%20learning%5C%2C%5C%20%5C%E2%5C%80%5C%9Closs%5C%20function,training%5C%20process%5C%20to%5C%20improve%5C%20accuracy..

[31] *Coding Deep Learning for Beginners — Linear Regression (Part 3): Training with Gradient Descent*. URL: https://towardsdatascience.com/coding-deep-learning-for-beginners-linear-regression-gradient-descent-fcd5e0fc077d.

[32] *Understanding Learning Rates and How It Improves Performance in Deep Learning*. URL: https://towardsdatascience.com/understanding-learning-rates-and-how-it-improves-performance-in-deep-learning-d0d4059c1c10.

[33] *The Vanishing Gradient Problem*. URL: https://towardsdatascience.com/the-vanishing-gradient-problem-69bf08b15484.

[34] *Vermeidung der Überanpassung von Machine-Learning-Modellen*. URL: https://de.mathworks.com/discovery/overfitting.html.

[35] *This thing called Weight Decay*. URL: https://towardsdatascience.com/this-thing-called-weight-decay-a7cd4bcfccab.

[36] *Early Stopping in Practice: an example with Keras and TensorFlow 2.0*. URL: https://towardsdatascience.com/a-practical-introduction-to-early-stopping-in-machine-learning-550ac88bc8fd.

[37] *Dropout in Neural Networks*. URL: https://towardsdatascience.com/dropout-in-neural-networks-47a162d621d9.

[38] Christoph Bernhard Hoog Antink. *Künstliche Intelligenz in der Medizin 18-ha-2020 – VL 08 Neuronale Netze*.

[39] *AutoML for Data Augmentation*. URL: https://blog.insightdatascience.com/automl-for-data-augmentation-e87cf692c366.

[40] *Model-Driven vs Data Driven methods for Working with Sensors and Signals*. URL: https://medium.com/@RealityAI/model-driven-vs-data-driven-methods-for-working-with-sensors-and-signals-98fc6ac8cc92.

[41] *Curse of Dimensionality — A “Curse” to Machine Learning*. URL: https://towardsdatascience.com/curse-of-dimensionality-a-curse-to-machine-learning-c122ee33bfeb.

[42] *What is Explainable AI (XAI)?* URL: https://towardsdatascience.com/what-is-explainable-ai-xai-afc56938d513.

[43] S J Hamilton, W R B Lionheart und A Adler. „Comparing D-bar and common regularization-based methods for electrical impedance tomography“. In: *Physiological Measurement* 40.4 (Apr. 2019), S. 044004. DOI: 10.1088/1361-6579/ab14aa. URL: https://dx.doi.org/10.1088/1361-6579/ab14aa.

[44] „An Impedance Camera for Spatially Specific Measurements of the Thorax“. In: *IEEE Transactions on Biomedical Engineering* BME-25.3 (1978), S. 250–254. DOI: 10.1109/TBME.1978.326329.

[45] B H Brown und A D Seagar. „The Sheffield data collection system“. In: *Clinical Physics and Physiological Measurement* 8.4A (Nov. 1987), S. 91. DOI: 10.1088/0143-0815/8/4A/012. URL: https://dx.doi.org/10.1088/0143-0815/8/4A/012.

[46] Fadil Santosa und Michael Vogelius. „A Backprojection Algorithm for Electrical Impedance Imaging“. In: *SIAM Journal on Applied Mathematics* 50.1 (1990), S. 216–243. DOI: 10.1137/0150014. URL: https://doi.org/10.1137/0150014.

[47] J -P Morucci u. a. „A direct sensitivity matrix approach for fast reconstruction in electrical impedance tomography“. In: *Physiological Measurement* 15.2A (Mai 1994), A107. DOI: 10.1088/0967-3334/15/2A/015. URL: https://dx.doi.org/10.1088/0967-3334/15/2A/015.

[48] Michael Imhoff. *Electrical Impedance Tomography: The realisation of regional ventilation monitoring 2nd edition Eckhard Teschner*.

[49] Chao Tan u. a. „Image Reconstruction Based on Convolutional Neural Network for Electrical Resistance Tomography“. In: *IEEE Sensors Journal* 19.1 (2019), S. 196–204. DOI: 10.1109/JSEN.2018.2876411.

[50] Tao Zhang u. a. „Advances of deep learning in electrical impedance tomography image reconstruction“. In: *Frontiers in Bioengineering and Biotechnology* 10 (2022). ISSN: 2296-4185. URL: https://www.frontiersin.org/articles/10.3389/fbioe.2022.1019531 (besucht am 20. 07. 2023).

[51] S. Acharya und B.C. Taylor. „A neural network based method for the inverse problem of electrical impedance tomography“. In: *IEEE 30th Annual Northeast Bioengineering Conference, 2004. Proceedings of the*. 2004, S. 55–56. DOI: 10.1109/NEBC.2004.1299990.

[52] Marketa Michalikova u. a. „Image reconstruction in electrical impedance tomography using neural network“. In: *2014 Cairo International Biomedical Engineering Conference (CIBEC)*. 2014, S. 39–42. DOI: 10.1109/CIBEC.2014.7020959.

[53] Timo Huuhtanen und Alexander Jung. „Anomaly Location Detection with Electrical Impedance Tomography Using Multilayer Perceptrons“. In: *2020 IEEE 30th International Workshop on Machine Learning for Signal Processing (MLSP)*. 2020, S. 1–6. DOI: 10.1109/MLSP49062.2020.9231818.

[54] A. Adler und R. Guardo. „A neural network image reconstruction technique for electrical impedance tomography“. In: *IEEE Transactions on Medical Imaging* 13.4 (1994), S. 594–600. DOI: 10.1109/42.363109.

[55] Yang Wu u. a. „Shape Reconstruction With Multiphase Conductivity for Electrical Impedance Tomography Using Improved Convolutional Neural Network Method“. In: *IEEE Sensors Journal* 21.7 (2021), S. 9277–9287. DOI: 10.1109/JSEN.2021.3050845.

[56] Andre Bianchessi u. a. „Electrical Impedance Tomography Image Reconstruction Based on Neural Networks“. In: *IFAC-PapersOnLine* 53.2 (2020). 21st IFAC World Congress, S. 15946–15951. ISSN: 2405-8963. DOI: https://doi.org/10.1016/j.ifacol.2020.12.360. URL: https://www.sciencedirect.com/science/article/pii/S2405896320306443.

[57] S J Hamilton, J L Mueller und T R Santos. „Robust computation in 2D absolute EIT (a-EIT) using D-bar methods with the ‘exp’ approximation“. In: *Physiological Measurement* 39.6 (Juni 2018), S. 064005. DOI: 10.1088/1361-6579/aac8b1. URL: https://dx.doi.org/10.1088/1361-6579/aac8b1.

[58] Olaf Ronneberger, Philipp Fischer und Thomas Brox. „U-net: Convolutional networks for biomedical image segmentation“. In: *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015:*

*18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18*. Springer. 2015, S. 234–241.

[59] Xinyu Zhang u. a. „V-Shaped Dense Denoising Convolutional Neural Network for Electrical Impedance Tomography“. In: *IEEE Transactions on Instrumentation and Measurement* 71 (2022), S. 1–14. DOI: 10.1109/TIM.2022.3166177.

[60] Shu-Wei Huang, Hao-Min Cheng und Shien-Fong Lin. „Improved Imaging Resolution of Electrical Impedance Tomography Using Artificial Neural Networks for Image Reconstruction“. In: *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. 2019, S. 1551–1554. DOI: 10.1109/EMBC.2019.8856781.

[61] Shangjie Ren u. a. „RCRC: A Deep Neural Network for Dynamic Image Reconstruction of Electrical Impedance Tomography“. In: *IEEE Transactions on Instrumentation and Measurement* 70 (2021), S. 1–11. DOI: 10.1109/TIM.2021.3092061.

[62] Zhou Chen u. a. *Edinburgh EIT Dataset*. Accepted: 2022-05-26T15:53:49Z. 26. Mai 2022. DOI: 10.7488/ds/3463. URL: https://datashare.ed.ac.uk/handle/10283/4440 (besucht am 10. 11. 2023).

[63] *Ender 3*. URL: https://www.creality.com/products/ender-3-3d-printer.

[64] Xu Bai u. a. „A Comprehensive Noise Model for Wideband and High Frame Rate Electrical Impedance Tomography Systems“. In: *IEEE Sensors Journal* 23.13 (2023), S. 14253–14263. DOI: 10.1109/JSEN.2023.3275639.

[65] Xu Bai u. a. „A Modified Noise Model of Electrical Impedance Tomography System by Considering Colored Noises“. In: *IEEE Transactions on Instrumentation and Measurement* 71 (2022), S. 1–10. DOI: 10.1109/TIM.2022.3144223.

[66] *Principal Component Analysis – einfach erklärt!* URL: https://databasecamp.de/statistik/principal-component-analysis#:~:text=Die%5C%20Principal%5C%20Component%5C%20Analysis%5C%20(kurz,einen%5C%20Gro%5C%C3%5C%9Fteil%5C%20der%5C%20Varianz%5C%20erkl%5C%C3%5C%A4ren..

[67] *What is Dimensionality Reduction? Overview, and Popular Techniques*. URL: https://www.simplilearn.com/what-is-dimensionality-reduction-article.

[68] *Principal Component Analysis – einfach erklärt!* URL: https://medium.com/@dareyadewumi650/understanding-the-role-of-eigenvectors-and-eigenvalues-in-pca-dimensionality-reduction-10186dad0c5c.

[69] *How to Calculate Signal to Noise Ratio*. URL: https://www.horiba.com/int/scientific/technologies/fluorescence-spectroscopy/how-to-calculate-signal-to-noise-ratio/.

[70] Alistair Boyle und Andy Adler. „The impact of electrode area, contact impedance and boundary shape on EIT images“. In: *Physiological Measurement* 32.7 (1. Juli 2011), S. 745–754. ISSN: 0967-3334, 1361-6579. DOI: 10.1088/0967-3334/32/7/S02. URL: https://iopscience.iop.org/article/10.1088/0967-3334/32/7/S02 (besucht am 04. 12. 2023).